

# 硕士学位论文

## 数据驱动的互联网卡用户离网预测及干预 算法研究

□□□□

Central South University

一级学科            计算机科学与技术  
二级学科            计算机应用技术  
作者姓名            钱凯  
指导教师            吕丰教授

2022 年 4 月



中图分类号 TP391  
UDC 004.9

学校代码 10533  
学位类别 学术学位

## 硕士学位论文

# 数据驱动的互联网卡用户离网预测及干预 算法研究

□□□□

**Central South University**

作者姓名 钱凯  
一级学科 计算机科学与技术  
二级学科 计算机应用技术  
研究方向 深度学习  
二级培养单位 计算机学院  
指导教师 吕丰 教授  
副指导教师

论文答辩日期 \_\_\_\_\_ 答辩委员会主席 \_\_\_\_\_

中南大学

2022年4月



## 学位论文原创性声明

本人郑重声明，所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了论文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中南大学或其他教育机构的学位或证书而使用过的材料。与我共同工作的同志对本研究所作的贡献均已在论文中作了明确的说明。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

学位论文作者签名：\_\_\_\_\_ 日期：\_\_\_\_年\_\_月\_\_日

## 学位论文版权使用授权书

本学位论文作者和指导教师完全了解中南大学有关保留、使用学位论文的规定：即学校有权保留并向国家有关部门或机构送交学位论文的复印件和电子版，允许本学位论文被查阅和借阅。本人授权中南大学可以将本学位论文的全部或部分内容编入有关数据库进行检索和公开传播，可以采用复印、缩印或其它手段保存和汇编学位论文。本人同意按《中国优秀博硕士学位论文全文数据库出版章程》规定享受相关权益。本人保证：毕业后以学位论文内容发表的论文作者单位注明中南大学；学位论文电子文档的内容和纸质学位论文的内容相一致。

延缓公开论文延缓到期后适用本授权书，涉密论文在解密后适用本授权书。

本学位论文属于：(请在以下相应方框内打“√”)

公开

延缓公开，延缓期限（\_\_\_\_年\_\_月\_\_日至\_\_\_\_年\_\_月\_\_日）

学位论文作者签名：\_\_\_\_\_

指导教师签名：\_\_\_\_\_

日期：\_\_\_\_年\_\_月\_\_日

日期：\_\_\_\_年\_\_月\_\_日

(填写阿拉伯数字)



# 数据驱动的互联网卡用户离网预测及干预算法研究

**摘要：** LaTeX 利用设置好的模板，可以编译为格式统一的 pdf。目前国内大多出版社与高校仍在使用 word，word 由于其强大的功能与灵活性，在新手面对形式固定的论文时，排版、编号、参考文献等简单事务反而会带来很多困难与麻烦，对于一些需要通篇修改的问题，要想达到 LaTeX 的效率，对 word 使用者来说需要具有较高的技能水平。

为了能把主要精力放在论文撰写上，许多国际期刊和高校都支持 LaTeX 的撰写与提交，新手不需要关心格式问题，只需要按部就班的使用少数符号标签，即可得到符合要求的文档。且在需要全篇格式修改时，更换或修改模板文件，即可直接重新编译为新的样式文档，这对于 word 新手使用 word 的感受来说是不可思议的。

本项目的目的是为了创建一个符合中南大学研究生学位论文（博士）撰写规范的 TeX 模板，解决学位论文撰写时格式调整的痛点。

图 38 幅，表 1 个，参考文献 8 篇

**关键词：** 中南大学；学位论文；LaTeX 模板

**分类号：** TP391

□□□□

**Central South University**

**Abstract:** LaTeX can be compiled into a pdf of uniform format using the set template. At present, most domestic publishers and universities still use word. Because of its powerful function and flexibility, when faced with fixed-form papers by novices, simple matters such as typesetting, numbering, and reference documents will bring many difficulties and troubles. For some problems that need to be modified throughout, to achieve the efficiency of LaTeX, it requires a high level of skill for word users.

In order to focus on the writing of papers, many international journals and universities support the writing and submission of LaTeX. Novices don't need to care about formatting issues. They only need to use a few symbolic labels step by step to get the documents that meet the requirements. And when you need to modify the entire format, you can directly recompile the template file by replacing or modifying the template file. This is incredible for the word novice to use the word.

The purpose of this project is to create a TeX template that meets the specifications of the graduate degree thesis (PhD) of Central South University, and to address the pain points of format adjustment during the dissertation writing.

**Keywords:** CSU; LaTeX; Template

**Classification:** TP391

# 目 录

|   |      |
|---|------|
| 摘要 . . . . .                            | I    |
| ABSTRACT . . . . .                      | II   |
| 目录 . . . . .                            | III  |
| 插图索引 . . . . .                          | VI   |
| 表格索引 . . . . .                          | VIII |
| 符号说明 . . . . .                          | IX   |
| 第 1 章 绪论 . . . . .                      | 1    |
| 1.1 研究背景与意义 . . . . .                   | 1    |
| 1.2 国内外研究现状 . . . . .                   | 1    |
| 1.3 主要研究内容 . . . . .                    | 1    |
| 1.4 论文组织结构 . . . . .                    | 1    |
| 第 2 章 相关理论概述 . . . . .                  | 1    |
| 2.1 用户画像 . . . . .                      | 2    |
| 2.2 深度学习算法 . . . . .                    | 2    |
| 2.2.1 卷积神经网络 . . . . .                  | 2    |
| 2.2.2 循环神经网络 . . . . .                  | 2    |
| 2.2.3 基于注意力机制的神经网络 . . . . .            | 2    |
| 2.3 强化学习算法 . . . . .                    | 2    |
| 2.3.1 基于随机过程的多臂老虎机 . . . . .            | 2    |
| 2.4 本章小结 . . . . .                      | 2    |
| 第 3 章 基于自注意力机制的互联网卡用户离网预测模型设计 . . . . . | 2    |
| 3.1 平台描述 . . . . .                      | 2    |
| 3.2 数据描述 . . . . .                      | 3    |
| 3.3 数据分析 . . . . .                      | 5    |
| 3.4 特征工程 . . . . .                      | 8    |
| 3.4.1 静态特征工程 . . . . .                  | 8    |

|   |           |
|---|-----------|
| 3.4.2 时序特征工程 . . . . .                    | 12        |
| 3.5 问题建模与模型描述 . . . . .                   | 14        |
| 3.6 基于自注意力机制的编码算法 . . . . .               | 14        |
| 3.7 基于主成分分析算法的特征降维算法 . . . . .            | 16        |
| 3.8 基于多层次感知机的分类器设计 . . . . .              | 16        |
| 3.9 本章小结 . . . . .                        | 17        |
| <b>第 4 章 关于离网预测模块的实验评估与结果分析 . . . . .</b> | <b>18</b> |
| 4.1 实验设置 . . . . .                        | 18        |
| 4.1.1 基准模型 . . . . .                      | 19        |
| 4.1.2 评估指标 . . . . .                      | 19        |
| 4.2 用户离网预测模型性能评估 . . . . .                | 20        |
| 4.2.1 系统总体性能 . . . . .                    | 20        |
| 4.2.2 Top-U 用户的性能 . . . . .               | 21        |
| 4.3 参数影响 . . . . .                        | 23        |
| 4.3.1 性别参数的影响 . . . . .                   | 23        |
| 4.3.2 年龄参数的影响 . . . . .                   | 24        |
| 4.3.3 APP 参数的影响 . . . . .                 | 25        |
| 4.3.4 套餐参数的影响 . . . . .                   | 25        |
| 4.4 消融实验 . . . . .                        | 26        |
| <b>第 5 章 用户离网偏好感知的干预匹配算法设计 . . . . .</b>  | <b>28</b> |
| 5.1 模块描述 . . . . .                        | 28        |
| 5.2 离网原因与偏好的相关性分析 . . . . .               | 28        |
| 5.3 离网偏好排名归一化 . . . . .                   | 30        |
| 5.4 离网偏好生成 . . . . .                      | 31        |
| 5.4.1 不可信用户过滤机制 . . . . .                 | 31        |
| 5.4.2 自适应的权重归一化 . . . . .                 | 32        |
| 5.5 系统描述与问题建模 . . . . .                   | 33        |
| 5.6 奖励生成模型设计 . . . . .                    | 34        |
| 5.7 基于汤普森采样的用户-干预措施匹配算法设计 . . . . .       | 36        |
| 5.7.1 问题建模 . . . . .                      | 36        |
| 5.7.2 基于奖励生成模型的训练算法 . . . . .             | 37        |
| 5.8 本章小结 . . . . .                        | 37        |

|                                    |    |
|------------------------------------|----|
| 第 6 章 关于干预匹配算法模块的实验评估与结果分析 .....   | 38 |
| 6.1 实验设置 .....                     | 38 |
| 6.1.1 对比方案 .....                   | 38 |
| 6.1.2 评估指标 .....                   | 39 |
| 6.2 预离网用户干预框架性能评估 .....            | 40 |
| 6.2.1 性能检测与对比 .....                | 40 |
| 6.2.2 健壮性测试 .....                  | 42 |
| 6.3 参数影响 .....                     | 43 |
| 6.3.1 城市 .....                     | 43 |
| 6.3.2 年龄 .....                     | 43 |
| 6.3.3 离网风险 .....                   | 43 |
| 6.4 本章小结 .....                     | 45 |
| 第 7 章 总结与展望 .....                  | 46 |
| 7.1 工作总结 .....                     | 46 |
| 7.2 未来工作展望 .....                   | 46 |
| 参考文献 .....                         | 47 |
| 附录 A (附录名称) (三号黑体, 加粗) (必要时) ..... | 48 |
| 攻读学位期间主要的研究成果 .....                | 49 |
| 致 谢 .....                          | 50 |

## 插图索引

|                                   |    |
|-----------------------------------|----|
| 图 1-1 论文组织架构图 .....               | 1  |
| 图 3-1 大数据平台系统架构 .....             | 3  |
| 图 3-2 用户侧数据描述 .....               | 4  |
| 图 3-3 物品侧数据描述 .....               | 5  |
| 图 3-4 互联网卡发展趋势 .....              | 6  |
| 图 3-5 互联网卡离网用户-日期热力图 .....        | 7  |
| 图 3-6 互联网卡用户 Top10 离网原因 .....     | 8  |
| 图 3-7 互联网卡用户账户余额对比 .....          | 9  |
| 图 3-8 月不同阶段的互联网卡用户平均消耗流量值对比 ..... | 9  |
| 图 3-9 互联网卡用户月 APP 使用频次对比 .....    | 10 |
| 图 3-10 互联网卡用户流量活跃熵对比 .....        | 11 |
| 图 3-11 互联网卡用户目标编码值对比 .....        | 11 |
| 图 3-12 互联网卡用户流量记录条数序列对比 .....     | 13 |
| 图 3-13 互联网卡用户流量异常天数对比 .....       | 13 |
| 图 3-14 互联网卡用户离网预测模型架构 .....       | 15 |
| 图 4-1 基于滑动窗口的离网预测实验设置 .....       | 18 |
| 图 4-2 离网预测性能对比 .....              | 20 |
| 图 4-3 Top-U 用户的召回率对比 .....        | 21 |
| 图 4-4 Top-U 用户的精准率对比 .....        | 22 |
| 图 4-5 Top-U 用户的 F1 分数对比 .....     | 22 |
| 图 4-6 性别参数的影响 .....               | 23 |
| 图 4-7 年龄参数的影响 .....               | 24 |
| 图 4-8 APP 参数的影响 .....             | 25 |
| 图 4-9 套餐参数的影响 .....               | 26 |
| 图 5-1 预离网用户偏好生成模块图 .....          | 28 |
| 图 5-2 互联网卡用户所有离网原因示意图 .....       | 29 |
| 图 5-3 互联网卡用户可建模的离网原因示意图 .....     | 30 |
| 图 5-4 干预策略匹配模块图 .....             | 34 |
| 图 5-5 奖励模型内部示意图 .....             | 35 |
| 图 6-1 匹配算法性能对比图 .....             | 40 |
| 图 6-2 干预框架总体性能对比图 .....           | 41 |
| 图 6-3 奖励总和对比图 .....               | 42 |

|                             |    |
|-----------------------------|----|
| 图 6-4 平均奖励对比图 .....         | 42 |
| 图 6-5 收入总和对比图 .....         | 43 |
| 图 6-6 不同先验分布下的系统性能对比图 ..... | 44 |
| 图 6-7 城市参数对于性能影响的对比图 .....  | 44 |
| 图 6-8 年龄参数对于性能影响的对比图 .....  | 45 |
| 图 6-9 年龄参数对于性能影响的对比图 .....  | 45 |

## 表格索引

|                      |    |
|----------------------|----|
| 表 4-1 消融实验 . . . . . | 26 |
|----------------------|----|

## 符号说明

| 符号 | 意义   | 单位（量纲） |
|----|------|--------|
| 频率 | 赫[兹] | Hz     |

## 第1章 绪论

- 1.1 研究背景与意义
- 1.2 国内外研究现状
- 1.3 主要研究内容
- 1.4 论文组织结构

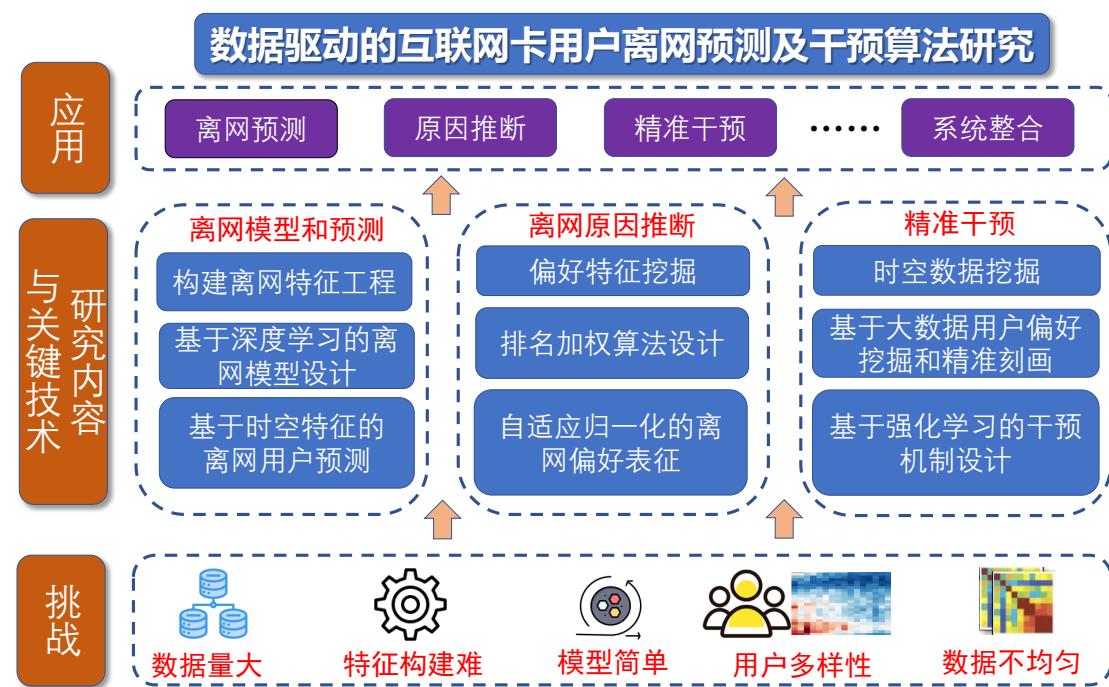


图 1-1 论文组织架构图

## 第2章 相关理论概述

## 2.1 用户画像

### 2.2 深度学习算法

#### 2.2.1 卷积神经网络

#### 2.2.2 循环神经网络

#### 2.2.3 基于注意力机制的神经网络

### 2.3 强化学习算法

#### 2.3.1 基于随机过程的多臂老虎机

### 2.4 本章小结

## 第3章 基于自注意力的互联网卡用户离网预测模型设计

### 3.1 平台描述

在本章中，本文会首先介绍平台架构，然后描述数据格式、规模等信息，接着进行了三个方面的数据分析，最后进行了相应的特征工程。

运营商们每天都会生产和存储巨量的数据，其中分为业务支持系统（BSS）和运营支持系统（OSS），这两者也构建了大数据平台的底层，从而用来提升业务和运营表现。具体来说，图3-1展示了流量运营商的大数据平台架构，其中包括数据层、业务逻辑层、核心算法层和应用层。

首先是数据层，数据层主要是承担数据采集、数据存储和数据管理的功能。首先从数据源中保存来自业务支持系统（BSS）和运营支持系统（OSS）的多维度数据，包括用户属性数据、用户流量使用数据、用户CDR数据、用户APP数据等。然后通过数据操作工具来做这些数据做周期性的更新、修改和删改工作从而提供给上层做其他工作。其中，Hadoop分布式文件系统（HDFS）通过分布式硬件平台来提供基础的数据存储功能。Hive/Spark SQL则是提供数据查询、清洗、过滤等功能，尤其是提高了针对海量数据的开发和处理效率。而MapReduce则是提供大数据的并行计算范式从而缩短数据处理时间。

然后是业务逻辑层，次层主要为不同的业务部门提供数据分析、挖掘和建模功能。举例来说，其中包括数据预处理、统计分析、特征工程、机器学习等模块。

接着是核心算法层，主要是实现一些机器学习和深度学习模型的核心算法，其中包括针对表格型数据的轻度梯度提升机（LGBM）和多层感知机（MLP）等模型，针对序列数据的长短期记忆网络（LSTM）、时域卷积网络（TCN）、基于

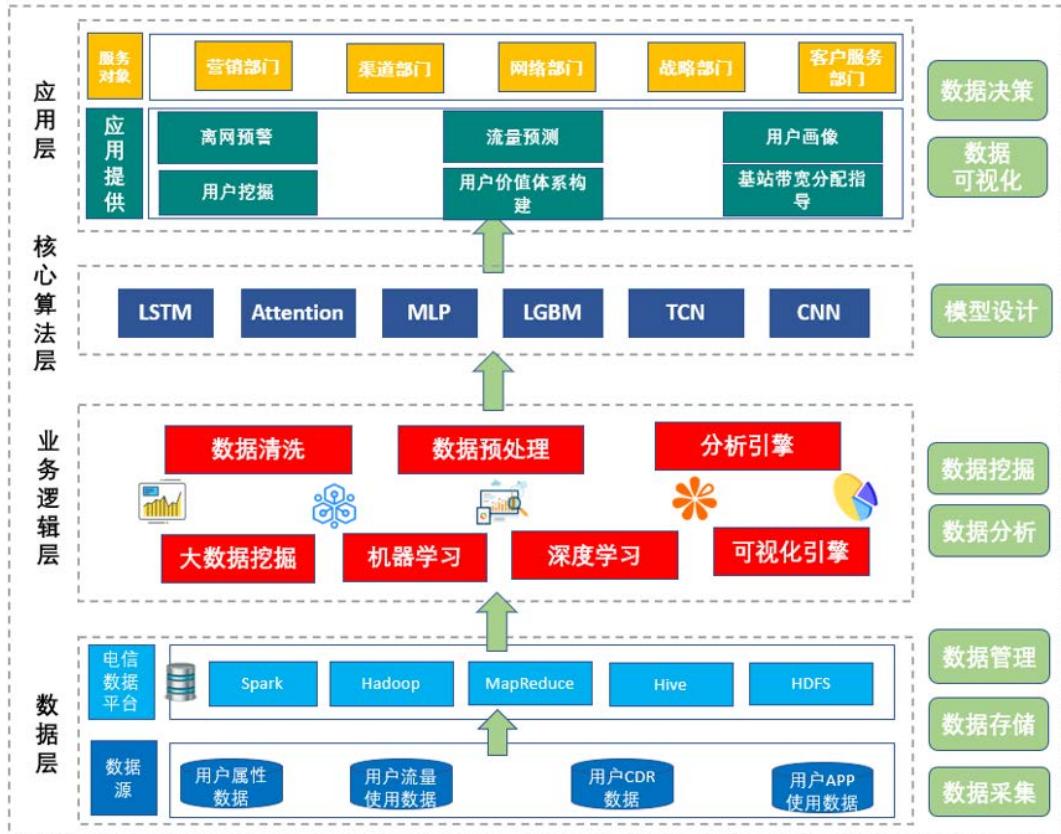


图 3-1 大数据平台系统架构

自注意力机制的深度神经网络（Transformer）等模型，针对图像的卷积神经网络（CNN）、自注意力视觉神经网络（ViT）等模型等。

最后是应用层，主要是提供经过开发人员开发和封装好的全流程自动的应用程序，为下游的营销部门、渠道部门等提供用户画像、离网预警等功能。

### 3.2 数据描述

首先，本文来描述一下用户侧数据，如图3-2所示。

**时间范围.** 本文拥有 2020 年 4 到 6 月，11 月到 12 月和 2021 年 1 到 2 月的 7 个月的数据。

**用户类型.** 本文过滤掉了政企用户、家庭用户和其他用户，只留下互联网卡个人用户。

**数据规模.** 在这 7 个月的数据中，一共有 400 万的互联网卡个人用户，400 万条以月为粒度的属性表记录，35 亿条以次为粒度的 CDR(通话细节记录) 表记录，400 亿条以次为粒度的流量表记录，4 亿条以月为粒度的 APP(应用程序) 表记录，1000 万条以次为粒度的停机表记录。其中属性表记录的为用户属性数据，而其他四个表记录的为用户行为数据，尤其是流量表和 CDR 表的数据尤为珍贵，

| CDR 表  |                        |                        |                        |   |                 |                  |             |
|--|------------------------|------------------------|------------------------|---|-----------------|------------------|-------------|
| 主叫号码<br>F7D97A                                     | 被叫号码<br>BDA794         | 开始时间<br>20200421123236 | 结束时间<br>20200421123305 | 时长<br>29  | 基站 ID<br>218090 | 城市 ID<br>11      | .....       |
| 流量表  |                        |                        |                        |   |                 |                  |             |
| 加密号码<br>F7D97A                                     | 开始时间<br>20200406041136 | 结束时间<br>20200406051136 | 下行流量<br>3700375        | 上行流量<br>1371049                                     | 时长<br>3600      | 基站 ID<br>218090  | .....       |
| 用户属性表  |                        |                        |                        |   |                 |                  |             |
| 加密号码<br>F7D97A                                     | 年龄<br>18               | 性别<br>male             | 余额<br>304.75           | 出账金额<br>19.00                                       | 套餐金额<br>19      | 城市 ID<br>11      | 流量<br>21.47 |
| 月份 ID<br>202004                                    | 在网时长<br>16             | 经度<br>112.59           | 纬度<br>28.19            | 单停次数<br>3   | 双停次数<br>1       | 套餐 ID<br>1186881 | .....       |
| APP 表  |                        |                        |                        |   |                 |                  |             |
| 加密号码<br>F7D97A                                     | 一级标签<br>社交软件           | 二级标签<br>通信             | 三级标签<br>微信             | 使用流量<br>323   | 使用次数<br>7812    | 天数<br>10         | .....       |
| 停机表  |                        |                        |                        |   |                 |                  |             |
| 加密号码<br>F7D97A                                     | 停机时间<br>2020.11.10     | 停机类型<br>单停             | 是否复机<br>否              | .....   | .....           | .....            | .....       |
| 2020.04 至 2021.02 的数据统计                            |                        |                        |                        |   |                 |                  |             |
| 互联网卡用户数量:400 万<br>CDR 记录条数: 35 亿<br>属性表记录条数: 400 万 |                        |                        |                        | 停机表记录条数:1000 万条<br>流量表记录条数: 400 亿<br>APP 表记录条数: 4 亿 |                 |                  |             |

图 3-2 用户侧数据描述

能够刻画用户的序列行为。但是从另一方面来说，如此海量的数据也给数据分析和模型训练推理带来了极大的硬件资源、方法性能、时间压力。

**具体字段.**

**数据用途.**

接着，本文来描述物品侧数据，如图3-3所示。

**时间范围.** 本文拥有 2020 年 11 月 12 月和 2021 年 1 2 月的 4 个月的数据。

**用户类型.** 本文也同样过滤掉了政企用户、家庭用户和其他用户，只留下互联网卡个人用户。

**数据规模.** 在这 4 个月的数据中，一共有 20 万的离网的互联网卡个人用户，20 万条以次为粒度的干预表记录，80 条以个为粒度的套餐信息表记录。其中干预表记录的为运营商人工客服对离网客户的干预数据，而套餐表记录的则为互联网卡套餐的相关数据。

**具体字段.**

表 2  
数据描述

| 干预表                     |                   |                         |                      |                   |                     |               |       |
|-------------------------|-------------------|-------------------------|----------------------|-------------------|---------------------|---------------|-------|
| 加密号码<br>F7D97A          | 营销结果<br>挽留失败      | 离网原因<br>套餐不合适           | 营销时间<br>201123 13:58 | 通话时长<br>136       | 联系电话<br>13826011809 | 城市<br>岳阳      | ..... |
| 套餐信息表                   |                   |                         |                      |                   |                     |               |       |
| 套餐名称<br>B 站权益卡          | 主套餐 ID<br>9013357 | 主套餐名称<br>20200406051136 | 套餐内容<br>19 元         | 可选包 ID<br>9015724 | 可选包名<br>流量优惠包       | 可选项<br>1GB 流量 | ..... |
| 2021.11 至 2021.02 的数据统计 |                   |                         |                      |                   |                     |               |       |
| 干预表记录条数: 5 万            | 互联网卡用户数量: 5 万     |                         |                      | 套餐信息表记录条数: 80     |                     |               |       |

图 3-3 物品侧数据描述

### 3.3 数据分析

在本章中，本文会首先针对互联网卡正常用户和离网用户做全面的数据分析，接着探索在哪些属性和行为数据上互联网卡离网用户和正常用户表现出较大差异，然后针对这些数据做相应的特征计算，提取用以区分互联网卡正常用户和离网用户的关键特征。

本文首先定义了互联网卡离网用户，然后分析了互联网卡的离网趋势以及互联网卡用户的离网原因分布。

**离网用户定义.** 离网用户也被称为流失用户，往往是用户在使用过程中因服务不满意、资费贵、改用其他竞品等原因而选择不再使用互联网卡。其中又分为两种，分别是主动性离网和被动性离网。其中主动性离网是指用户主动到运营商营业厅提出销卡的请求，还包括退还余额等行为。而被动性离网则指用户保持了至少两周 14 天的双停状态，没有通过充值话费等行为使得相应手机号复机。则运营商会主动将这类号码销户，之后再销售给其他用户。本文的研究主要是针对被动性离网，因为主动性离网行为只占互联网卡所有离网行为的不到 10%，尚且不受运营商们重视。

**互联网卡趋势.** 为了了解互联网卡这个业务的发展趋势，本文绘制了从 2020 年 4 月到 2021 年 2 月的发展趋势图，如图3-4所示。从图中，本文可以观察到互联网卡在初期增长得十分迅速，但是后期增长趋势放缓，从 2020 年 4 月到 2021 年 2 月一共增长了 50% 的用户，数量约为 100 万。究其背后的原因是因为尽管在一开始互联网卡新增用户占大多数，但是随着时间流逝，离网用户的数量

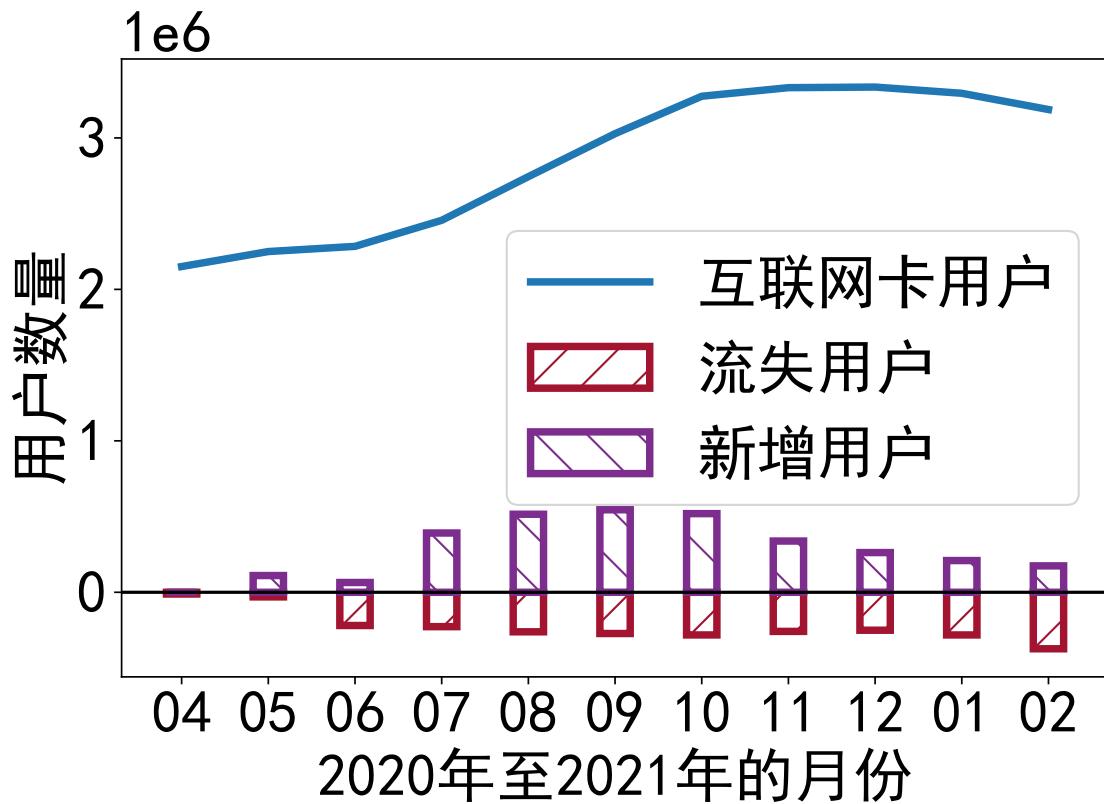


图 3-4 互联网卡发展趋势

迅速增长，甚至超过了月新增用户。这使得离网问题变得日益严重起来，对运营商维系互联网卡业务的稳定性提出了挑战。

**离网时间分析.** 为了进一步地理解互联网卡用户的离网行为，本文分析了互联网卡用户 7 个月的停机数据并分析了每个用户的离网时间。图3-4展示了 7 个月份内不同日期的离网用户数量，本文可以观察到在每个月的 9 号至 19 号拥有绝大多数的离网用户（超过了 95%）。本文还可以发现不同月份的离网用户数量和离网时间分布具有一定差异。举例来说，2021 年 1 月 14 日的离网用户数量可以达到 122029 个，然而其他月份只有更少的离网用户。此外，本文还观察到在每个月的月初和月末都基本没有互联网卡用户离网。这可能是与运营商的工作特点有关联，运营商的每个月初和月末常常需要做些清点工作。上述发现带给本文两个启示，首先，由于用户的离网行为在每月都有相同和不同之处，不是非常稳定，这带给整个系统的建模带来了一定挑战。其次，这也启示本文互联网卡用户偏好在月中离网，因此本文应当在上月末或者当月初就完成当月互联网卡的离网用户预测，才对运营商有实际意义。又因为互联网卡庞大的用户体量，运营商只能在每月初才能完成对所有数据的采集和基本处理工作，因此本文的工作最终也是在每月月初进行推理论和产出的。

**离网原因分析.** 为了理解为什么一部分互联网卡用户倾向于离网，本文

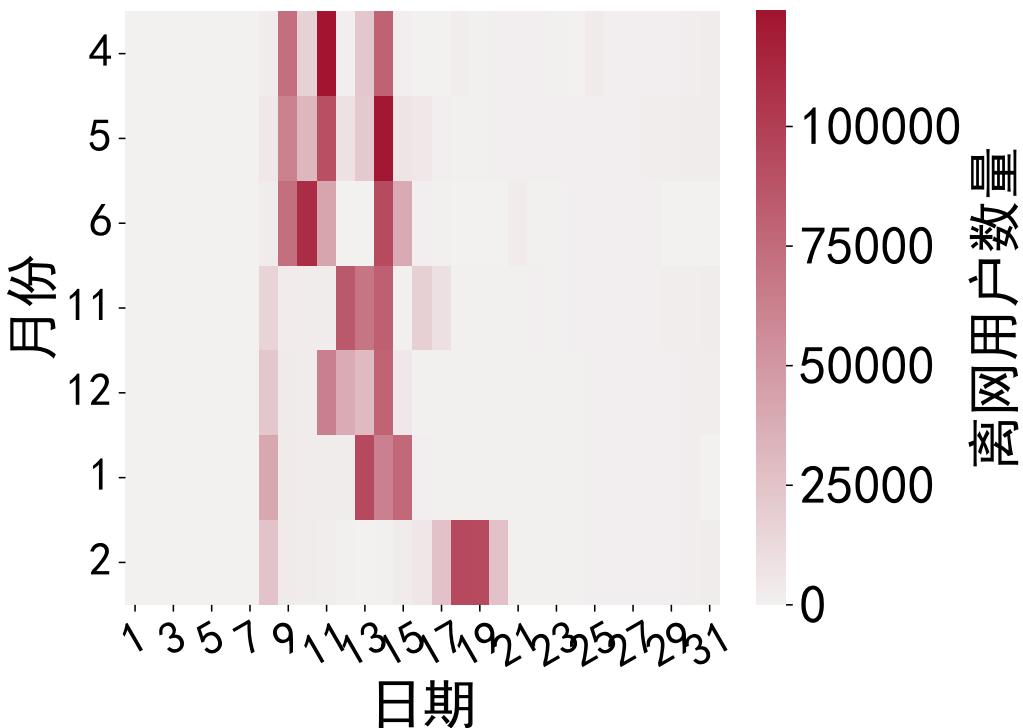


图 3-5 互联网卡离网用户-日期热力图

基于运营商客服收集的离网反馈分类了用户离网原因。图3-6展示了互联网卡用户离网的数量最大的前10个原因。本文可以看到互联网卡用户最多是因为“号卡太多”这个原因离网的。因为现在不同的运营商都在计划占据整个互联网卡市场。他们通过向新用户频繁宣传和给予大量折扣的优惠来吸引他们使用自家的互联网卡。因此，部分互联网卡用户可能会被其他运营商的优惠政策所吸引，从而离网转向使用他运营商的互联网卡。第二大离网原因是互联网卡用户不愿使用异地号。因为运营商的不同省份都是各自独立的，都会向全国各地兜售互联网卡。因此部分互联网卡用户使用的互联网卡的负责公司所出的省份与自己所处的省份并不同，在接听和拨打电话时常常会引起误会，而这个现象则会导致部分用户不想使用异地的互联网卡。并且由于异地的关系，手机信号和网络可能变得不稳定，从而影响用户的使用体验。此外，套餐不合适和无使用需求也占据了相当大的比例，这些是能被运营商优化的。从长期来说，互联网卡用户和原因的分布随着时间流逝和新用户的加入可能会变得不同。因此，本文只关注用户离网原因的类别。然后，本文可以为不同离网原因类别设计相应的干预策略从而挽留住那些已经离网或者将要离网的互联网卡用户。总的来说，用户离网原因分布的改变并不会影响系统的总体性能。

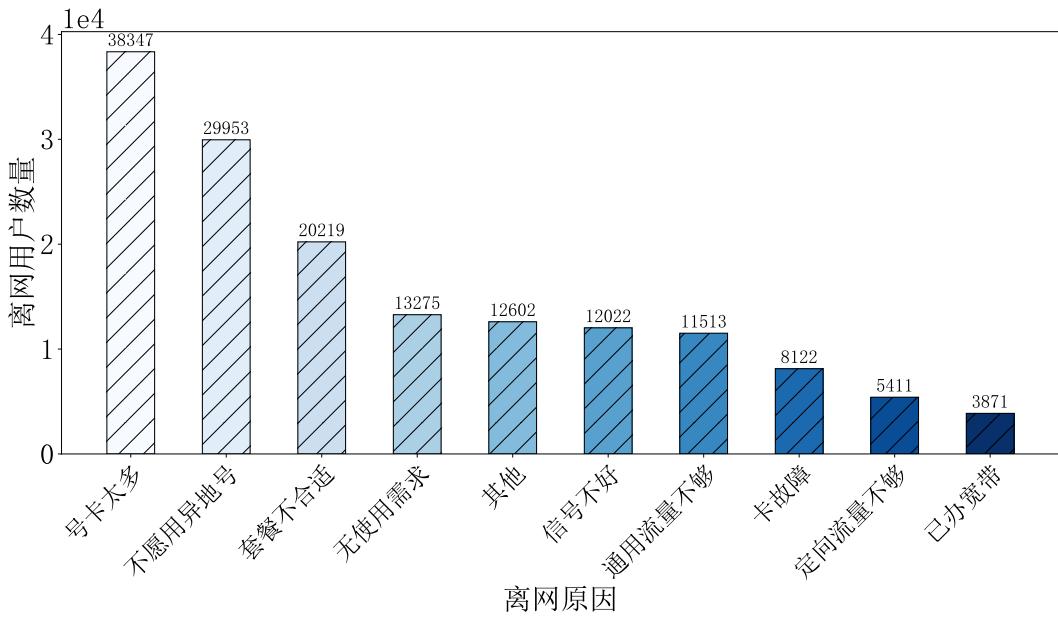


图 3-6 互联网卡用户 Top10 离网原因

因为运营商通过向互联网卡用户收取基本的套餐费用以及额外的服务费用来赚取利润的，所以互联网卡这个业务市场高度依赖于互联网卡用户的数量。因为用户离网问题对运营商来说至关重要，所以本文设计和实现的系统不得不理解互联网卡离网用户的潜在行为并且提前预测用户的离网行为从而发起早期的干预。因此，本文迫切需要了解互联网卡用户画像，在此基础上制定更有效的业务策略，防止他们离网，这也是本工作的动力之一。

### 3.4 特征工程

在本小节中，本文会展示基于数据分析的一些重要特征，主要分成两类，一类是静态画像特征，另一类是时间序列特征。

#### 3.4.1 静态特征工程

**账户余额.** 当互联网卡用户即将离网的时候，他们通常倾向于花光账户里的余额，因此账户余额越低，用户越容易离开运营商。图3-7展示了互联网卡正常用户和离网用户的累积分布函数（CDF）图，可以看出这两条曲线有着非常大的差距。详细来说，对于 80% 的用户来说，离网用户的账户余额都小于 40 元，而正常用户的账户余额都小于 75 元，这意味着账户余额在用户发生离网行为前是一条关键的线索。

**平均流量消耗阶段.** 对于即将离网的用户来说，他们的网络行为往往会发生变化。为了捕捉这个特征，本文把每个月份平均分成三个等长的阶段，分别

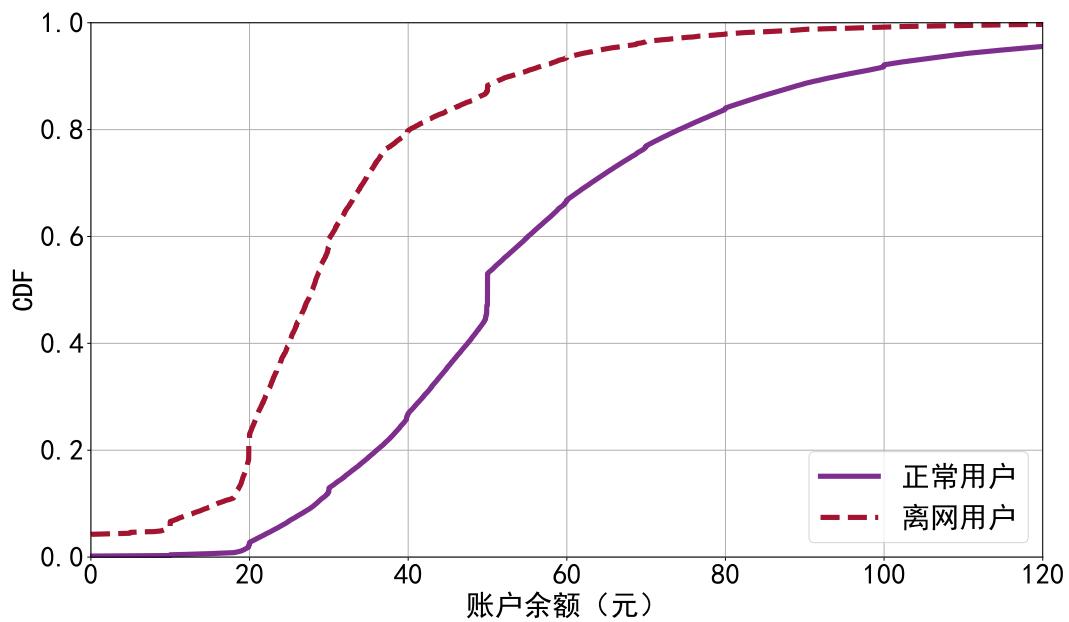


图 3-7 互联网卡用户账户余额对比

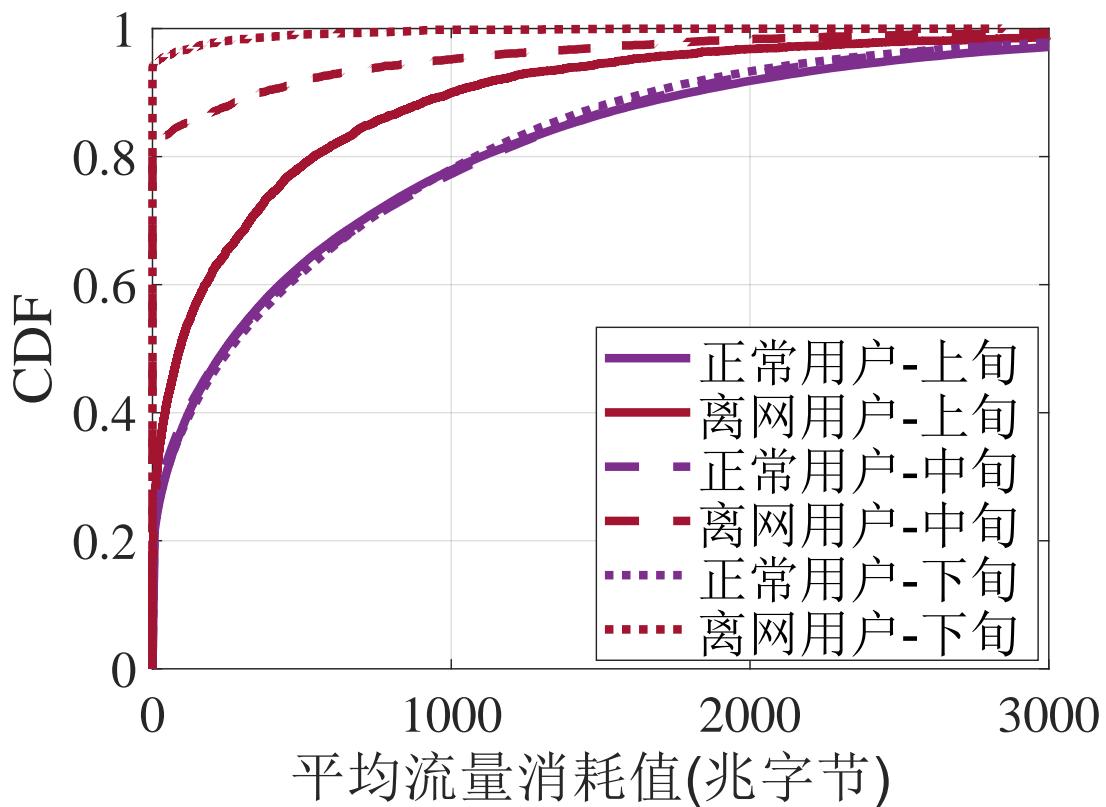


图 3-8 月不同阶段的互联网卡用户平均消耗流量值对比

是上旬，中旬和下旬。图3-8显示了正常用户和离网用户在月份不同阶段的流量消耗变化。从中可以观察到对于正常用户来说，平均流量消耗并没有什么区别。但是在离网用户的三个不同阶段，流量消耗曲线有很明显的差距。举个例子，在

上旬，中旬和下旬，平均消耗流量为 0 的用户在所有离网用户占比分别达到了 30%，80% 和 96%。

**APP 使用频次.** 为了捕捉互联网卡用户的 APP 使用习惯，本文基于采集的

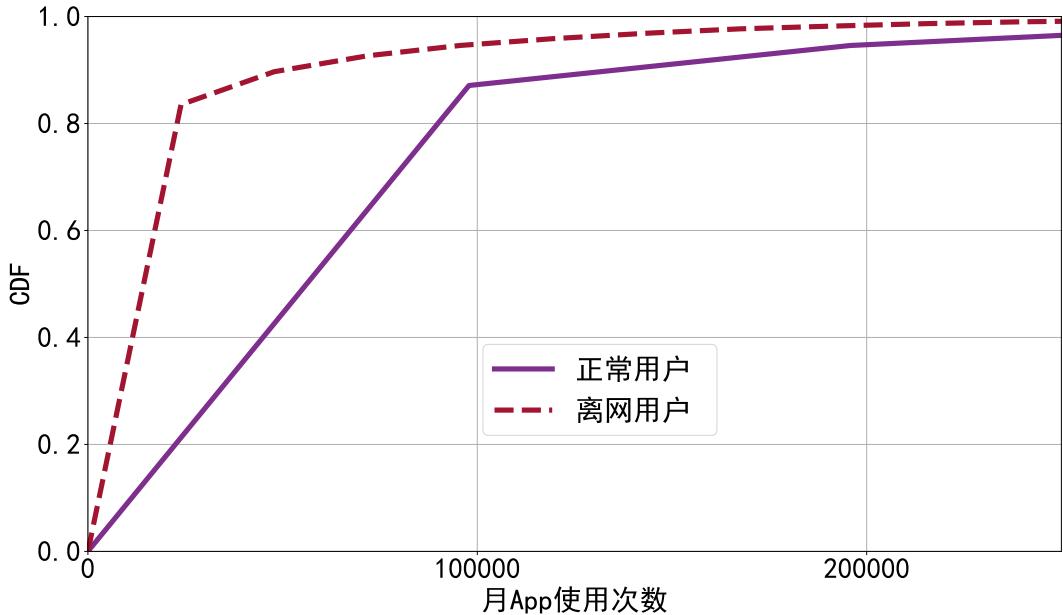


图 3-9 互联网卡用户月 APP 使用频次对比

APP 表计算了每个互联网卡用户在一个月内的所有 APP 使用频次。在图3-9中，本文描绘了正常用户和离网用户关于 APP 使用频次的对比 CDF 图，并且其中有非常大的不同。具体来说，正常用户的 APP 使用频次的中位数是 36075 次，而离网用户的对应中位则是 18442 次。这意味着 APP 使用频次对于互联网卡用户来说是一个非常有价值的特征用以区别正常用户和离网用户。

### 活跃熵.

和上述思路保持一致，本文基于香农信息熵探索了在一个月内日指标观察值（包括，使用流量大小，流量记录条数，上网时长等）的不确定性。对于某个互联网卡用户  $u$  来说，他关于上网时长序列的活跃熵  $H(D_u)$  可以被如下公式(3-1)计算。

$$H(D_u) = \sum_{k=0}^{\min(\max_{\text{bin}}, \text{len}(D_u))} p_k \log \frac{1}{p_k} \quad (3-1)$$

其中  $D_u$  是用户  $u$  的上网时长序列， $p_k$  表示上网时长序列中的数值落在第  $k$  个箱子的概率。此外， $\max_{\text{bin}}$  是分箱的数量， $\text{len}(D_u)$  是  $D_u$  的长度。如果上网时序的活跃熵比较大，这意味着上网时长序列中的数值在区间  $[\min(D), \max(D)]$  中更为分散和混乱。否则，如果上网时序列的活跃熵比较小，这意味着上网时长序列中的数值都集中在某个较小的确定区间内。在图3-10中，本文同时绘制了正

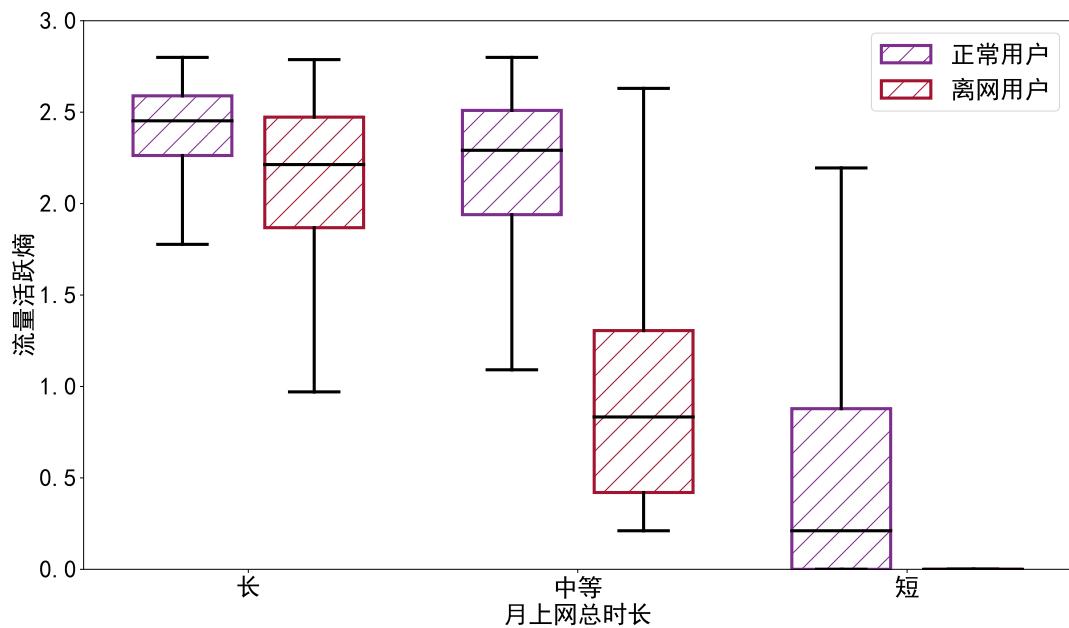


图 3-10 互联网卡用户流量活跃熵对比

常用户和离网用户关于日上网时长活跃熵的箱线图。并且用户们被分成了三组，分别是上网时长较长，上网时长中等和上网时长较短。本文可以观察到两种类型用户的不同行为模式，其中离网用户有着更小的熵值，这显示了他们有这更简单的网络行为模式，从而使得他们能够同正常用户区分开来。

**目标编码.** 为了构建目标编码，比如将分类特征替换为相应目标的后验概

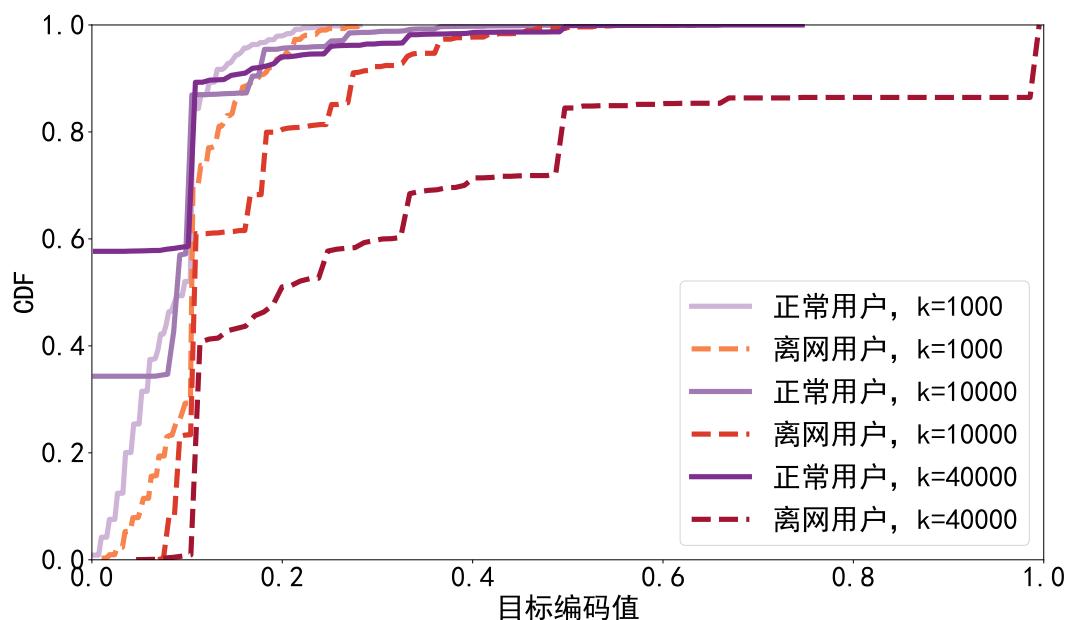


图 3-11 互联网卡用户目标编码值对比

率，本文首先根据用户的流量消耗值将互联网卡用户分组。特别地，本文将流量数据等宽地平均分到了  $k$  个箱子中，每个箱子的宽度 ( $w$ ) 等于

$$w = (\text{Max} - \text{Min})/k \quad (3-2)$$

其中 Max 和 Min 分别代表了用户在一个月内的总流量使用值的最小值和最大值，并且每个箱子的边界值分别是  $\{\text{Min} + w, \text{Min} + 2w, \dots, \text{Min} + (k - 1)w\}$ 。因此，针对流量分箱的目标编码值，比如以符号  $\vec{R}$  表示，可以被如下公式(3-3)计算

$$\vec{R} = \text{Concat}\left(\frac{\sum_{j=1}^{n_i} u_{ij} \cdot y_{ij}}{n_i}\right), i = 1, 2, \dots, k, \quad (3-3)$$

其中  $n_i$  表示在第  $i$  个箱子中的用户数量， $u_{ij}$  表示在第  $i$  个箱子中的第  $j$  个用户， $y_{ij} \in \{0, 1\}$  表示目标值，比如， $y_{ij} = 1$  表示这个用户是离网用户，否则，这个要用户就是正常用户、此外，*Concat* 函数用于拼接  $k$  个值到向量  $\vec{R}$  中。图3-11描绘了在分箱数量不同时正常用户和离网用户的目标编码值的 CDF 对比图。本文可以观察到，当  $k=1000$  时，离网用户和正常用户之间的差距还不是特别明显。但是，当分箱数量增加的时候，比如  $k=40000$  时，一个良好的性能差距浮现出来，这也意味着正常用户和离网用户被分发到不同的箱子后计算的目标编码值可以有效地区分两者。

值得注意的是，除了上述提到的重要特征，其他基础画像特征，比如年龄、性别、开卡日期和终端类型等也被提取和注入到模型当中了。

### 3.4.2 时序特征工程

除了静态特征，时序特征对于学习模型来说也是非常重要的因为离网行为通常是一个渐进进程而不是一个突发事件。

**流量序列.** 图3-12展示了在一个月内的互联网卡用户的日产生流量记录条数的箱线图。本文可以从中观察到正常用户每日通常比离网用户都产生了更多数量的流量记录条数。更加重要的是，对于正常用户来说，时序行为的差异十分小，但是对于离网用户来说他们的流量使用行为显得更不稳定。这也意味着这种时间相关性能被加以利用用来区别这两种类型的用户。需要指出的是，除了每日流量记录，其他日粒度特征还包括上行流量值，下行流量值，上网时长，通话次数等，也都被提取成时序特征并且喂给了后续的学习模型。

**流量异常天数.** 除了分析互联网卡用户的流量统计特征，本文还检测了互联网卡用户在一个月内的哪些日期出现了流量异常行为，因为异常值往往象征着此用户表现同以往不同的行为，很有可能会趋向离网。明确来说，基于用户

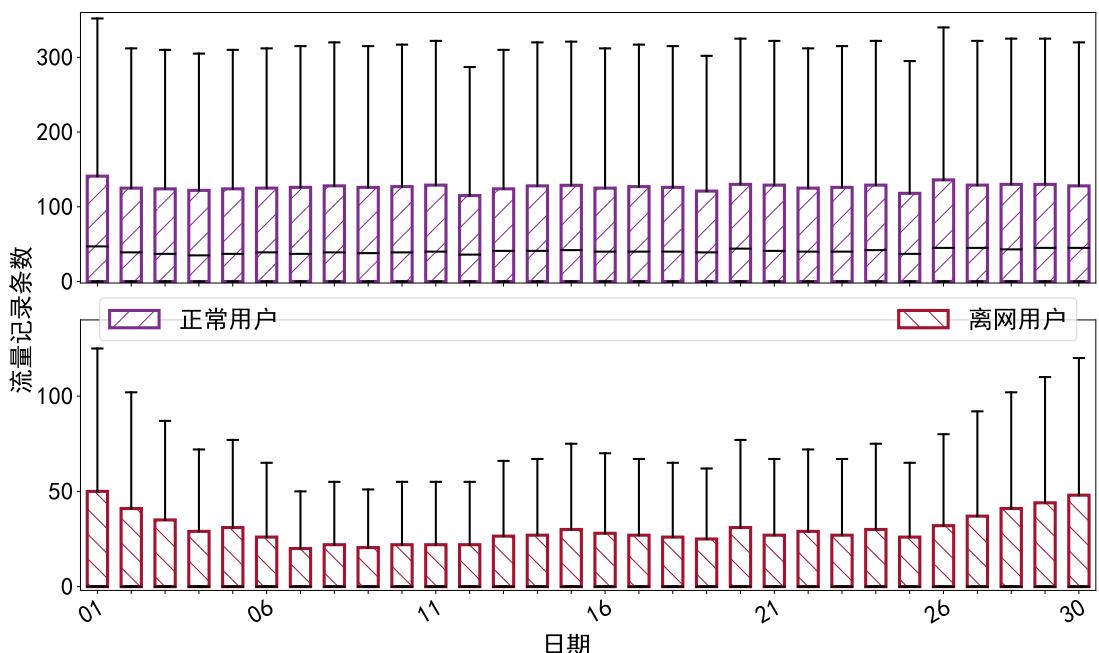


图 3-12 互联网卡用户流量记录条数序列对比

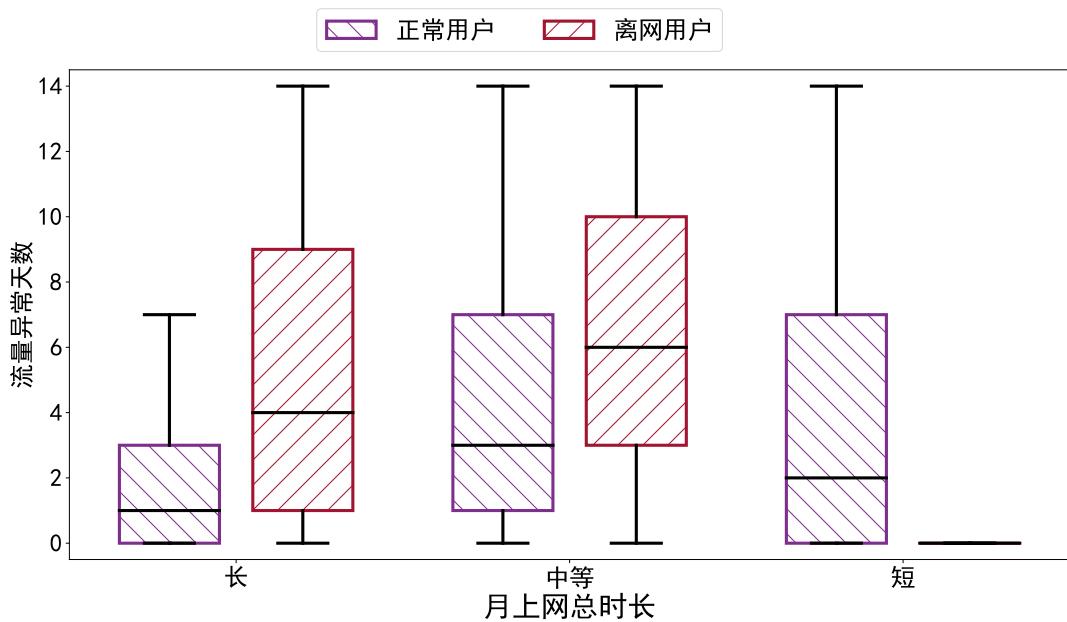


图 3-13 互联网卡用户流量异常天数对比

的日序列行为，本文对所有用户累加了使用特征值，包括上行流量值，下行流量值，上网时长和流量记录条数。因此，对每个序列特征来说，它都能被表征为  $X = [B_1, B_2, \dots, B_i, \dots, B_n]$ ，其中  $B_i$  表示这个月内第  $i$  天的统计特征。为了获得更平稳的序列特征，本文对上述得到的序列特征计算了它们的一阶前向差分形式，

用来  $X' = [F_1, F_2, \dots, F_i, \dots, F_{n-1}]$  表示，可以用以下公式(3-4)计算。

$$F_i = B_{i+1} - b_i \quad (3-4)$$

然后，本文定义了异常值  $E(X')$ ，可以通过使用四分位距 (IQR) 加上以下公式(3-5)来判定。

$$E(X') > Q_u + \gamma * IQR \quad | \quad E(X') < Q_l * IQR \quad (3-5)$$

其中  $IQR = Q_u - Q_l$ ,  $\gamma = 1.5$ 。 $Q_u$  是上四分位值，显示只有  $1/4$  的观察值比它大，然后  $Q_l$  是下四分位值，这就意味着只有  $1/4$  的观察值比它小。因此，每天的流量行为是否是异常值可以通过计算用户序列特征前向差分值的异常值来判断。在图3-13中，本文为正常用户和离网用户都描绘了月异常天数的箱线图。类似地，其中用户也被分成了三组，依据为在一个月内的总上网时长从高到低依次排序。具体来说，其中较高和中等的离网用户组明显拥有更多的异常天数，能够被利用来识别离网事件。但是对于使用较少的离网用户组来说，离网用户比正常用户有着更少的异常天数。这是合理的，因为他们有着稀疏的上网行为，这也导致了没有异常值产生。

### 3.5 问题建模与模型描述

为了预测潜在的互联网卡离网用户，本文设计了一个可学习的模型架构：互联网卡离网预测 Inter Card Churn Prediction(ICCP)，其中包括基于主成分分析算法的特征降维算法，基于自注意力机制的编码算法，轻量级的多层感知机和分类的多层感知机的，如图3-14所示。

**特征输入.** 本文基于采集的数据构建了特征工程来提取用户属性和行为特征。对于这两种类型的特征，本文定义符号  $\mathcal{P} \in \mathbb{R}^{1 \times M}$  来表示画像特征矩阵，其中  $M$  表示所有静态特征的数量，定义符号  $\mathcal{T} \in \mathbb{R}^{Q \times D}$  来表示时序特征矩阵，其中  $Q$  是所有日粒度特征的数量， $D$  是序列特征的长度。在为所有用户计算完这两类特征值后，它们将和离网标签一起被输入到可学习的模型来做监督学习。

### 3.6 基于自注意力机制的编码算法

为了捕捉潜在的时间关联性，矩阵  $\mathcal{T}$  和一个随机向量会首先被喂入到一个嵌入层 (Embedding layer)，它会输出一个固定维度大小的低维空间向量  $Q$ ，在

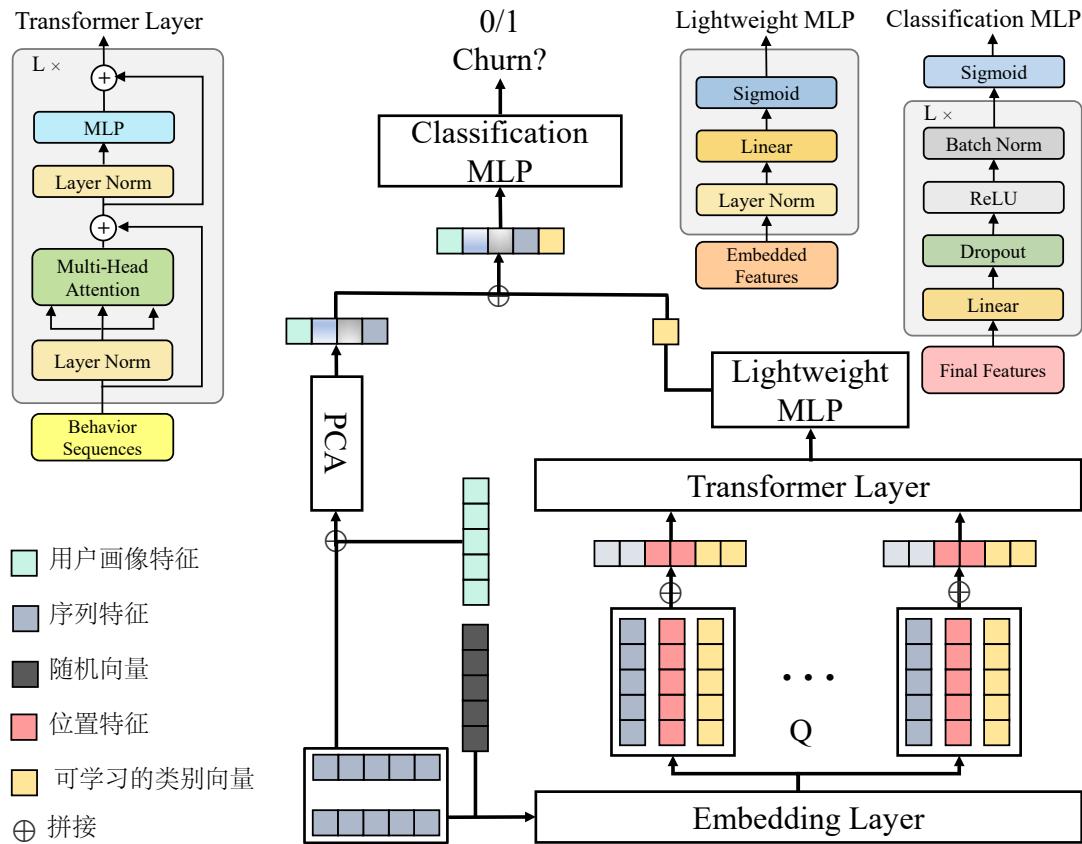


图 3-14 互联网卡用户离网预测模型架构

图3-14可以看出，这个向量  $Q$  包含序列，位置和类别信息，并用不同的颜色标注了出来。然后这个向量  $Q$  被输入到了变形层（Transformer Layer），其中包括  $L$  个块，每个块中包含层归一化（LN），多头自注意力（MSA）和多层次感知机（MLP），这相对应的函数可以被如下公式计算。

$$z_0 = [s_{class}; \mathcal{T}^1; \mathcal{T}^2; \dots; \mathcal{T}^{|D|}; \mathcal{T}_{pos}^1; \mathcal{T}_{pos}^2; \dots; \mathcal{T}_{pos}^D], \quad (3-6-a)$$

$$z_l' = MSA(LN(z_{l-1})) + l - 1, l = 1 \dots L \quad (3-6-b)$$

$$z_l = MLP(LN(z_l')) + z_l', \quad (3-6-c)$$

$$y = LN(z_L^0), \quad (3-6-d)$$

其中  $z_0$  是嵌入层的输出， $\mathcal{T}^i$  表示第  $i$  个时序特征的信息，而  $\mathcal{T}_{pos}^i$  表示  $\mathcal{T}^i$  的位置嵌入信息。嵌入层和变形层的具体工作流程可见算法3-1。在这之后，变形层的输出将被输入到轻量级的多层次感知机（Lightweight MLP），其中包括层归一化，全连接层和 Sigmoid 层。然后轻量级的多层次感知机将会输出一个离网概率值，后者将被视作为一个新特征注入到之后的分类多层次感知机中。

**算法 3-1 针对多重序列特征的嵌入变换算法**

**Input:** 时序特征  $T^{(N*L)}$ , 嵌入向量数量  $Q$ , 块长度  $V$ , 块宽度  $W$ , 嵌入向量大小  $D$ , 变换块数量  $L'$

**Output:** 用户时序特征的编码向量  $E^{(Q*D)}$

- 1: 把时序特征  $T^{(N*L)}$  变形成块  $B^{Q*(V*W)}$
- 2: 训练一个全连接神经网络来编码块  $B^{Q*(V*W)}$  到块  $B^{Q*D}$
- 3: 随机初始化一个可学习的服从高斯分布的向量  $X^D$
- 4: 随机初始化一个可训练的服从高斯分布的位置嵌入矩阵  $M^{(Q+1)*D}$
- 5: 拼接块  $B^{Q*D}$ , 向量  $X^D$ , 矩阵  $M^{(Q+1)*D}$  成  $Z_0$
- 6: 初始化  $Q_i = W_i^Q * Z_0, K_i = W_i^K * Z_0, V_i = W_i^V * Z_0, i = 1, \dots, 3$
- 7: 计算  $Head_i = softmax(\frac{Q_i * K_i^T}{\sqrt{d_{k_i}}})V_i, i = 1, \dots, 3$
- 8: 计算  $MSA(Z_0) = Concatenate(Head_1, \dots, Head_3) * W^O$
- 9: 计算  $Z'_l = MSA(LN(Z_{l-1})) + Z_{l-1}, l = 1 \dots L'$
- 10: 计算  $Z_l = MLP(LN(Z'_{l-1})) + Z'_{l-1}, l = 1 \dots L'$
- 11: 计算  $E^{(Q*D)} = LN(Z_{L'}^0)$
- 12: 返回  $E^{(Q*D)}$

### 3.7 基于主成分分析算法的特征降维算法

为了捕捉用户的画像信息, 本文首先将用户画像特征和时序特征拼接成一个一维向量, 比如说,  $V_i = \{x_1, x_2, \dots, x_{M+Q \times D}\}$ 。然后这个向量将被输入到主成分分析算法这个组件。它会输出一个压缩向量  $W_i^* = \{w_1, w_2, \dots, w_{d'}\}$ , 其中  $w_{d'}$  是新维度的大小。接着这个新向量和轻量级多层感知机的输出会被拼接, 然后输入到最终的分类多层感知机中。需要特别指出的是, 针对画像特征和时序特征的主成分分析算法能够在保持大多数特征成分的同时, 比如最大限度地保留原始信息, 这也能够减少用于分类的特征的复杂度, 加速模型训练和收敛。具体的工作流可见算法3-2。

### 3.8 基于多层次感知机的分类器设计

**模型训练.** 为了分类一个互联网卡用户是否是离网用户, 本文将其建模成一个二分类的问题。本文通过使用分类多层次感知机, 其中包括  $L$  个块, 每个块包含小批量归一化 (Batch Norm), ReLU, Dropout 和全连接层。为了训练这个模型, 本文采用交叉熵作为损失函数, 可以被以下公式(3-7)所计算。

$$\mathcal{L} = \frac{1}{N} \sum_i -[y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i)] \quad (3-7)$$

其中  $p_i$  表示用户  $i$  离网概率值, 而  $y_i \in \{0, 1\}$  是表示用户是否离网的标签, 具体来说,  $y_i = 1$  代表此用户是一个离网用户, 否则,  $y_i = 0$  此用户是一个正常用户。 $N$  表示所有训练样本的数量。

---

算法 3-2 针对画像特征和时序特征的主成分分析

---

**Input:** 用户画像特征  $P$ , 时序特征  $T$ , 信息阈值  $I$   
**Output:** 被信息阈值截断的关于用户特征的主成分  $P_c$

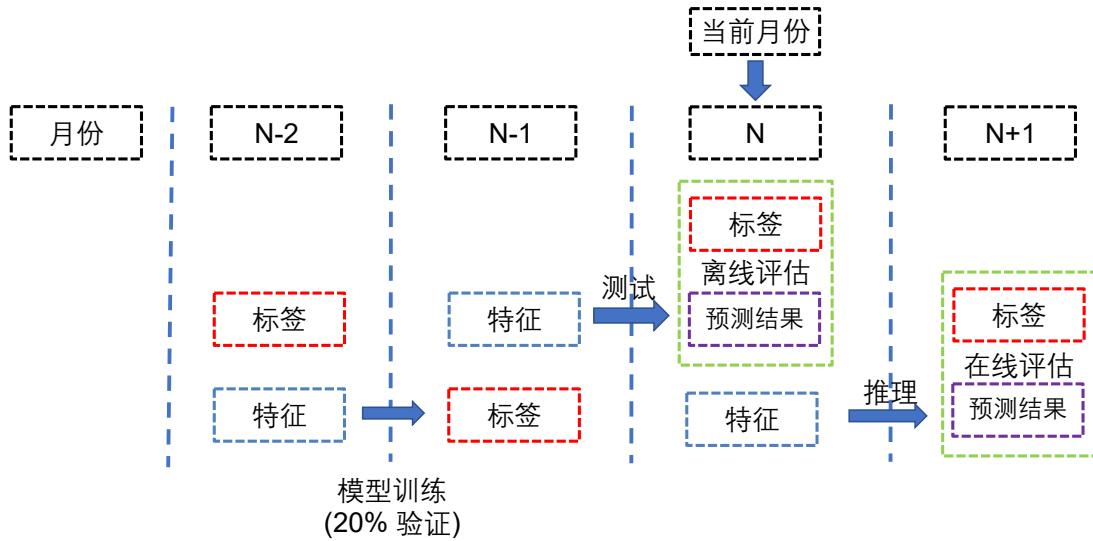
- 1: 初始化时序矩阵  $t$  为空
- 2: 初始化信息权重  $w$  为 0 和主成分数量  $n$  为 0
- 3: **for**  $i \leftarrow 1 \cdots Q$  **do**
- 4:    $t \leftarrow$  拼接  $t$  和  $T$  的第  $i_{th}$  个时序特征
- 5: **end for**
- 6:  $P \leftarrow$  拼接  $t$  和  $P$
- 7: 并行对所有特征去中心化  $P_i = P_i - \frac{1}{M+Q*D} \sum_{j=1}^{M+Q*D} P_j$
- 8: 计算特征的协方差矩阵  $C = \frac{1}{M+Q*D} P P^T$
- 9: 计算特征值  $\lambda$  和协方差矩阵  $C$  对应的特征向量  $\vec{v}$
- 10: 根据  $\lambda$  降序排列  $\vec{v}$  来得到矩阵  $C'$
- 11: **repeat**
- 12:    $w = \frac{\sum_{i=1}^n \lambda_i}{\sum_{i=1}^{M+Q*D} \lambda_i}$
- 13:    $n \leftarrow n + 1$
- 14: **until**  $w < I$
- 15: 选择  $C'$  的前  $n$  行来得到变换矩阵  $A$
- 16:  $P_c = AP$
- 17: 返回  $P_c$

---

## 3.9 本章小结

## 第4章 关于离网预测模块的实验评估与结果分析

### 4.1 实验设置



为了评估 ICCP 的性能，本文首先使用了某个运营商的互联网卡用户离网信息来标记离网用户，比如，如果一个互联网卡用户双停超过两个礼拜并且没有复机行为，那该用户就会被标记为离网用户。图3-2展示了在不同月份基于滑动窗口的训练和预测实验设置。需要特别指出的是，假设当前月份是  $N$  月，本文首先会使用  $N - 1$  月的用户离网信息来标记拥有  $N - 2$  月特征的用户，然后用相同的方法使用  $N$  月的用户离网信息来标记拥有  $N - 1$  月特征的用户。然后，我们使用拥有  $N - 2$  月特征的用户和  $N - 1$  月的标签来训练 ICCP，其中 20% 的数据样本用于验证。接着，本文使用拥有  $N - 1$  月特征的用户和  $N$  月的标签来测试 ICCP 的离线性能。最后，依赖于上述机制，本文把  $N$  月无标签的用户特征数据输入到 ICCP 中，就可以得到下一个月的互联网卡离网用户名单，并且可以在下月评估 ICCP 的在线真实性能。综上所述，本文利用滑动窗口机制，通过将窗口从上个月移动到当前月实现用户的特征捕捉，然后使用 ICCP 模型来预测下月的潜在离网用户。

对于特征工程和性能评估，本文使用了横跨五个月采集的数据，分别是 2020 年的 5 月、6 月，11 月、12 月和 2021 年的 1 月。其中 2020 年的 6 月、12 月和 2021 年的 1 月的数据分别用来标注 2020 年 5 月、11 月和 12 月互联网卡用户（是离网用户还是正常用户）。然后，本文使用相应的数据样本来进行离网预测模型的训练和测试。由于系统资源的限制，本文随机挑选了 50 万的互联网卡用户作为一

个月的数据样本，其中在 2020 年 5 月有 493251 个正常用户和 6749 个离网用户。此外，对于 2020 年 11 月和 12 月的互联网卡用户而言，则有 871049 个正常用户和 73289 个离网用户。因此，本文在 2020 年 5 月、6 月、11 月和 12 月的 500000 个数据样本上构建了实验，其中 80% 的样本用于训练，剩下 20% 的样本用于测试。

#### 4.1.1 基准模型

为了显示本文提出的 ICCP 模型的优越性，本文设计和实现了一下可以比较的分类基准模型，包括机器学习和深度学习模型。值得注意的是，虽然这些算法在科研文献中被广泛采纳用来解决分类问题，在其中却没有解决互联网卡离网分类和预测的。另外，为了保证比较的公平性，所有的基准模型的特征输入都与 ICCP 保持一致。

- **随机森林 (RF)**：是一种被广泛采纳用来分类问题的基于决策树的传统机器学习算法。
- **轻量梯度提升机 (LGBM)**：是一种基于决策树算法的分布式梯度提升机器学习框架。这种机器学习提供了高效率并行训练，低内存消耗，更高准确率和大量数据的快速处理。
- **长短期记忆网络 (LSTM)**：是深度学习领域内的一种循环神经网络架构 (RNN)。它能很好地捕捉序列数据中的短期时间相关性。
- **多层感知机 (MLP)**：是人工神经网络中的一种基础模型。它利用反向传播机制来进行模型训练。多层感知机架构是由包含全连接层，批量归一化 (BN) 层，ReLU 层，Dropout 层的块堆积而成的。
- **残差前馈神经网络 (ResMLP)**：是一种基于残差连接的神经网络架构。其中包括一个隐层前馈神经网络和一个线性的残差连接。和多层感知机相比，残差前馈神经网络是一种拥有三个块层的更简单的残差网络架构。在本文离网预测场景当中，我们在每三个块层中添加了一个残差连接用来解决反向传播过程当中的梯度消失问题。

#### 4.1.2 评估指标

对于离网预测问题来说，基于以下这四个基础测试结果，分别是真阳性样本 (TP)，假阳性样本 (FP)，真阴性样本 (TN)，假阴性样本 (FN)，我们采用了一下 5 个评价指标来评估相应性能。

- **精准率 (Precision)**：指的是一个被预测为离网的用户被正确预测的概率，具体公式为， $\frac{TP}{TP+FP}$ 。

- **召回率 (Recall)**: 指的是在真实标签中所有离网用户被正确预测的概率，具体公式为， $\frac{TP}{TP+FN}$ 。
- **F1 分数 (F1-Score)**: 被定义为精准率和召回率的调和平均数，具体公式为， $2 \times \frac{Precision \times Recall}{Precision + Recall}$ 。
- **接收者操作特征曲线下面积 (AUC)**: 被定义为随机挑选一个正样本和负样本，正样本能排在负样本之前的概率。该评价指标用来判断模型是否擅长分类。具体公式为， $\frac{\sum_{i \in positiveClass} rank_i - \frac{M(M+1)}{2}}{M \times N}$ ，其中 M 和 N 分别表示正样本和负样本的数量。
- **精准率-召回率曲线下面积 (PR-AUC)**: 被定义在同一张图中根据不同阈值同时画出的精准率-召回率曲线下的面积。这项评价指标等同于根据不同阈值计算的召回率和精准率的平均乘积累加和。具体公式为， $\sum_{k=1}^N P(k) \Delta R(k)$ 。

## 4.2 用户离网预测模型性能评估

### 4.2.1 系统总体性能

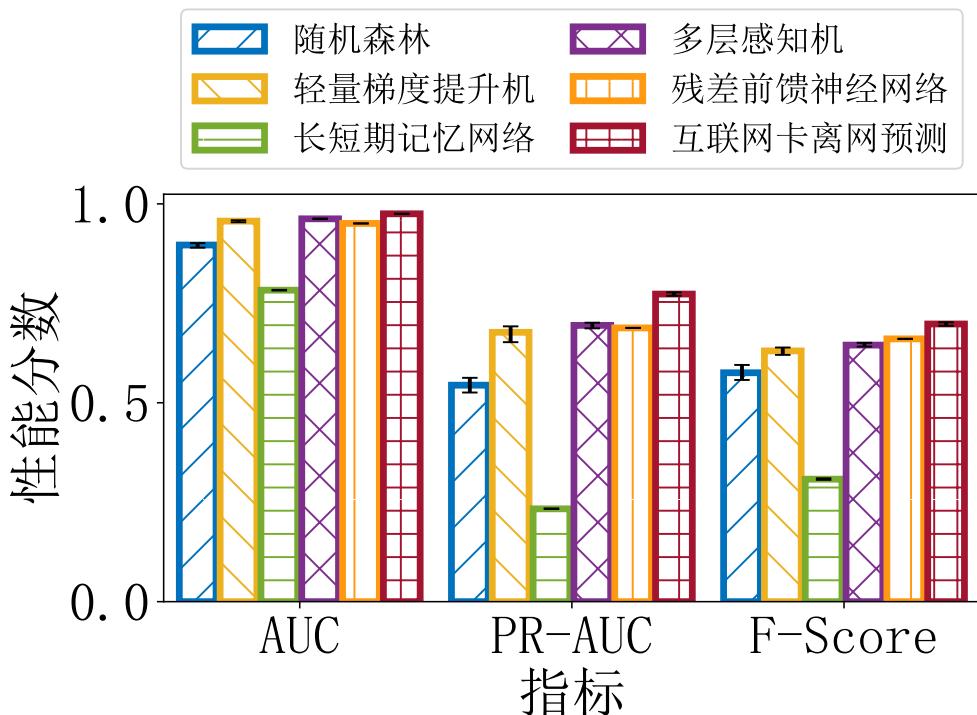


图 4-2 离网预测性能对比

本文首先通过与基线模型的对比来检验本文提出的模型 ICCP 的系统总体性能。在把所有数据平均分成 5 组（比如，k 折交叉验证中方法 k=5）来计算性能的

平均值和上下界，图4-2展示了不同分类模型的性能表现。本文可以做出以下推断：首先就 AUC, PR-AUC 和 F1 分数而言，本文提出的 ICCP 模型可以显著超越基线模型。具体来说，随机森林，轻量梯度提升机，长短期记忆网络，多层感知机和残差前馈神经网络的平均 PR-AUC 分数分别为 0.54, 0.67, 0.23, 0.69 和 0.68，在另一方面，ICCP 的平均 PR-AUC 分数为 0.77。其次，与其他基准预测模型相对比而言，长短期记忆网络表现出了最差的性能，这是因为长短期记忆网络只能捕捉时序特征而忽略了静态画像特征。第三，通过比较随机森林、轻量梯度提升机和长短期记忆网络、多层感知机和残差前馈神经网络，本文可以发现深度学习模型展示了提高互联网卡用户离网预测准确率的潜力。这里面的主要原因为深度学习模型可以通过利用多维度特征学习隐含信息表示。需要指出的是，本文也测试了其他机器学习模型，包括决策树，支持向量机和梯度提升树等，最终本文选取了表现性能最好的随机森林和轻量梯度提升机作为机器学习模型的代表。

#### 4.2.2 Top-U 用户的性能.

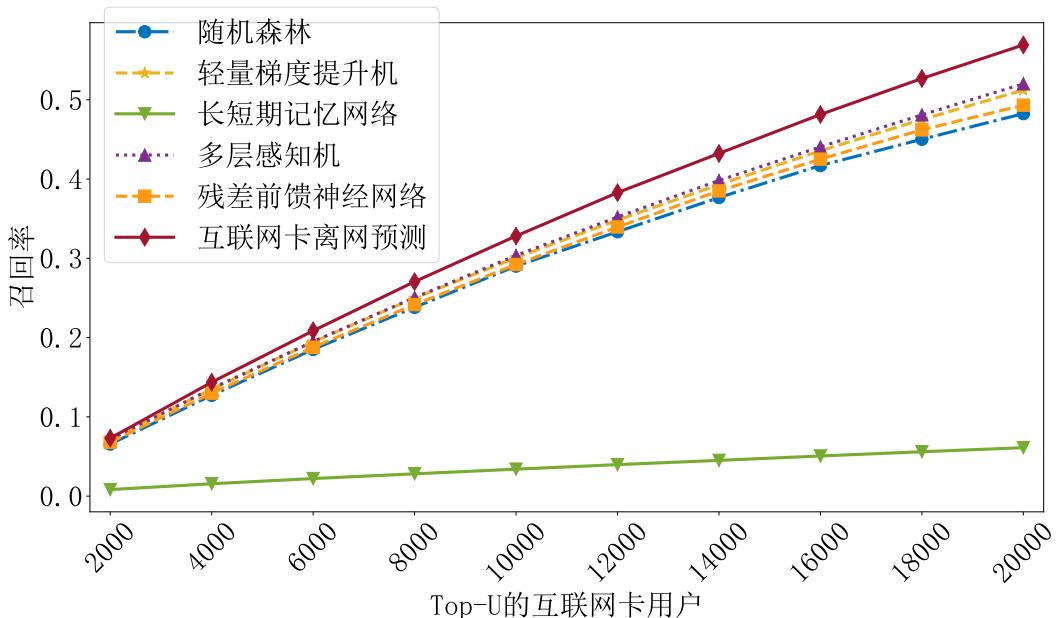


图 4-3 Top-U 用户的召回率对比

为了进一步评估离网预测模型的性能，我们测试了 Top-U 个互联网卡用户的模型表现。需要特别指出的是，整个预测系统将会产生 Top-U 个互联网卡用户的名单，其中是最有可能在下个月离网的用户，接着我们评估了他们的预测性能。这个 Top-U 用户性能的评价指标可以作为运营商做决策的重要参考。图4-4, 图4-3和图4-5分别展示了 Top-U 用户的精准率 (Precision@U)、召回率 (Recall@U) 和 F1 分数 (F1-Score@U)。其中用户范围是从前 2000 个一直到前 20000 个。本

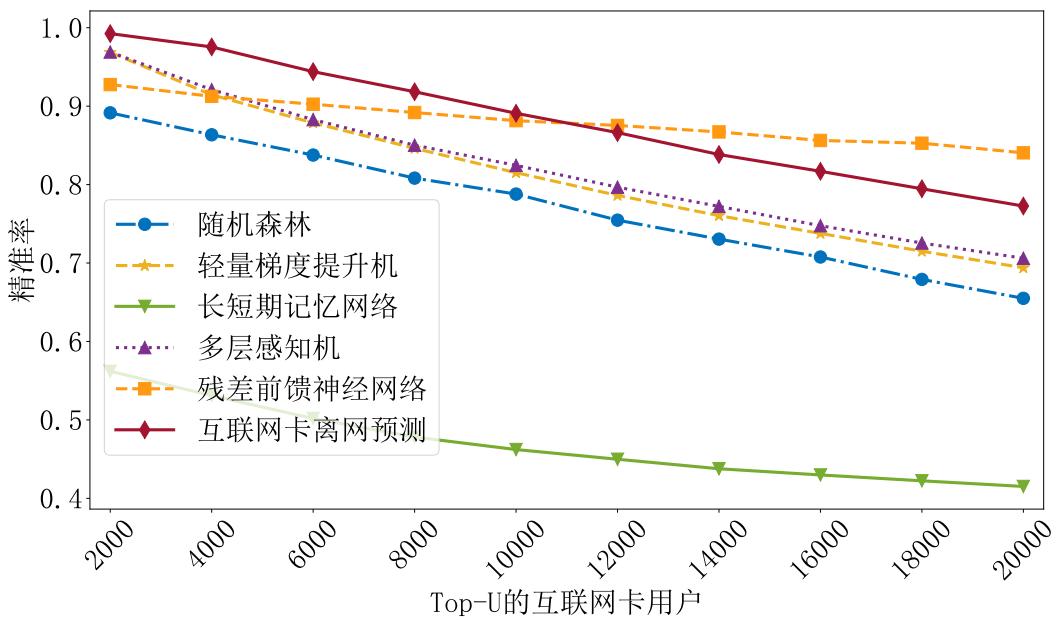


图 4-4 Top-U 用户的精准率对比

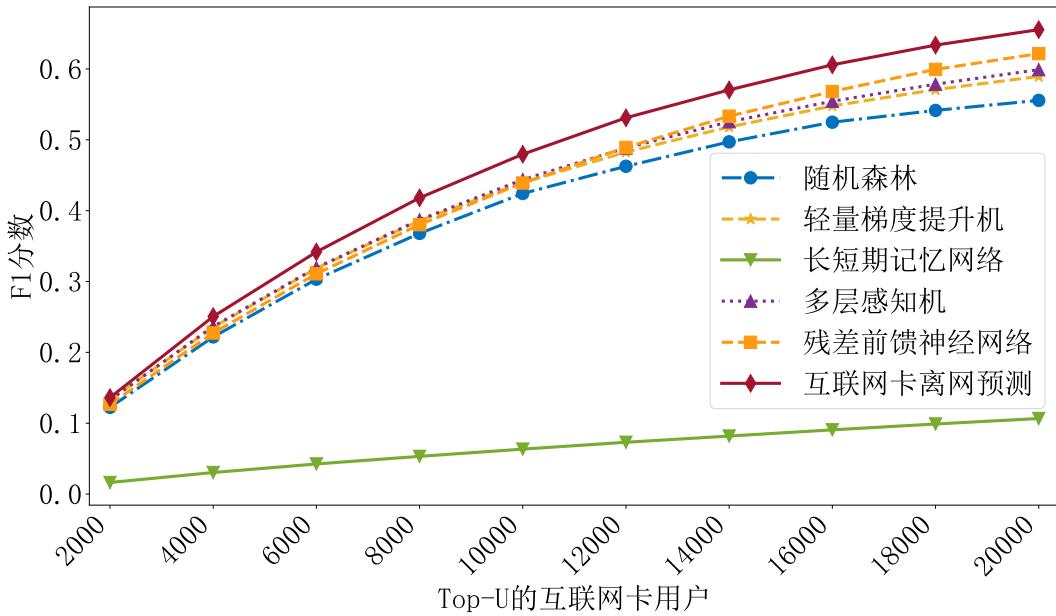


图 4-5 Top-U 用户的 F1 分数对比

文做出了以下的主要观察。

首先，在 Top-U 用户的设置下，我们提出的 ICCP 模型能在 Recall@U 和 F1-Score@U 这两项指标上明显超过其他基准模型。举例来说，ICCP 的 Precision@20000, Rcall@20000, F1-Score@20000 分数为 {0.77, 0.60, 0.65}，与此同时残差前馈神经网络，多层感知机，轻量梯度提升机，长短期记忆网络和随机森林的对应分数分别为 {0.84, 0.49, 0.62}, {0.70, 0.52, 0.53}, {0.69, 0.51, 0.59}, {0.65, 0.48, 0.55}

和 {0.41, 0.06, 0.11}。第二，对于 Precision@U 和 Recall@U 这两个评价指标而言，随着用户 U 数量的增加，精准率是逐渐下降的，与此同时，召回率却是逐渐上升的。这是合理的，因为在用户 U 很少的情况下，这些被识别出来的预离网用户往往拥有更高的可能性离网运营商，这导致了精确率较高，但在另一方面，由于用户基数较少，也导致召回率较低。第三，随着用户 U 的增加，Precision@U 的下降趋势和 Recall@U 的增长逐渐放缓的趋势共同说明了随着用户 U 的增加，从中识别出离网用户变得越来越困难。此外，当 Top 用户数量大于 12000 时，残差前馈神经网络的精确率要高于其他方法是因为被添加到残差前馈神经网络中的残差连接结构。这个结构大大改善了在反向传播中的梯度消失问题，同时也使得残差前馈神经网络在预测 Top-U 用户时更加平衡，下降趋势也更加平缓。但是，本文提出的 ICCP 模型在 F1 分数这个综合指标上能超过残差前馈神经网络这个基线模型，是因为后者在召回率分数上增长缓慢。

### 4.3 参数影响

在保证了预测性能后，我们进一步探讨了用户性别、年龄、App 使用情况、套餐选择等用户属性参数对预测性能的影响。

#### 4.3.1 性别参数的影响

我们将用户样本分为男性和女性两个子集，采用  $k = 5$  的 k 折交叉验证方法分别评估模型性能。图4-6绘制了平均性能度量分数，其中男性和女性用户都有

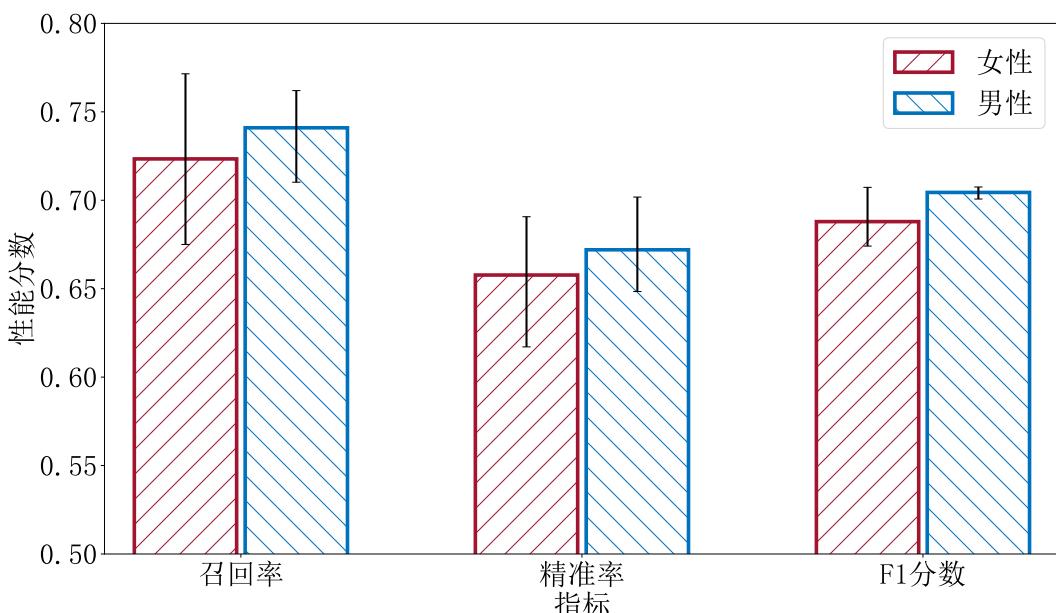


图 4-6 性别参数的影响

错误条用来，显示模型性能的上下界。本文可以得到以下结论：ICCP 对男性和女性均是有效的，他们的指标得分非常相似，并且与系统的整体性能相当。如，对于召回率、精准率和 F1 分数的指标，女性用户可以分别获得 0.72、0.66 和 0.69 的平均分，而男性用户可以分别获得 0.74、0.67 和 0.71 的平均分。另一方面，我们可以发现男性的指标得分略大于女性用户，这与男性用户比女性用户有更多的流量消耗行为是一致的。可以解释为，流量消费行为较多的男性用户离开运营商，更有利于学习模型捕捉潜在的离网行为线索。

#### 4.3.2 年龄参数的影响

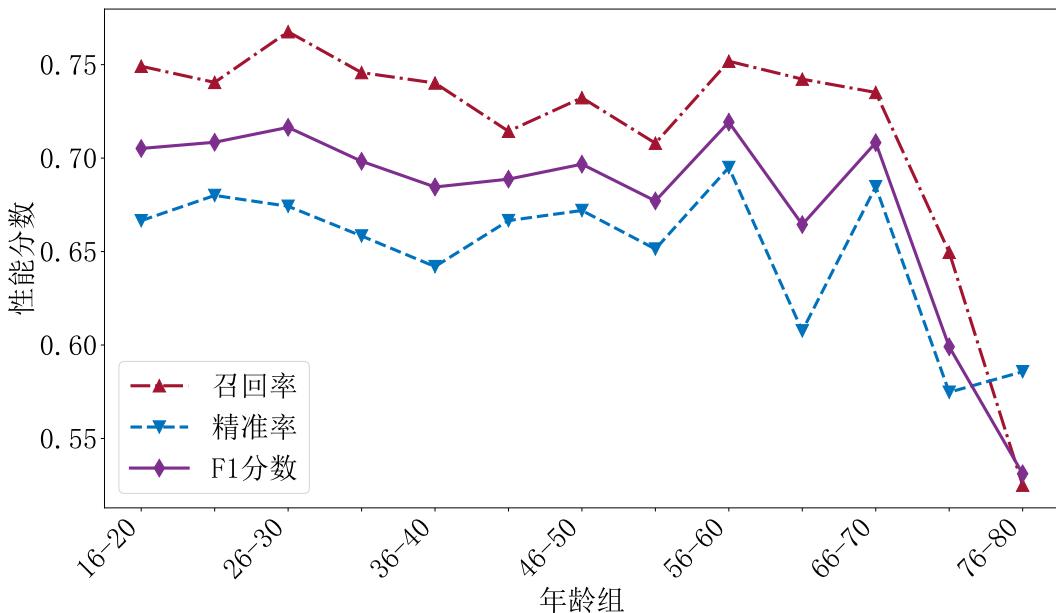


图 4-7 年龄参数的影响

为了研究用户年龄的影响，我们将 IC 用户分为 13 个年龄组，年龄从 16 岁到 80 岁，每个年龄组的范围为 5。图4-7显示了 ICCP 在不同年龄组中获得的召回率、精准率和 F1 分数的平均指标得分。虽然 16 岁至 60 岁用户的分数略有变化，但几乎所有的分数都在 70% 以上，这意味着 ICCP 可以在所有用户上稳健运行，而不受用户年龄影响流量消耗。另外，对于 16 岁至 35 岁的用户，他们可以获得最高的精度分数，这是因为年轻用户在互联网服务中更活跃，他们在离开系统前的异常行为更容易被识别出来。另一方面，对于 61 岁至 80 岁的用户，我们可以看到指标得分有严重的抖动，这是因为老年用户在互联网服务中不太活跃，很难捕捉他们的网络使用行为。

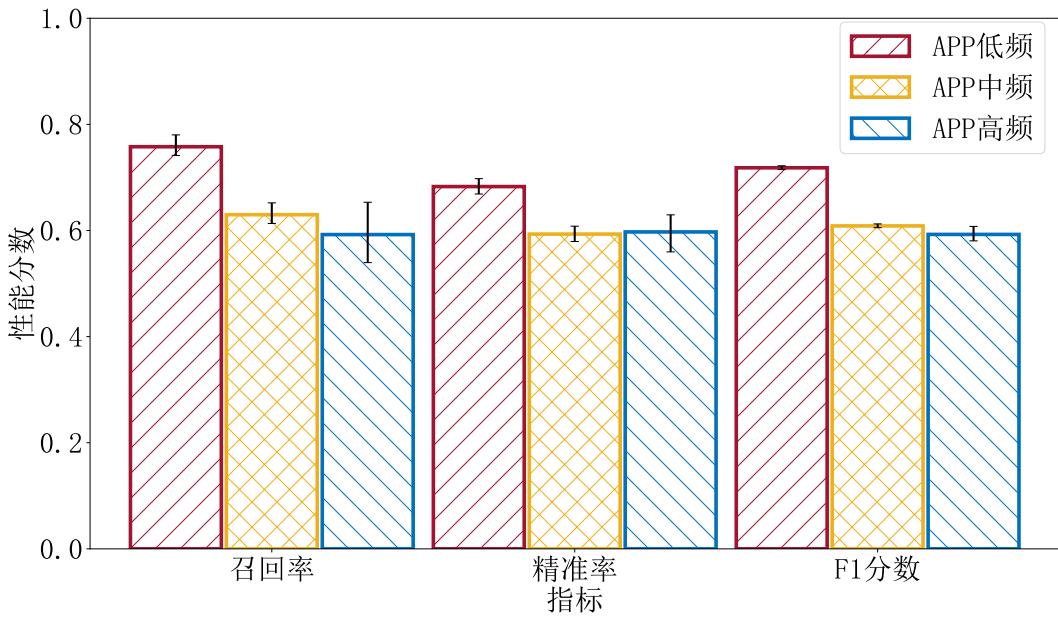


图 4-8 APP 参数的影响

### 4.3.3 APP 参数的影响

我们通过对用户应用程序使用频率的排序，将用户样本分为三个级别，即：高、中、低。图4-8显示了采用  $k=5$  的  $k$  折交叉验证方法对三组 APP 使用水平不同的互联网卡用户的平均度量得分和误差条。我们可以看到，ICCP 在 APP 使用频率中等和较高的用户中都能很好地工作，这两个用户的指标得分非常相似。但是，我们可以观察到，APP 使用频率较低用户的指标得分比其他 App 使用级别的用户要大，这与我们之前的分析是一致的，低 App 使用频率的特征可以有效区分出离网用户。例如，对于召回率、精确度和 F1 分数的指标，APP 使用频率较低用户组可以分别获得 0.76、0.68 和 0.72 的平均分，APP 使用频率中等用户组可以分别获得 0.63、0.59 和 0.61 的平均分，而 APP 使用频率较高用户组用户可以分别获得 0.59、0.58 和 0.59 的平均分。

### 4.3.4 套餐参数的影响

为了检验用户套餐选择的影响，我们采用  $k$  折交叉验证方法，用误差条图绘制前 2 个受欢迎套餐（例如，19 元和 39 元）的平均度量分数，如图4-9所示。我们可以观察到，ICCP 对于这两种套餐的用户都可以稳健地工作，其中他们的精准率度量得分非常相似，并且与系统的总体性能相当。此外，我们可以看到 39 元套餐的指标得分（例如，召回率和 F1 分数）比 19 元套餐的用户略大，这是因为根据我们之前的分析，19 元套餐比 39 元套餐有更多的离网用户，从而带来了更

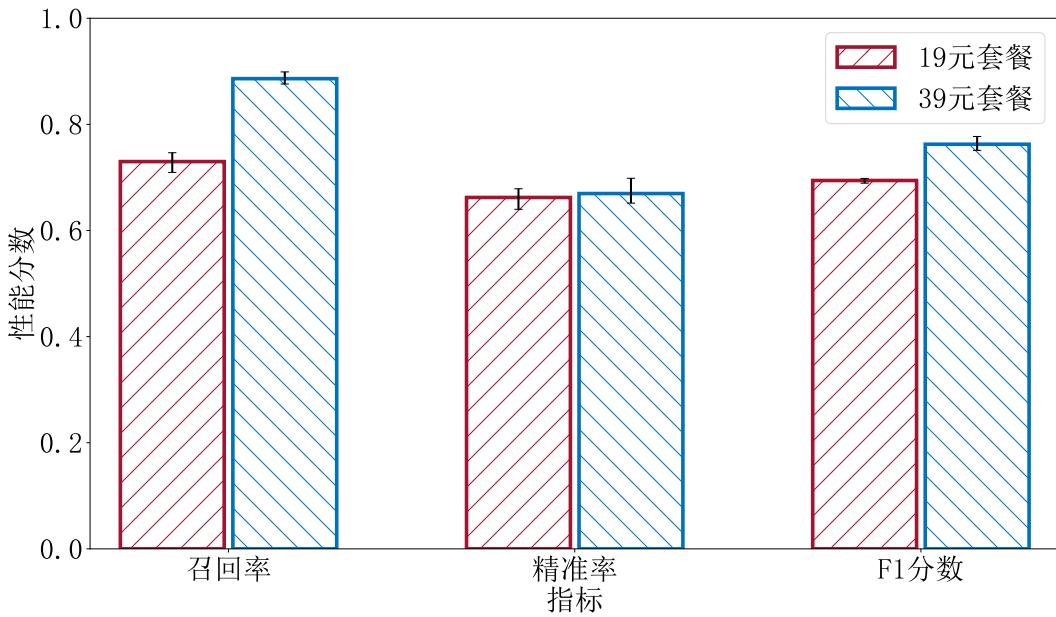


图 4-9 套餐参数的影响

多的预测挑战。

#### 4.4 消融实验

表 4-1 消融实验

|           | AUC    | PR-AUC | F1 分数  | 召回率    | 精准率    |
|-----------|--------|--------|--------|--------|--------|
| 所有特征      | 0.9754 | 0.7749 | 0.7022 | 0.7464 | 0.6630 |
| -目标编码     | 0.8656 | 0.4646 | 0.4548 | 0.4783 | 0.4335 |
| -账户余额     | 0.9441 | 0.6420 | 0.5750 | 0.5795 | 0.5706 |
| -CDR 序列   | 0.9727 | 0.7380 | 0.6781 | 0.7378 | 0.6274 |
| -异常天数     | 0.9752 | 0.7742 | 0.7014 | 0.7513 | 0.6577 |
| -开卡月份     | 0.9745 | 0.7699 | 0.6970 | 0.7392 | 0.6593 |
| -流量序列     | 0.9735 | 0.7624 | 0.6912 | 0.7336 | 0.6535 |
| -年龄       | 0.9735 | 0.7624 | 0.6912 | 0.7336 | 0.6535 |
| -活跃熵      | 0.9439 | 0.6411 | 0.5716 | 0.6355 | 0.5195 |
| -APP 使用频次 | 0.9712 | 0.7321 | 0.6754 | 0.7668 | 0.6035 |

在本小节中，我们将进行消融实验来验证提取特征的有效性。消融实验结果如表4-1所示。我们可以观察到，对于我们提取的主要特征，它们可以显著地影响预测性能，特别是目标编码和帐户余额这两个特征。特别是，当去除目标编码、帐户余额和活跃熵特征时，精度从 0.6630 下降到 0.4335、0.5706 和 0.5195，性

能分别下降 34.6%、13.9% 和 21.6%。同样地，对于 F1 分数和召回率，分数可以分别从 0.7022 降低到 0.4548、0.5750 和 0.5716，从 0.7464 降低到 0.4783、0.5795 和 0.6355。

## 第5章 用户离网偏好感知的干预匹配算法设计

### 5.1 模块描述

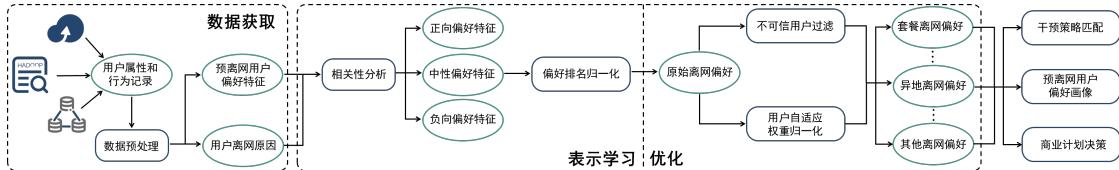


图 5-1 预离网用户偏好生成模块图

离网偏好模块的目标是找到一个准确的、可解释的表示法来表示离网预测模块给出的预离网用户的离网偏好。因此，我们首先限制了可用数据所能反映的离网原因的范围。在此基础上，运用耦合分析方法检验了各离网原因的独立性。接下来，我们通过提出的偏好排序归一化技术提取用户离网偏好。最后，对不可靠用户进行筛选，并实现用户自适应的权重归一化技术，来表征预离网用户的离网偏好。

### 5.2 离网原因与偏好的相关性分析

如图5-2所示为互联网卡用户离网原因分布，从中可以看出，离网原因有几十种，且各不相同。因此，我们选取用户数量排名前 10 位的离网原因，并绘制出相应的分布。

如图5-3所示，离网原因服从长尾分布，前 10 名离网原因的人数占总离网原因人数的 90%。因此，我们选择前 10 个离网原因来代表互联网卡用户的离网偏好是合理的。然而，由于现有数据表达能力有限，我们在 10 大离网原因中取消了 5 个，分别是号卡太多，无使用需求，其他，卡故障和已办宽带。

我们想知道，单一的离网原因是否可以完全代表预离网用户的离网偏好。因此，本文选取 20 万个离网用户来计算每两个离网原因之间的重叠程度。我们用杰卡德相似系数来计算重叠度，计算公式(5-4)如下式所示。

$$J(R_A, R_B) = \frac{|R_A \cap R_B|}{|R_A \cup R_B|} \quad (5-1)$$

其中  $R_A, R_B$  分别表示因为离网原因 A 和 B 的离网用户 id 集合。

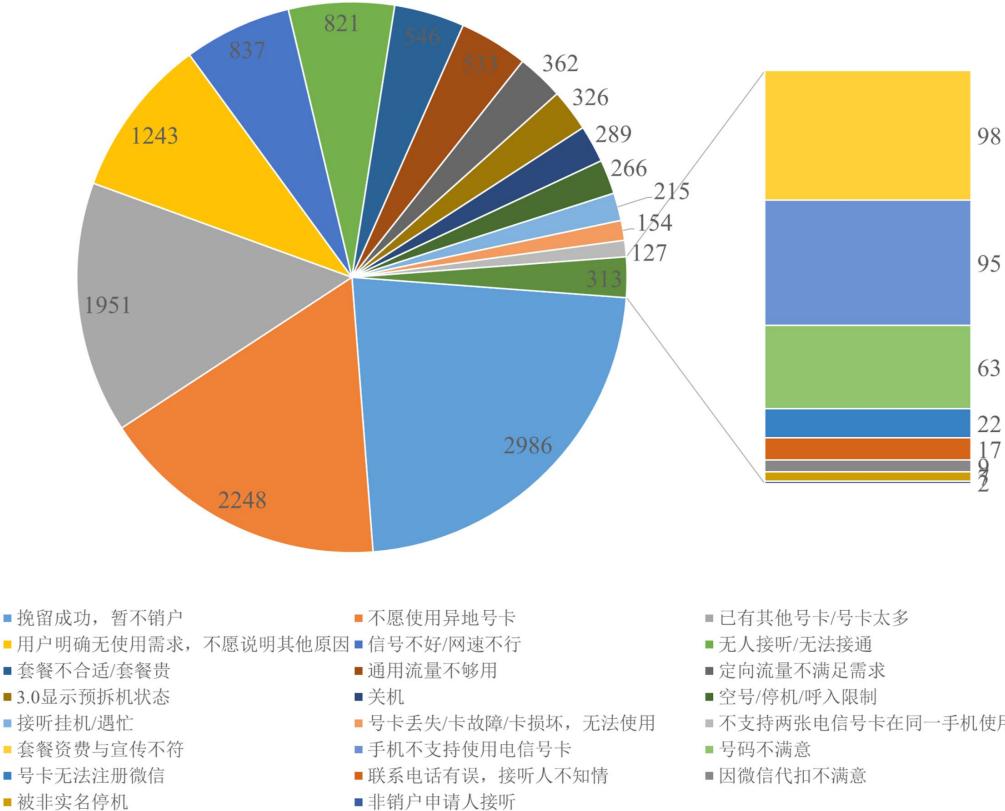


图 5-2 互联网卡用户所有离网原因示意图

|        | 套餐不合适 | 信号不好 | 异地号卡 | 通用流量不够 | 定向流量不够 |
|--------|-------|------|------|--------|--------|
| 套餐不合适  | 1     | 0.04 | 0.63 | 0.71   | 0.06   |
| 信号不好   | -     | 1    | 0    | 0      | 0      |
| 异地号卡   | -     | -    | 1    | 0.75   | 0.05   |
| 通用流量不够 | -     | -    | -    | 1      | 0      |
| 定向流量不够 | -     | -    | -    | -      | 1      |

从表5.2中，我们可以得出这样的结论：由于套餐昂贵、异地号卡、通用流量不足等原因高度重叠，从而一起导致了用户的离网。这个现象暗示我们，部分离网用户的离网原因分布与个人偏好相关，可能有多个离网原因导致用户离网。此外，因网速低或定向流量不足而离网的离网用户相对独立，而高使用频次和高消费的离网用户大多为具有显著维系价值的外地用户。

综上所述，本文需要一个不同权重的离网原因数据结构来捕捉潜在离网用户的离网偏好。严格来说，我们定义了一个离网原因向量  $\vec{Cp} = [r_1, \dots, r_n]$ ，本文把这称之为叫做离网偏好向量，用来表示潜在离网用户的离网偏好。然后我们定义  $r_i \in \vec{Cp}$  表示潜在离网用户的第  $i$  个离网原因的权重， $n$  表示离网原因的数量。因

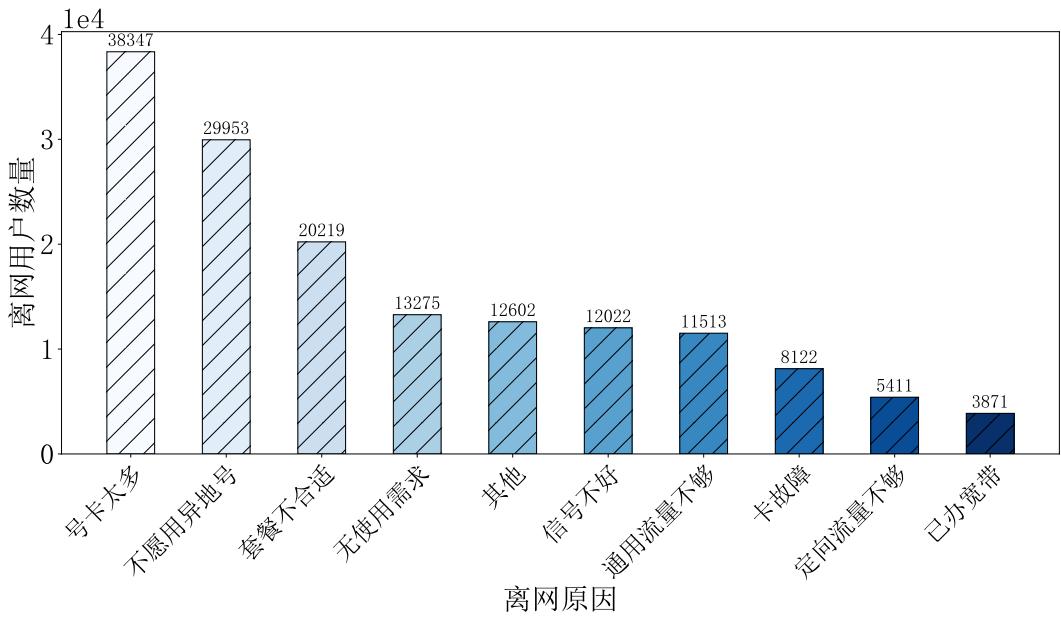


图 5-3 互联网卡用户可建模的离网原因示意图

此，我们得到约束如下： $r_c^1 + r_c^2 + \dots + r_c^n = 1$ 。具体来说，在我们的场景中，离网原因包括套餐昂贵、网速低、定向流量不足、非本地互联网卡和通用流量不足，即  $n = 5$ 。

### 5.3 离网偏好排名归一化

#### 相关特征选择

| 离网原因   | 偏好特征 1   | 相关性 1 | 偏好特征 2  | 相关性 2 |
|--------|----------|-------|---------|-------|
| 套餐不合适  | 出账金额     | 正向    | 账户余额    | 负向    |
| 信号不好   | 最大网速     | 负向    | 平均网速    | 负向    |
| 异地号卡   | 异地流量记录条数 | 正向    | 异地流量消耗值 | 正向    |
| 通用流量不够 | 通用流量记录条数 | 正向    | 通用流量消耗值 | 正向    |
| 定向流量不够 | 定向流量记录条数 | 正向    | 定向流量消耗值 | 正向    |

我们首先人工选择与相应离网原因高度相关的偏好特征。例如，如表5.3所示，我们为昂贵的套餐这个离网原因选择了出账金额和账户余额这两个偏好特征。

#### 等频分箱

为了表示离网预测模块给出的预离网用户的离网偏好，我们要计算出某一

特定预离网用户在所有潜在离网用户中所处的水平。具体来说，如果某个预离网用户  $c$  在某个特定离网原因  $crf$  所属的偏好特征上排名超过了绝大多数用户，那么我们假设该预离网用户  $c$  很有可能因为离网原因  $crf$  而离网。此外，由于每个偏好特征的分布和性质不同，本文需要一种方法来推导出能按比例地反映离网原因的权重。基于以上假设，我们采用等频分箱技术对表5.3中的上述特征分别进行离散化处理。接着，本文能把每个偏好特征从值域  $[min\_val, max\_val]$  映射到值域  $[1, n_c]$ ，其中  $min\_val$ ,  $max\_val$  和  $n_c$  分别表示偏好特征的最小值，最大值和分箱数量。在我们的设置当中， $n_c = 100$ .

### 双重排名归一化

对于和对应离网原因是正相关关系的特征向量  $\vec{x}$  来说，特征  $x$  的排名向量  $\overrightarrow{R_x}$  等于

$$\overrightarrow{R_x} = \frac{\vec{x} - min\_val}{max\_val - min\_val} * (n_c - 1) + 1. \quad (5-2)$$

对于和对应离网原因是负相关关系的特征向量  $\vec{x}$  来说，特征  $x$  的排名向量  $\overrightarrow{R_y}$  等于

$$\overrightarrow{R_y} = \frac{\vec{y} - min\_val}{max\_val - min\_val} * (n_c - 1) + 1. \quad (5-3)$$

## 5.4 离网偏好生成

在推导出所有偏好特征的排名向量集合之后，我们可以计算出预离网用户的原始离网偏好向量

$$\overrightarrow{C_{pr}} = [pr_1, \dots, pr_n] = concat(\sum_{j=1}^2 0.5 \times R_{ij}, for i = 1, \dots, n). \quad (5-4)$$

例如，预离网者  $c$  的原始离网偏好向量  $\overrightarrow{C_{pr}}$  可能等于  $[0.9, 0.7, 0.01, 0.02, 0.4]$ ，这意味着昂贵的套餐成本、低网速、定向流量不足、非本地互联网卡和通用流量不同的权重分别为  $0.9, 0.7, 0.01, 0.02, 0.4$ 。

### 5.4.1 不可信用户过滤机制

首先，虽然离网预测模型已经过滤掉了大部分正常用户，但仍有少数正常用户被遗漏。其次，干预的预算有限，只能覆盖部分离网用户。第三，典型活跃离网用户的离网偏好特征的排序和要高得多。基于以上三个原因，我们在生成客户离网偏好模块之后设置了一个不可信用户过滤模块。具体来说，排名和小于预先定义的阈值  $t$  的预离网用户将被过滤，即离网偏好字段的平均排名小于  $t/n$ 。由

于这些预离网用户的离网偏好与其他预离网用户相比并不值得注意，这些预离网用户将被移除来保证有限预算的投资回报率(ROI)。

#### 5.4.2 自适应的权重归一化

虽然预离网用户的离网偏好是个性化的，但对于每一个预离网用户，每个离网偏好的贡献率之和应该等于1。为了统一离网偏好向量元素的量级，我们采用改进的 softmax 函数，通过用户自适应的方式表示预离网用户的离网偏好向量  $\vec{C}_p$ ，如下公式5-5所示。

$$\vec{C}_p = \frac{e^{pr_i - \max(\vec{C}_{pr})}}{\sum_{i=1}^n e^{pr_i - \max(\vec{C}_{pr})}} \quad (5-5)$$

其中  $\max(\vec{C}_{pr})$  表示原始离网偏好向量  $\vec{C}_{pr}$  的最大值。最后，我们可以获得预离网用户  $c$  的离网偏好向量  $\vec{C}_{pc}$  和预离网用户集  $C$  的离网偏好矩阵  $\vec{C}_p$ 。

## 5.5 系统描述与问题建模

### 问题形式化

为了建模匹配模块，我们首先需要把匹配问题形式化，以保证我们的框架能够泛化到其他不同应用场景并且用支持不同算法、模型等实现具体功能。以下是具体描述。

对于运营商等企业，他们会采取一些干预策略，如营销宣传、优惠政策等来维系预离网用户。为保持通用性，我们定义干预策略集  $\vec{E} = [E_0, E_1, E_2, \dots, E_i, \dots, E_M]$ ，其中  $0$  表示不进行任何干预， $E_i$  表示第  $i$  个的干预策略。在我们的情景中，干预策略可以分为以下四种：话费、流量、通话和 APP。

为了使我们提出的框架能够感知预算，干预策略的成本被形式化为向量  $\vec{E} = [E_0, E_1, E_2, \dots, E_i, \dots, E_M]$ ，其中  $E_i$  表示第  $i$  个干预策略的成本。其中， $E_0 = 0$  表示企业对预离网用户不做任何干预时，成本等于 0。

对于在由离网预测模块给出的预离网用户集合  $\mathcal{C}$  中的任何一个预离网用户  $c$ ，我们定义一个二元状态变量  $y_c$  来表示下个月该预离网用户  $c$  是否会真的离网，其中  $y_c = 1$  表示下个月预离网用户  $c$  会离网， $y_c = 0$  则表示相反的意思。我们还定义了一个二元状态变量  $z_c$  来表示在执行干预后，预离网用户  $c$  是否被成功维系，其中  $z_c = 1$  表示预离网用户  $c$  被成功保留， $z_c = 0$  则相反。 $\vec{x}_c$  被定义为企业实施到预离网用户  $c$  的干预策略。 $\vec{x}_c = [x_{c0}, x_{c1}, \dots, x_{cj}, \dots, x_{cM}]$ ，其中  $x_{cj} = 1$  表示用户  $c$  采用了第  $j$  个干预策略， $x_{cj} = 0$  表示相反。需要特别指出的是， $x_{c0} = 1$  表示企业对预离网用户  $c$  不采取任何干预措施。

因此，匹配模块的优化目标可以形式化为

$$\begin{aligned} & \max \sum_{c \in \mathcal{C}} y_c z_c \\ \text{s.t. } & \sum_{\forall c} \vec{x}_c \cdot \vec{E} \leq B, \\ & LV_c \geq \vec{x}_c \cdot \vec{E}, \forall c \end{aligned} \tag{5-6}$$

其中  $B$  表示为企业预算， $LV_c$  表示为预离网用户  $c$  的生命周期价值。 $(5-6)$  代表的意义为企业预先给定的预算  $B$  的前提下，基于我们预算感知的框架，我们的目标是最大化干预成功的离网用户数。第一个约束意味着所有的干预策略投入成本和要小于等于预算  $B$ 。第二个约束旨在通过限制投入到预离网用户  $c$  的成本之和要小于等于其生命周期价值的贪婪方式来保证最后最终收益是非负的。

### 设计思想

我们对于匹配模块的设计思想是把挽留策略匹配问题建模成一个多臂老虎机问题。原因如下：

1. 我们只给每个用户匹配一个挽留策略。
2. 假设每个挽留策略对某个用户是否干预成功的指示变量是服从某一概率分布的，但是每个挽留策略不一定是独立的，所以不同的拉杆之间可能有耦合关系。
3. 目的是最大化挽留收益。这些都符合典型的多臂老虎机问题设置，一次操作对应一个用户，一个拉杆对应一个挽留策略，老虎机的累积奖励对应企业的最终挽留收益。

基于上述原因，我们设计了如下架构。首先我们生成一个奖励模型用以给匹配算法提供基于用户离网偏好的反馈从而弥补缺失直接用户偏好数据的问题。然后我们通过离线训练挽留策略匹配模型来使它学习不同离网偏好的预离网用户的挽留策略偏好。

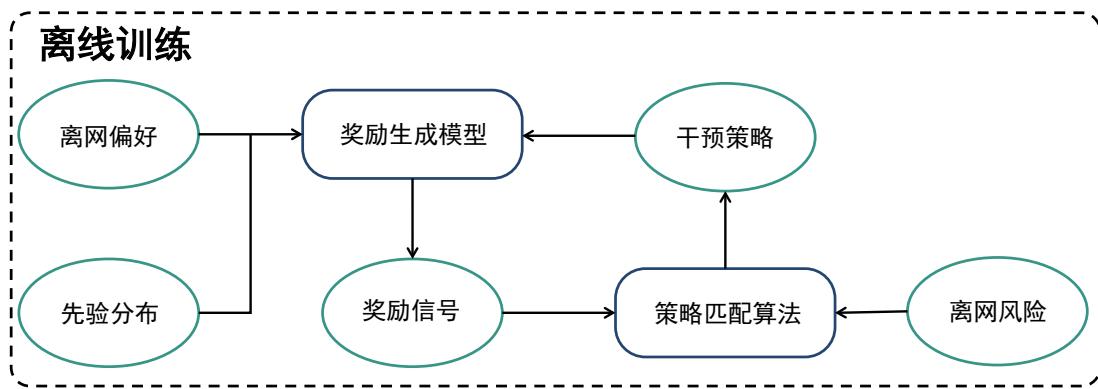


图 5-4 干预策略匹配模块图

## 5.6 奖励生成模型设计

基于以下三个原因，我们设计了奖励生成模型。

1. 我们的数据缺乏直接的干预记录，如客户 id、匹配的干预策略、干预结果等。然而，我们获得了不同离网原因所匹配的干预策略成功概率的统计数据。
2. 受基于人类反馈的强化学习 (RLHF) 的启发，我们设计的这个模块可以通过接受预离网用户的离网偏好来生成反映人类偏好的奖励。
3. 由于干预记录数据的稀疏性，奖励生成模型可以生成合成数据用于训练后续算法，以降低相关数据的收集和清理成本。

为此，我们实现了一种接受预离网用户的离网偏好和相应的干预策略作为输入，并返回信号值作为奖励的多臂老虎机 MAB。因此，奖励生成模型的拉杆数量需要满足约束

$$\# \text{. arms} = (M + 1) \times N \quad (5-7)$$

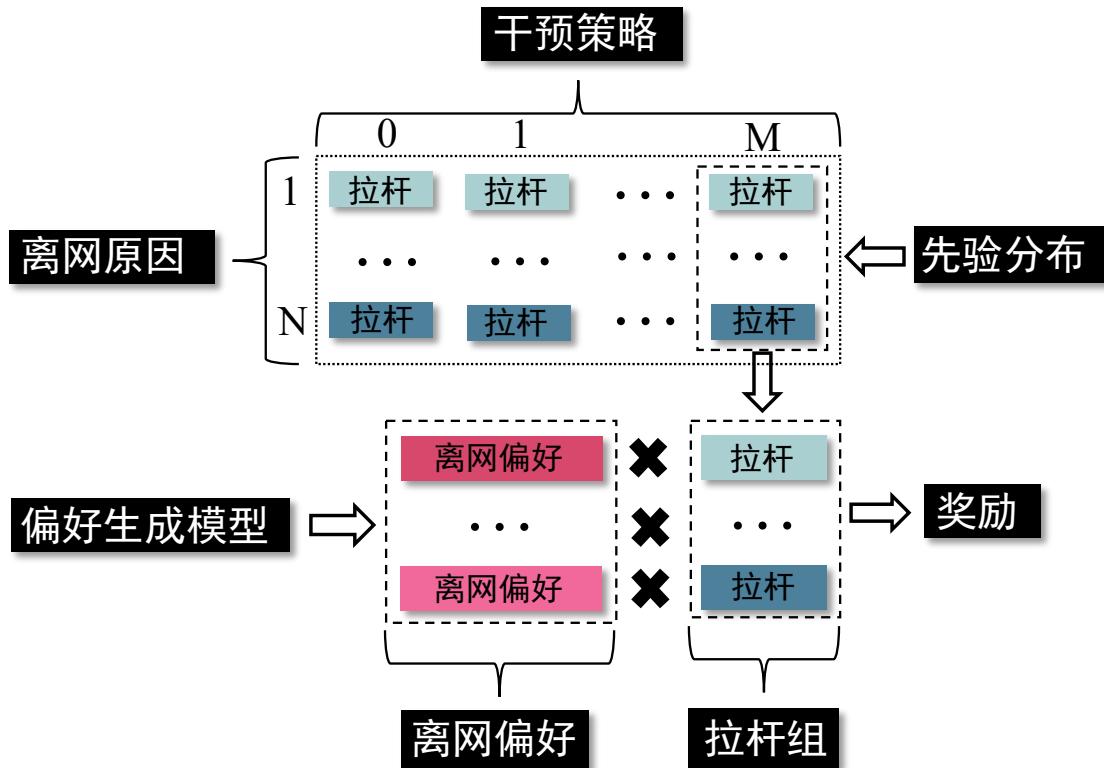


图 5-5 奖励模型内部示意图

，其中  $N$  为离网原因数， $M$  为干预策略数。具体而言，如图5-5所示，奖励生成模型有  $N$  行和  $M + 1$  列的拉杆，其中  $arm_{ij}$  表示对于因为离网原因  $i$  离网的用户匹配干预策略  $j$  的奖励期望。一列的拉杆被合称为一个拉杆组。

奖励生成模型中的拉杆可以被任意分布初始化，包括领域知识分布、均匀分布、高斯分布、二项分布、伽玛分布、泊松分布和指数分布等。由于我们统计了不同离网原因对应的干预策略成功概率。我们可以设定上述分布的期望等于平均成功概率。对于基于领域知识的分布，我们用不同离网原因对应的干预策略平均成功概率填充。

接下里，本文会介绍产生被称为奖励的信号值的机制。首先，离网偏好模块将输出预离网用户  $c$  的离网偏好向量  $\vec{Cp}_c$ 。其次，策略匹配算法将匹配预离网用户  $c$  以干预策略  $s_c$ 。接着，奖励生成模型将干预策略  $s_c$  作为输入，然后选择相应的拉杆组。然后，奖励生成模型将离网偏好向量  $\vec{Cp}_c$  与拉杆组  $\vec{Ag}_c$  的点积计算为干预策略  $s_c$  的奖励期望，如公式(5-8)所示。

$$\mathbb{E}_{s_c} = \vec{Cp}_c \cdot \vec{Ag}_c \quad (5-8)$$

最后，奖励生成模型将根据 0 到 1 的均匀分布生成随机数  $rn$ 。如果生成的随机数小于或等于点积，奖励生成模型将返回奖励  $r_c = 1$ ，否则为  $r_c = 0$ 。具体可见

公式(5-9)

$$r_c = \begin{cases} 1, & \text{if } \mathbb{E}_{s_c} \leq rn \\ 0, & \text{otherwise} \end{cases} \quad (5-9)$$

由公式(5-9)可知，单个干预策略的维系成功概率服从伯努利分布。假设有  $M + 1$  个干预策略，那么我们如果尝试匹配无限次的话，我们将得到所有干预策略的平均奖励集合  $\theta = (\theta_0, \dots, \theta_M)$ 。接下来，如果策略匹配算法选择一个干预策略  $s$ ，那么我们可以得到一个奖励  $r \in \{0, 1\}$ ，这实际上是从伯努利分布中抽取的样本。换句话说， $\mathbb{P}[r = 1|s\theta] = \theta_s$  并且  $\mathbb{P}[r = 0|s, \theta] = 1 - \theta_s$ ，这与观测到的事实是一致的。

## 5.7 基于汤普森采样的用户-干预措施匹配算法设计

### 5.7.1 问题建模

在本文的场景中，多臂老虎机问题可以表示为五元组  $\langle \mathcal{A}, \mathcal{E}, \mathcal{C}, \mathcal{A}', \mathcal{R} \rangle$ 。

**代理 (Agent) ( $\mathcal{A}$ )**. MAB 问题的目标是最大化离网预测模块在预离网用户集  $\mathcal{C}$  中收集的累积奖励，如下所示。

$$\begin{aligned} & \max \sum_{c \in \mathcal{C}} y_c r_c, \quad s_c \sim \mathcal{R}(\cdot | s_c) \\ & \text{s.t. } E_{s_c} \leq B, \\ & LV_c \geq E_{s_c}, \forall c \end{aligned} \quad (5-10)$$

公式(5-10)是公式(5-6)的具体实现之一，其中  $s_c$ ,  $r_c$  分别表示与预离网用户  $c$  匹配的干预策略，匹配干预策略  $s_c$  所得的奖励。

**环境 (Environment) ( $\mathcal{E}$ )**.  $\mathcal{E}$  包含用户侧信息和项目侧信息。更具体地说，我们接受离网预测模块生成的预离网用户集合  $\mathcal{C}$  作为用户侧信息。此外，我们将干预策略集  $\mathcal{S}$  定义为物品侧信息，这其也是干预策略集  $\mathcal{M}$  的具体实现。因此，干预策略空间等于集合  $\{s_0, \dots, s_M\}$ ，我们定义了  $s_m \in \mathcal{S}$  来表示任何在干预策略空间中的干预策略。相应的，干预策略集的代价集形式化为向量  $\vec{E} = [E_0, E_1, E_2, \dots, E_i, \dots, E_M]$ ，其中  $E_i$  表示第  $i$  个干预策略的成本。需要特别指出的是，其中  $E_0 = 0$  表示企业在预离网用户上不做任何干预时，成本等于 0。

**上下文 (Context) ( $\mathcal{C}$ )**. 首先也是最重要的，我们引入预算  $B$ ，以设置一个反映实际应用中资源有限的环境。此外，我们定义了离网偏好模块给出的离网偏好矩阵  $C_p$  和离网预测模块给出的离网风险向量  $\vec{Cr}$  作为上下文信息，使所提出的框架具有上下文感知能力，从而提高整体性能。

**动作 (Action) ( $\mathcal{A}'$ )**. 由于匹配干预策略对应于拉动杠杆，我们定义多臂老虎机中有  $M + 1$  个拉杆。正式来说，我们将可用拉杆集合定义为干预策略集  $\mathcal{S}$ 。

**奖励 (Reward) ( $\mathcal{R}$ ).** 对于每一个干预策略  $s$ , 我们定义了它的期望回报为

$$Q(s) = \mathbb{E}_{s \sim \mathcal{R}(\cdot|s)}[r] \quad (5-11)$$

。因此, 当离网用户具有确定的离网偏好时, 至少存在一种干预策略的奖励期望大于或等于其他干预策略的奖励期望。我们定义最佳奖励期望为

$$Q^* = \max_{s \in S} Q(s) \quad (5-12)$$

。我们引入当前干预策略的懊悔, 即当前干预策略的奖励期望与最佳干预策略的奖励期望之差, 可被以下公式计算

$$R(s) = Q^* - Q(s). \quad (5-13)$$

自然地, 累积懊悔是干预了  $N$  个预离网用户后的懊悔的总和。换句话说, 对于一个序列  $N$  步决策过程  $s_1, s_2, \dots, s_N$  而言, 累积懊悔

$$\sigma_R = \sum_{n=1}^N R(s_n) \quad (5-14)$$

。因此, 多臂老虎机问题的目标是使累积奖励最大化, 也等于使累积遗憾最小化。

### 5.7.2 基于奖励生成模型的训练算法

首先, 我们选择 Thompson Sampling(TS) 作为基础算法, 原因如下。TS 算法是一种蒙特卡罗抽样方法, 它对所有拉杆的奖励概率进行抽样。更具体地说, TS 算法假设每个拉动杠杆的奖励期望服从一定的概率分布, 然后选取杠杆中最高的奖励期望。然而, 获得所有拉杆奖励期望的成本是巨大的, 这是不现实的。因此, TS 采用基于抽样的策略, 即根据所有干预策略的奖励概率分布进行一轮抽样, 得到所有干预策略的样本。TS 在所有样本中选择奖励最高的作为匹配干预策略。因此, 在贝叶斯框架下, TS 比贪心算法具有天然的优势, 因为前者是通过随机抽样而不是后者简单的样本平均来估计奖励期望。为了进一步挖掘上下文信息, 本文提出了一种针对运营商互联网卡用户的干预策略匹配 internet card strategy matching(ICSM) 算法。在算法5-1中给出了所提出的 ICSM 算法的伪代码。

## 5.8 本章小结

---

**算法 5-1 ICSM: 在资源有限上下文中的投资回报率优先的汤普森采样算法**


---

**Input:** 预离网用户集  $\mathcal{C}$ , 干预策略集  $\mathcal{S}$ , 成本向量  $\vec{E}$ , 预算  $\mathcal{B}$ , 离网偏好矩阵  $C_p$ , 离网风险向量  $\vec{Cr}$ , 离网指示向量  $\vec{Ci}$ , 生命周期价值向量  $\vec{LV}$ , 奖励生成模型  $RGM$

**Output:** ICSM, 预算  $\mathcal{B}$ , 奖励列表  $RL$

```

1: 初始化  $S(1) = 0, F(1) = 0$ 
2: for  $c = 1, 2, \dots, \mathcal{C}$  do
3:   if 预算  $\mathcal{B} <$  干预策略最小的成本  $\min(\vec{E})$  then
4:     break
5:   else
6:     初始化最大概率  $MaxProb = -1$ 
7:     初始化选择拉杆号  $SelectedArm = -1$ 
8:     for  $m = 0, 1, \dots, \mathcal{M}$  do
9:       从  $Beta(S_m(t) + 1, F_m(t) + 1)$  分布中采样奖励期望  $r_m$ 
10:      if  $\mathcal{B} >= \vec{E}_m$  and  $LV_c >= \vec{E}_m$  and  $r_m / \vec{E}_m > MaxProb$  then
11:        最大概率  $MaxProb = r_m / \vec{E}_m$ 
12:        选择拉杆号  $SelectedArm = m$ 
13:      end if
14:    end for
15:    奖励  $r_c = RGM(C_{pc}, SelectedArm)$ 
16:     $RL$  在尾部追加  $(r_c * Ci_c)$ 
17:     $S_{SelectedArm}(t + 1) = S_{SelectedArm}(t) + r_c * Cr_c$ 
18:     $F_{SelectedArm}(t + 1) = F_{SelectedArm}(t) + 1 - r_c * Cr_c$ 
19:    预算  $\mathcal{B} - = \vec{E}_{SelectedArm}$ 
20:  end if
21: end for

```

---

## 第 6 章 关于干预匹配算法模块的实验评估与结果分析

### 6.1 实验设置

为了证明我们所提出的 UPRS 框架和 ICSM 算法的有效性，我们收集了年龄在 16-81 岁之间的正常个人互联网卡客户。2020 年 11 月收集的训练数据集有 30 万名用户，其中包括 23112 名离网用户。2020 年 12 月收集的测试数据集有 7.5 万用户，其中包括 5939 名离网用户。两个数据集的正负样本不平衡比例非常接近，一个是 11.98，另一个是 11.62。

#### 6.1.1 对比方案

基准模型为了证明我们提出的 ICSM 的优越性，我们设计并实现了以下可比较的匹配基准模型，包括强化学习模型。需要注意的是，虽然这些算法在各个领域的文献中已被广泛采用，但 IC 用户干预策略匹配并没有参考实现。此外，为

了保证比较的公平性，所有基准测试都采用了与 ICSM 相同的偏好输入。

- **$\epsilon$ -贪婪 ( $\epsilon$ -Greedy)**: 是强化学习中平衡探索与开发的一种简单方法。它指示智能体选择一个小概率  $\epsilon$  的随机操作，否则就根据当前对奖励的估计选择最佳操作，概率  $\epsilon$  是固定的。
- **$\epsilon$ -衰减 ( $\epsilon$ -Decay)**: 是  $\epsilon$ -贪婪算法的变体。在智能体使用一些在线算法来学习最优行为的情况下，智能体在最初探索更多，并最终在接近目标行为时利用更多。这种从重度探索到重度开发的转变可以通过逐渐减少 *epsilon* 来实现。在我们的场景中， $\epsilon = \frac{1}{\sqrt{t}}$ 。
- **置信区间上界算法 (UCB)**: 是一种在网络广告、推荐系统、临床试验等多个领域平衡探索和开发的流行而有效的方法。UCB 算法以经验均值和方差为基础，为每个行动的期望回报分配一个上界，并在每一轮中选择上界最高的行动。在我们的场景中， $\hat{U}_t(a) = \sqrt{\frac{\log t}{2(N_t(a)+1)}}$ 。
- **汤普森采样 (TS)**: 是一种用于在线决策问题的算法，其中行动是按顺序采取的，必须在利用已知的知识以最大化当前绩效和投资积累可能提高未来绩效的新信息之间取得平衡。该算法求解范围广，计算效率高，在多臂老虎机问题中得到了广泛应用。

### 6.1.2 评估指标

对于干预策略匹配问题来说，基于以下这四个基础测试结果，分别是真阳性样本 (TP)，假阳性样本 (FP)，真阴性样本 (TN)，假阴性样本 (FN)，我们采用了一下 5 个评价指标来评估相应性能。

- **匹配算法性能：**
  - **累加懊悔 (Cumulative Regrets)**：指的是一种衡量算法给出的动作序列与后验最佳动作序列相比表现差距的评价指标。它被定义为一个最优动作序列的期望奖励与算法选择的动作序列的期望奖励之间的差值，直到某个时间步长。换句话说，它衡量的是由于算法做出的次优决策，随着轮次的增加积累了多少懊悔。[2]
- **系统总体性能：**
  - **精准率 (Precision)**：指的是一个预离网用户是真实离网用户并且被成功挽留的概率，具体公式为， $\frac{TP}{TP+FP}$ 。
  - **召回率 (Recall)**：指的是所有的真实离网用户被成功识别被成功挽留的比例，具体公式为， $\frac{TP}{TP+FN}$ 。
  - **F1 分数 (F1-Score)**：指的是精准率和召回率的调和平均数，具体公式为，

$$2 \times \frac{Precision \times Recall}{Precision + Recall}.$$

- **商业性能:**

- **奖励总和 (Rewards)** : 指的是被成功识别和挽留的离网用户的数量, 数值和  $TP$  一样.
- **平均奖励 (AR)**: 指的是预离网用户被成功挽留的概率。
- **收入总和 (Total Revenue)** : 指的是被成功识别和挽留的离网用户的的生命周期价值总和。

## 6.2 预离网用户干预框架性能评估

### 6.2.1 性能检测与对比

#### 匹配算法性能.

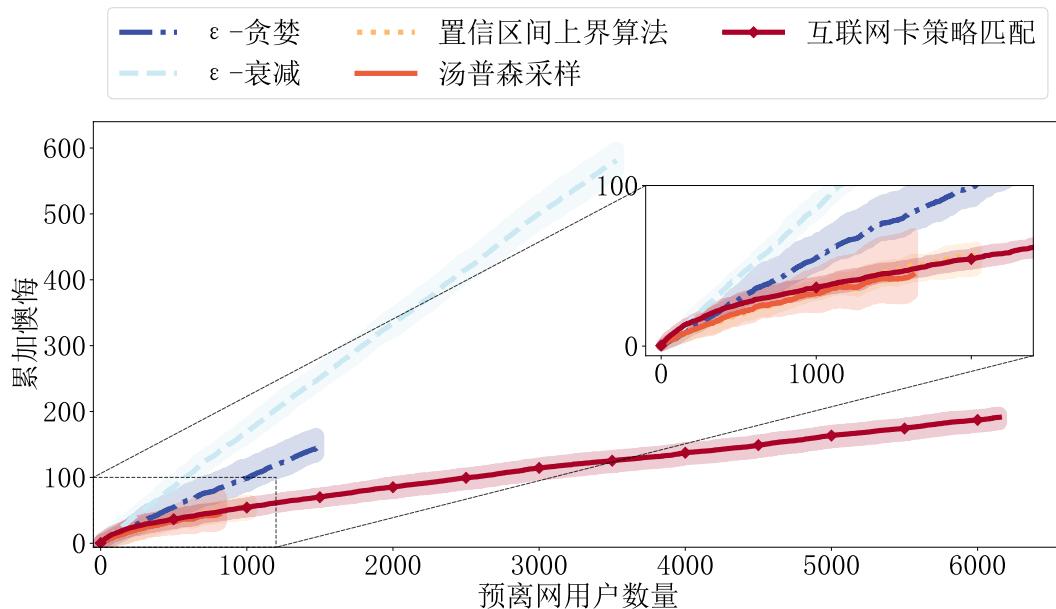


图 6-1 匹配算法性能对比图

我们首先通过与基准匹配算法的比较来测试所提出的 ICSM 算法的性能。图6-1为5种不同匹配算法计算的累加懊悔值, 实线表示5次独立实验下的平均性能, 对应的面积表示性能的上下界。然后我们可以得到如下的表述。首先, 我们提出的 ICSM 每轮累积遗憾次优只比 TS 差。同时, ICSM 算法干预了最多的预离网用户, 以获得与其他基准相比最好的奖励。第二, 尽管 TS 和 UCB 在干预的初始阶段表现有效, 但在干预的中期, 由于预算不足, 它们很快就失效了。它们沉迷于成功概率较高的策略, 同时也付出了较高的代价。最后, 观察  $\epsilon$ -贪婪算

法和  $\epsilon$ -衰减算法，我们可以得出结论，这些算法更倾向于成功率较低的策略，从而不能很好地挖掘干预策略的潜力。

### 干预框架总体性能.

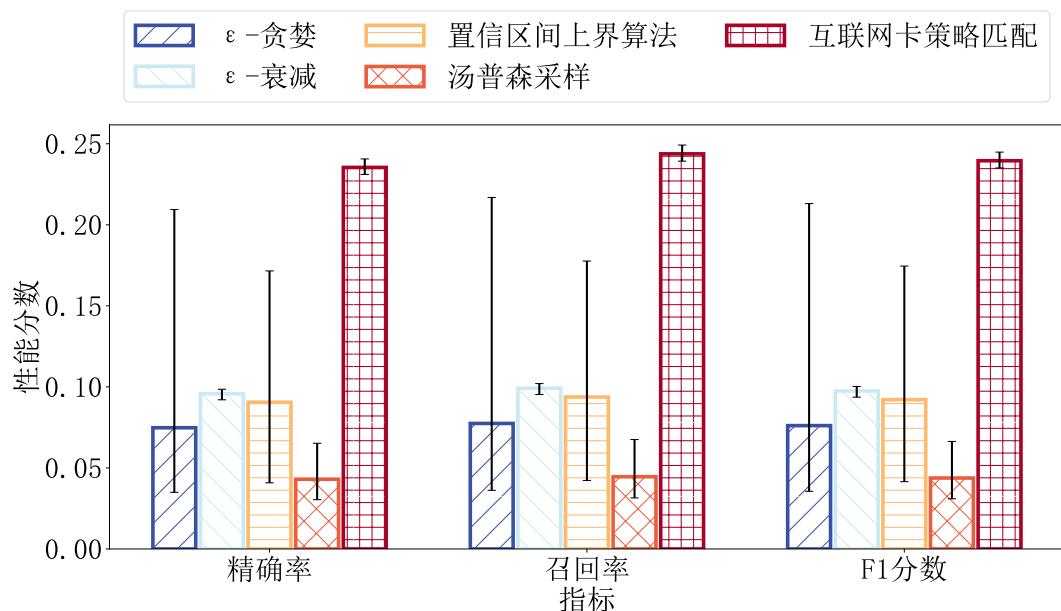


图 6-2 干预框架总体性能对比图

为了证明我们提出的框架 UPRS 的优越性，我们检查了系统的整体性能，以评估整个工作流程的有效性，包括离网预测，偏好建模和策略匹配。因为被建模一个分类问题。因此，我们采用精准率、召回率和 F1 分数等指标来评估整体性能。图6-2显示了各个匹配算法总体性能的平均值和上下界。我们可以进行如下的主要观察。首先，提出的 ICSM 算法在所有指标上都显著优于其他基准测试。例如，ICSM 中精准率、召回率和 F1 分数的平均分为 0.23,0.25,0.24，次优算法  $\epsilon$ -衰减的平均分约为 0.08,0.09,0.08。其次是由于误差多重效应导致整体性能较低。具体来说，系统的整体性能取决于以下两个因素的乘积，一个是离网预测性能，另一个是干预策略匹配性能。

### 商业指标.

我们选择了三个典型的业务指标来证明所提出的框架的有效性，分别是奖励总和、平均奖励和收入总和。根据图6-4，我们可以得出以下结论。首先，我们可以看到 ICSM 在三个指标上优于所有基线算法。其中， $\epsilon$ -贪婪、 $\epsilon$ -衰减、置信区间上界算法、汤普森采样的平均奖励的平均得分分别为 0.12、0.16、0.13、0.11，ICSM 的平均奖励平均得分为 0.41，性能分别提高了 242%、156%、215%、273%。其次，本文提出的 ICSM 算法在 5 个独立实验中表现出相当的稳定性，总体性能波动仅为 1%，有利于在工业生产环境中部署。

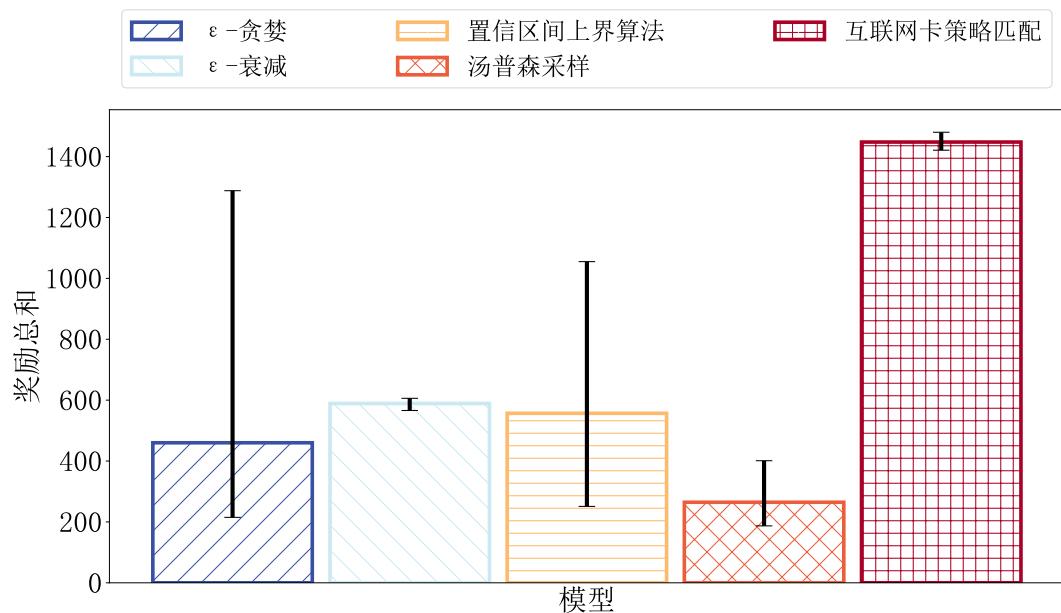


图 6-3 奖励总和对比图

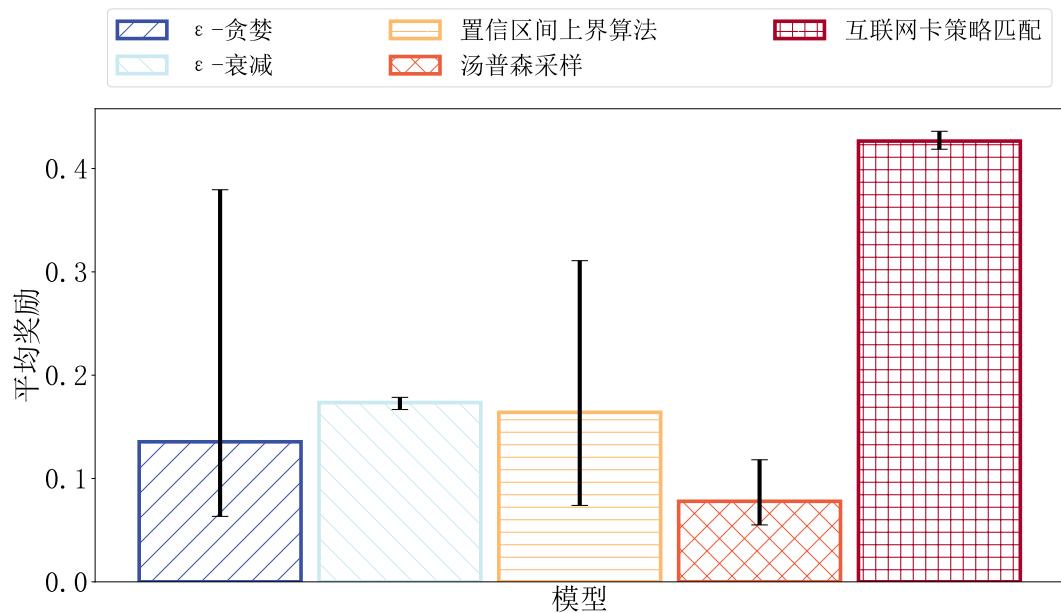


图 6-4 平均奖励对比图

### 6.2.2 健壮性测试

在评估了我们提出的框架的总体性能后，超参数、用户特征如何影响整个系统的健壮性是我们感兴趣的。因此，我们进行了以下参数影响实验。

为了检验我们提出的匹配算法 ICSM 的鲁棒性，我们准备了 6 个常见的先验概率分布。由图 6-6 可知，ICSM 在均匀分布、高斯分布、二项分布、伽玛分布、

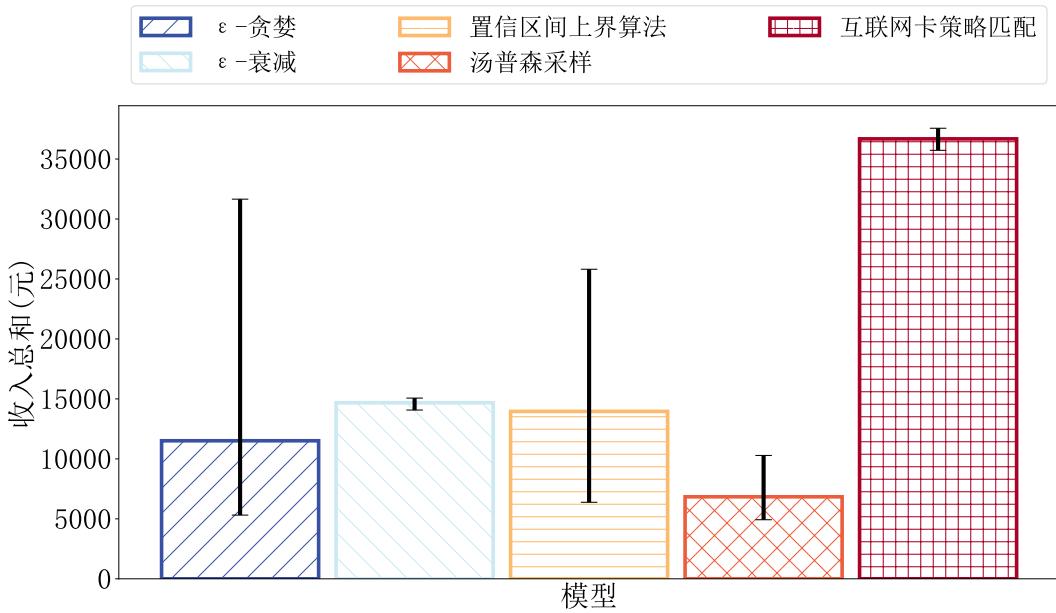


图 6-5 收入总和对比图

泊松分布、指数分布等常见概率分布下具有鲁棒性。在上述概率分布中，ICSM 优于所有基准算法。

### 6.3 参数影响

#### 6.3.1 城市

接下来，我们探讨城市层面对商业性能的影响，以找出城乡之间的不平等。我们首先按 GDP 降序排列城市，并且对城市名称做了脱敏处理，如图6-7所示。我们可以看到，虽然城市之间的奖励总和是不相等的，但平均奖励却非常接近，这表明了我们的 ICSM 算法的鲁棒性。

#### 6.3.2 年龄

然后，我们探讨年龄对商业性能的影响，以了解不同代际之间的差异。我们首先选择 16 岁到 85 岁的客户。其次，以 5 岁为单位进行年龄分组。从图6-8可以看出，虽然各年龄组的奖励不相等，但平均奖励值非常接近，这表明我们的 ICSM 算法在年龄方面具有鲁棒性。

#### 6.3.3 离网风险

最后，我们对离网预测模块给出的离网风险值的影响感兴趣。首先，我们将流失率风险因子分成 5 个人数相等的类别，其中类别越高，风险越高。从图6-9可

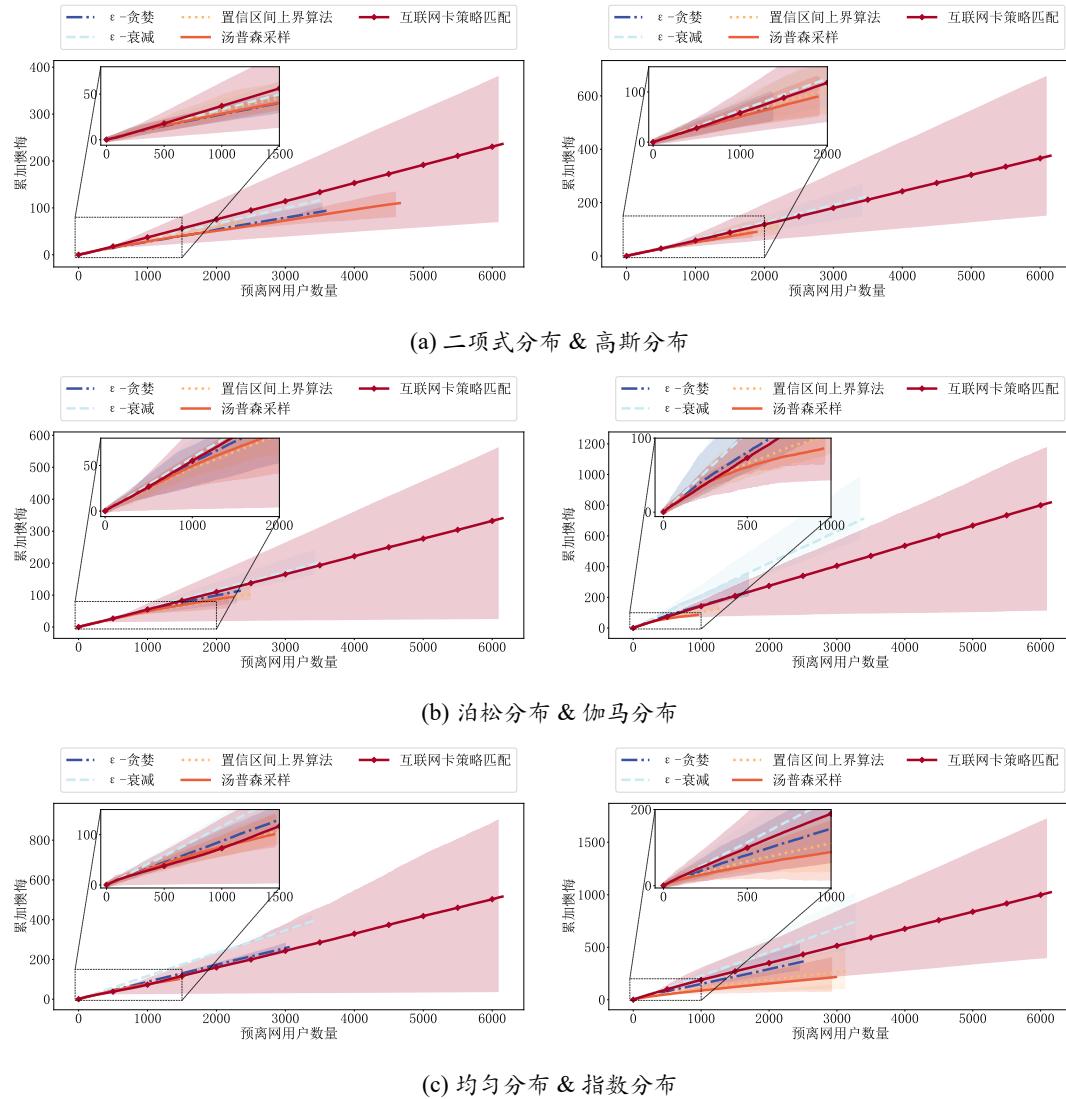


图 6-6 不同先验分布下的系统性能对比图

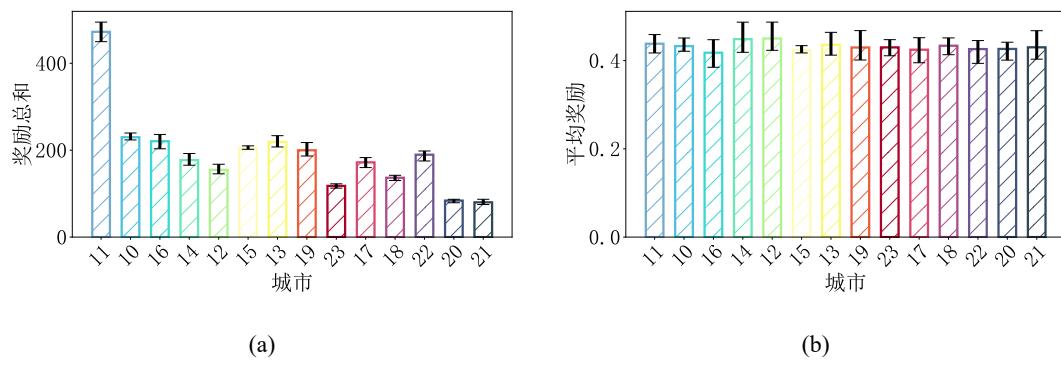


图 6-7 城市参数对于性能影响的对比图

以看出，虽然流失风险等级之间的收益不相等，但当流失风险等级增加时，AR 只会出现略微的衰减，这证明了我们的 ICSM 算法的鲁棒性。

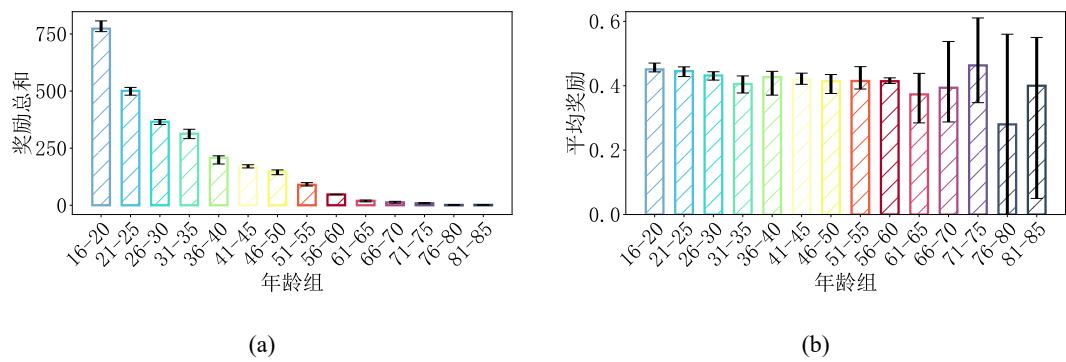


图 6-8 年龄参数对于性能影响的对比图

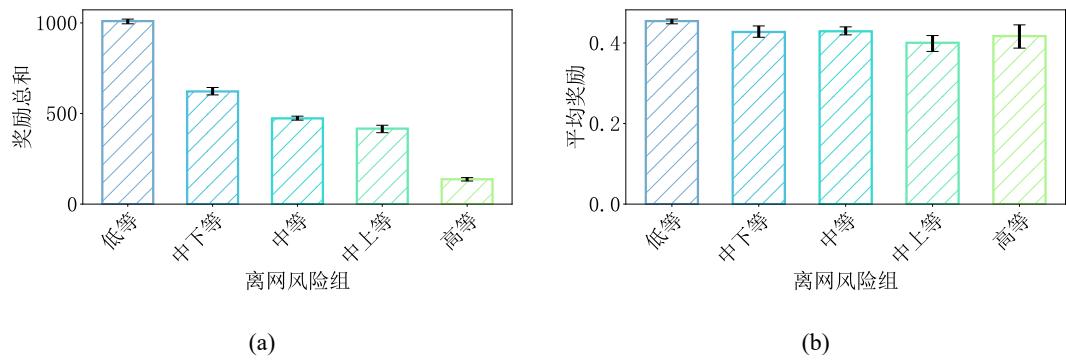


图 6-9 年龄参数对于性能影响的对比图

## 6.4 本章小结

## 第 7 章 总结与展望

7.1 工作总结

7.2 未来工作展望

## 参考文献

- [1] Lamport L. Latex: a document preparation system: user's guide and reference manual [M]. Addison-wesley, 1994.
- [2] Pritchard A, et al. Statistical bibliography or bibliometrics [J]. Journal of documentation, 1969, 25(4): 348-349.
- [3] 施巍松, 刘芳, 孙辉, 等. 边缘计算 [M]. 北京: 科学出版社, 2018.
- [4] 施巍松, 张星洲, 王一帆, 等. 边缘计算: 现状与展望 [J]. 计算机研究与发展, 2019, 56(01): 69-89.
- [5] Krauß V, Boden A, Oppermann L, et al. Current Practices, Challenges, and Design Implications for Collaborative AR/VR Application Development [C]//Proc. ACM CHI, Virtual Event/Yokohama, Japan. ACM, 2021: 454:1-454:15.
- [6] Wu F, Yang W, Lu J, et al. RLSS: A Reinforcement Learning Scheme for HD Map Data Source Selection in Vehicular NDN [J]. IEEE IoT J., 2021: 1-14.
- [7] Luo C, Zeng J, Yuan M, et al. Telco User Activity Level Prediction with Massive Mobile Broadband Data [J]. ACM Trans. Intell. Syst. Technol., 2016, 7(4): 63:1-63:30.
- [8] Wu F, Ren J, Lyu F, et al. Boosting Internet Card Cellular Business via User Portraits: A Case of Churn Prediction [C]//Proc. IEEE INFOCOM. 2022: 1-10.

## **附录 A (附录名称) (三号黑体, 加粗) (必要时)**

附录正文…… (格式参考正文)。换行示例。

## 攻读学位期间主要的研究成果

### 一、学术论文

- [1] **Daxia Mou**, Director, Someone. CSU Latex Template[J]. CSU player: 1(1):1-10. **(SCI 检索, JCR 1 区)**
- [2] Director, **Daxia Mou**, Someone, Someother. XXXXXX[J]. Transactions on Image Processing. **(SCI Under Review, JCR 1 区)**
- [3] Director, **Daxia Mou**, Someone, Someother. XXXXXX[J]. Transactions on Circuits and Systems for Video Technology. **(SCI Under Review, JCR 1 区)**

### 二、发明专利

- [1] 某大侠, XXX, XXX. 一种用 Latex 写中南大学学位论文的方法. 申请号: CN20190415xxxx, 公开号: CNXXXXXXXXXXA

### 三、主持和参与的科研项目

- [1] 国家自然科学基金面上项目《XXXXXXXXXXXXXX》, 项目编号: XXXXXXXX, 参与.

### 四、个人获奖情况

- [1] XX 金奖
- [2] XX 奖学金

## 致 谢

作者对给予指导、各类资助和协完成研究工以及提供种论文有作者对给予指导、各类资助和协完成研究工以及提供种论文有利条件的单位及个人表示感谢。  
致谢应实事求是，切忌浮夸与庸俗之词。