

硕士学位论文

数据驱动的互联网卡用户离网预测及干预 算法研究

Research on Data-Driven Churn Prediction and
Intervention Algorithm for Internet Card User

专业学位类别	电子信息
专业领域	计算机技术
作者姓名	钱凯
指导教师	吕丰教授

2023 年 5 月

中图分类号 TP391
UDC 004.9

学校代码 10533
学位类别 专业学位

硕士学位论文

数据驱动的互联网卡用户离网预测及干预 算法研究

**Research on Data-Driven Churn Prediction and
Intervention Algorithm for Internet Card User**

作者姓名 钱凯
专业学位类别 电子信息
专业领域 计算机技术
研究方向 数据挖掘和大数据处理
二级培养单位 计算机学院
指导教师 吕丰 教授

论文答辩日期 _____ 答辩委员会主席 _____

中南大学
2023年5月

学位论文原创性声明

本人郑重声明，所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了论文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得中南大学或其他教育机构的学位或证书而使用过的材料。与我共同工作的同志对本研究所作的贡献均已在论文中作了明确的说明。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

学位论文作者签名：_____ 日期：____年__月__日

学位论文版权使用授权书

本学位论文作者和指导教师完全了解中南大学有关保留、使用学位论文的规定：即学校有权保留并向国家有关部门或机构送交学位论文的复印件和电子版，允许本学位论文被查阅和借阅。本人授权中南大学可以将本学位论文的全部或部分内容编入有关数据库进行检索和公开传播，可以采用复印、缩印或其它手段保存和汇编学位论文。本人同意按《中国优秀博硕士学位论文全文数据库出版章程》规定享受相关权益。本人保证：毕业后以学位论文内容发表的论文作者单位注明中南大学；学位论文电子文档的内容和纸质学位论文的内容相一致。

延缓公开论文延缓到期后适用本授权书，涉密论文在解密后适用本授权书。

本学位论文属于：(请在以下相应方框内打“√”)

公开

延缓公开，延缓期限（____年__月__日至____年__月__日）

学位论文作者签名：_____

指导教师签名：_____

日期：____年__月__日

日期：____年__月__日

(填写阿拉伯数字)

数据驱动的互联网卡用户离网预测及干预算法研究

摘要：

互联网卡是最近通信运营商和互联网公司合作提出的一种新的商业模式，可以享受由合作互联网公司应用产生流量费用的大幅折扣或减免。然而，因为中国互联网卡市场竞争日趋激烈，需求逐步饱和等多种原因，用户离网/流失问题也日益严重，造成了较大的经济损失。为了全流程自动化高效地挽留住用户，本文针对互联网卡用户离网预测、离网原因推断和用户挽留问题展开研究。但是，要解决这些问题存在以下三个挑战：

- 1) 通信运营商的互联网卡用户规模较大，分布全国各地，异构特征显著，数据类型丰富，速度增长快，因此如何精准且全面地预测出其中潜在的离网用户成为了一个十分重要的挑战。
- 2) 互联网卡用户的离网原因高达上百种且只有少部分的离网用户有记录离网原因，如何在少量标注数据的情况下，如何合理、高效地表征用户离网偏好成为了一个棘手的挑战。
- 3) 由于缺乏用户干预交互记录，并且通信运营商等企业在实际干预过程中给予的预算往往是有限的。因此如何向预离网用户匹配合适的挽留措施，既能解决用户使用过程中的痛点，同时又不会让企业方付出过高的成本是一个极大的挑战。

为解决上述挑战，本文设计一种用户偏好感知的挽留框架(*UPRF*, *User Preference-Aware Retention Framework*)，具体而言，*UPRF*框架包含以下三部分内容：

- 1) 基于自注意力机制的互联网卡用户离网预测模块。首先对离网行为等做了详细的数据分析，接着从用户数据中分别提取了用户画像特征和序列特征，最后设计和实现了一种融合主成分分析算法和自注意力机制的互联网卡用户离网预测模型。
- 2) 基于排名加权归一化技术的离网偏好表征模块。首先抽取了5类能够被数据反映的离网原因，其次挑选了与这些离网原因相关的偏好特征，接着设计并实现了基于等频分箱的双重排名离散化算法，得到原始离网偏好向量，最后使用用户自适应权重归一化算法表征预离网用户的离网偏好。

3) 资源有限上下文的用户偏好感知挽留策略匹配模块。首先将挽留策略匹配问题建模成多臂老虎机问题，然后接收由上述模块给出的离网风险和离网偏好，使用基于领域知识的分布初始化奖励生成模型，最后训练基于资源有限上下文的偏好感知的挽留策略匹配算法。

最后，大量数据驱动的实验表明 *UPRF* 框架可以精准全面地预测潜在离网用户，有效提高挽留用户数和运营商收入总和。与最好的基准模型对比，其分别提升了 12%，25% 和 23%。此外，大量的健壮性测试也表明 *UPRF* 框架在不同参数设置的情况下都具有较好的性能表现。

图 38 幅，表 3 个，参考文献 112 篇

关键字：离网预测；用户偏好；用户干预；深度学习；强化学习

分类号： TP391

Research on Data-Driven Churn Prediction and Intervention Algorithm for Internet Card User

Abstract:

Internet card (IC) is a new business model proposed recently by the cooperation of cellular operators and Internet companies. Particularly, IC users can enjoy significant discounts or exemptions on target traffic budget, that generated by the applications of partner Internet companies. However, in China, because of the market of IC is becoming increasingly competitive, the demand of IC is gradually saturated, etc., the churn problem of IC user is getting worse which led to much economic loss. In order to automatically and efficiently retain users throughout the entire process, this paper conducts research on the churn prediction and the churn reason inference of Internet card users and the retention issues. Nevertheless, there are three challenges to addressing these issues:

1)The Internet card users of communication operators are relatively large, distributed all over the country, with obvious heterogeneous characteristics, rich data types and fast growth. Therefore, how to predict potential chunner of IC accurately and comprehensively has become a significant challenge.

2)There are hundreds of reasons for Internet card users to churn, and only a few users have recorded the reasons for churning. How to reasonably and efficiently represent the user's churn preference with a small amount of labeled data has become a thorny challenge.

3)Due to the lack of user intervention interaction records, and the budget given by companies such as communication operators in the actual intervention process is often limited. Therefore, how to match appropriate retention measures to pre-churners can not only solve the problems in the user's use process, but at the same time not make the enterprise pay too much cost is a great challenge.

To address these issues, we proposed a User Preference-Aware Retention Framework. Specifically, the *UPRF* framework includes the following three parts:

1) Internet card churn prediction module based on self-attention mechanism. We firstly makes a detailed data analysis on churn behavior, churn reason, etc. Then, the IC user’s portrait features and sequence features are extracted from the user data respectively. Finally, an Internet card user churn prediction model that combines principal component analysis algorithm and self-attention mechanism is designed and implemented.

2) Churn preference generation module based on ranking-weighted normalization technology. We firstly extracts 5 churn reasons that can be reflected by the data. Secondly, the preference characteristics that are more related to these churn reasons are selected. Then, a dual ranking discretization algorithm based on equal frequency binning was designed and implemented to present raw churn preference of pre-churners. Finally, the user-adaptive weight normalization algorithm is used to output the churn preference of the pre-churners.

3) User preference-aware retention strategy matching module in a resource-limited contexts. The retention strategy matching problem is firstly modeled as a multi-armed bandit problem. Then the strategy matching module receives the churn risk value given by the churn prediction module and the churn preference given by the churn preference generation module. Nextly, it initializes the reward generation model using a distribution based on domain knowledge. Finally, a preference-aware retention strategy matching algorithm in a resource-limited context is trained.

Last but not least, extensive data-driven experiments demonstrate the efficacy of *UPRF* in predicting potential IC chunner and raising number of reserved user and total revenue of mobile commnlications operator. Comparing to the best benchmark models, it imporved by 12%, 25% and 23%, respectively. Furthermore, comprehensive robustness testing shows that *UPRF* has good performance under different parameter settings.

Keywords: Churn Prediction; User Preference; User Intervention; Deep Learning; Reinforcement Learning

Classification: TP391

目 录

摘要	I
ABSTRACT	III
目录	V
插图索引	VIII
表格索引	X
第 1 章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	3
1.2.1 用户流失/离网预测	3
1.2.2 用户流失原因推断	4
1.2.3 用户干预与挽留	5
1.3 主要研究内容	6
1.3.1 互联网卡用户离网预测模型研究	6
1.3.2 预离网用户离网偏好表征算法研究	7
1.3.3 预离网用户挽留策略匹配算法研究	7
1.4 论文组织结构	8
第 2 章 相关理论概述	9
2.1 用户画像	9
2.1.1 用户行为	9
2.1.2 用户偏好	9
2.2 深度学习算法	10
2.2.1 循环神经网络	10
2.2.2 基于注意力机制的神经网络	11
2.3 强化学习算法	11
2.3.1 基于随机过程的多臂老虎机	12
2.3.2 基于上下文的多臂老虎机	12
2.4 本章小结	13

第3章 环境描述与系统概览	14
3.1 环境描述	14
3.1.1 平台描述	14
3.1.2 数据描述	15
3.2 UPRF 框架设计概览	17
3.2.1 挽留问题形式化	17
3.2.2 总体框架	18
3.2.3 数据输入输出规范	18
3.3 本章小结	19
第4章 基于自注意力的互联网卡用户离网预测模型设计	20
4.1 离网预测模块描述	20
4.2 数据分析	20
4.2.1 互联网卡趋势	21
4.2.2 离网时间分析	22
4.2.3 离网原因分析	22
4.3 特征工程	24
4.3.1 画像特征工程	24
4.3.2 时序特征工程	27
4.4 离网预测模型设计与实现	29
4.4.1 基于自注意力机制的编码算法	30
4.4.2 基于主成分分析算法的特征降维算法	31
4.4.3 基于多层感知机的分类器设计	32
4.5 实验评估与结果分析	32
4.5.1 实验设置	32
4.5.2 用户离网预测模型性能评估	34
4.5.3 参数影响	36
4.5.4 消融实验	39
4.6 本章小结	40
第5章 用户离网偏好感知的挽留策略匹配算法设计	41
5.1 离网偏好模块描述	41
5.2 离网偏好相关数据分析	41
5.2.1 离网原因与偏好的相关性分析	41

5.2.2 偏好特征双重排名离散化	43
5.3 离网偏好表征	44
5.3.1 加权表征离网偏好	44
5.3.2 不可信用户过滤机制	45
5.3.3 用户自适应权重归一化	45
5.4 挽留策略匹配模块描述	45
5.4.1 挽留策略匹配问题形式化	45
5.4.2 模块设计思想	46
5.4.3 挽留策略匹配问题建模	47
5.5 挽留措施匹配算法设计	48
5.5.1 奖励生成模型设计	48
5.5.2 基于汤普森采样的挽留策略匹配算法	50
5.6 实验评估与结果分析	50
5.6.1 实验设置	50
5.6.2 预离网用户干预框架性能评估	52
5.6.3 参数影响	55
5.7 本章小结	57
第6章 总结与展望	58
6.1 工作总结	58
6.2 未来工作展望	59
参考文献	61
攻读学位期间主要的研究成果	71
致谢	72

插图索引

图 1-1 某通信运营商现有干预流程示意图	2
图 1-2 论文组织架构图	8
图 3-1 大数据平台系统架构图	14
图 3-2 用户侧数据描述	16
图 3-3 挽留信息描述	16
图 3-4 用户挽留问题分解图	17
图 3-5 UPRF 框架总体示意图	18
图 4-1 离网预测模块示意图	20
图 4-2 互联网卡用户发展趋势图	21
图 4-3 互联网卡离网用户数量-日期热力图	22
图 4-4 互联网卡用户 Top10 离网原因分布图	23
图 4-5 互联网卡离网用户和正常用户账户余额对比图	24
图 4-6 月不同阶段的互联网卡用户平均消耗流量值对比图	25
图 4-7 互联网卡用户月 APP 使用频次对比图	25
图 4-8 互联网卡用户流量活跃熵对比图	26
图 4-9 互联网卡用户目标编码值对比图	27
图 4-10 互联网卡用户日流量记录条数序列对比图	28
图 4-11 互联网卡用户流量异常天数对比图	28
图 4-12 互联网卡用户离网预测模型架构	29
图 4-13 基于滑动窗口的离网预测模型实验设置图	32
图 4-14 离网预测模型总体性能对比图	35
图 4-15 互联网卡 Top-U 用户的分类指标性能对比图	36
图 4-16 探索性别参数影响的性能对比图	37
图 4-17 探索年龄参数影响的性能对比图	37
图 4-18 探索 APP 使用频次参数影响的性能对比图	38
图 4-19 探索套餐价格参数影响的性能对比图	39
图 5-1 离网偏好表征模块示意图	41
图 5-2 互联网卡用户所有离网原因示意图	42
图 5-3 互联网卡用户可建模的离网原因示意图	42
图 5-4 挽留策略匹配模块图	47
图 5-5 奖励模型内部示意图	49
图 5-6 匹配算法性能对比图	53

图 5-7 挽留框架总体性能对比图	53
图 5-8 匹配算法商业指标性能对比图	54
图 5-9 不同先验分布下的匹配算法性能对比图	55
图 5-10 城市参数对于匹配算法性能影响的对比图	56
图 5-11 年龄参数对于匹配算法性能影响的对比图	56
图 5-12 离网风险参数对于匹配算法性能影响的对比图	57

表格索引

表 4-1 消融实验	39
表 5-1 离网原因耦合分析表	43
表 5-2 离网原因-偏好特征对应表	43

第1章 绪论

1.1 研究背景与意义

随着蜂窝网络(如4G和5G)的快速发展，间歇性的无线连接和有限的数据速率不再是为用户提供沉浸式互联网体验的瓶颈^[1]。与此同时，为了充分释放用户的互联网兴趣，网络游戏、高清媒体播放、短视频平台、高清地图、虚拟现实(VR)和增强现实(AR)等大量杀手级应用正在丰富本文的日常生活^[2-5]。因此，移动用户现在更沉迷于互联网服务，而不是传统的点对点通信功能，这产生了越来越大的互联网流量。根据思科年度报告^[6]，到2023年，5G连接产生的流量将是4G连接的近3倍，占移动连接总量的10.6%。这意味着用户将通过手机、pad、5G等不同的移动设备或网络模式消费越来越多的数据。因此，通信运营商们正在寻求不同的商业模式，以应对用户对流量消费需求的爆炸式增长。

通信运营商试图通过设计不同的商业模式来吸引用户，以满足用户对互联网流量的爆炸性需求。互联网卡(Internet Card/IC)是最近移动通信运营商和互联网公司合作提出的一种新的商业模式。特别是与传统卡(Tradition Card/TC)相比，互联网卡用户可以享受由合作互联网公司应用产生流量费用的大幅折扣或减免。此外，与传统卡业务相比，互联网卡中可以用于所有互联网服务的定向流量包通常具有更低的价格和更高的流量上限。由于这些优势，互联网卡业务迅速吸引了大量用户。例如，根据本文的数据集可知，在中国的一个省份，每月新增互联网卡用户的数量就可以达到10万以上。随着传统卡业务的饱和，新用户减少，互联网卡用户的爆炸性增长可以通过生产新手机、制造更多卡、降低运营成本、提供额外服务等创造一个巨大的业务市场。

然而根据数据分析，本文发现如果互联网卡用户对套餐福利不满意，他/她们很可能会流失，从而导致巨大的收入损失。因此，研究互联网卡用户特征，设计有效的预测模型，提前寻找潜在离网用户，推断其离网原因，匹配合适的挽留策略，防止这部分用户离网成为当务之急。在文献中，已有一些针对蜂窝网络中的用户使用模式和行为建模的研究^[7-12]，但这些研究针对的是传统卡用户，与本文针对互联网卡用户的目标有较大差异。另一方面，用户流失/离网预测问题也在^[13, 14]等其他领域得到了研究。基于传统卡用户的行为分析和建模，提出了许多针对传统卡用户的预测模型，但由于传统卡用户使用特点不同，无法直接应用于互联网卡用户离网预测。此外，这些模型通常依赖机器学习技术进行预测，可能无法从多维用户特征中捕捉到潜在的相关性，导致预测性能不佳。

另外，本文也发现仅仅通过提供给通信运营商以离网预测用户名单的方式，

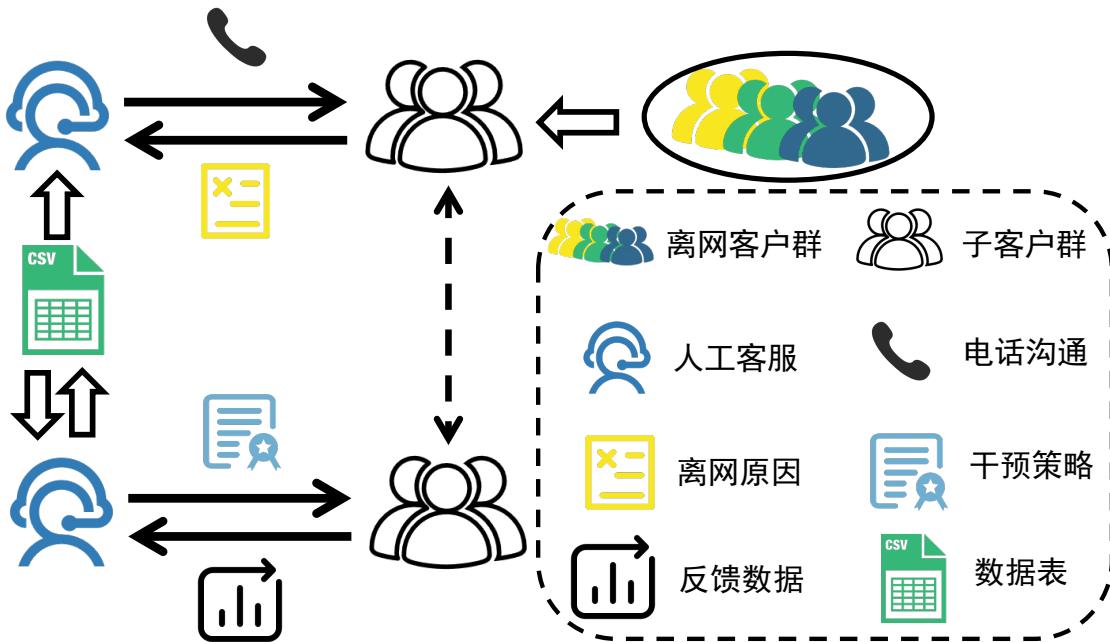


图 1-1 某通信运营商现有干预流程示意图

并不能充分解决运营商挽留潜在离网用户的问题。图1-1展示了某个通信运营商现有干预/挽留用户的流程：

- 1) 通过数据查询等手段获取上月离网用户群。
- 2) 由于预算有限，运营商不得不根据某个准则选择一个子离网用户群。
- 3) 然后人工客服通过用户预留的联系方式，依次拨打给相应的离网用户。先是了解用户的离网原因，然后采取相应话术/挽留策略来挽留用户。
- 4) 最后人工客服记录用户的离网原因，采取的对应挽留策略，用户的相应反馈数据和干预时间等信息到相应的数据表中。

可以观察到这样的流程会存在三个缺点。分别是

- 1) 通信运营商无法预测哪些互联网卡用户是否离网。因此，当人工客服去干预的时候，用户可能已经离网了。这种方式具有相当的延后性。
- 2) 通信运营商无法推断互联网卡用户的离网原因，只能事后调研和记录。
- 3) 因为无法推断互联网卡用户的离网原因，通信运营商无法匹配相应的挽留策略以及时地挽留住用户。

因此，本文的研究关注于设计和实现一个集离网预测模块，离网偏好表征模块，挽留策略匹配模块于一体的互联网卡用户挽留框架，用以解决以上现有通信运营商存在的问题，但不止于这一种应用场景，并且约定了每一个模块的数据输入输出规范，从而使得本文提出的互联网卡用户挽留框架能够泛化到其他领域或者应用场景中。

但是，要设计并实现这样一种互联网卡用户挽留框架存在着诸多挑战。首先，

通信运营商的互联网卡用户规模较大，分布全国各地，异构特征显著，数据类型丰富，速度增长快，处理速度要求高。因此，数据的广泛性、多样性、异构性给数据分析、特征提取、智能预测模型设计等数据智能过程带来诸多挑战；然后互联网卡用户的离网原因高达上百种且只有 2.5% 的离网用户有记录离网原因，如何在极少量标注数据的情况下，如何合理、高效地表征用户离网偏好成为了一个棘手的挑战；最后由于缺乏用户干预交互记录，并且往往通信运营商等企业在实际干预过程中给予的预算是有限的，因此如何向预离网用户匹配合适的挽留措施，既能解决用户使用过程中的痛点，同时又不会让企业方付出过高的成本，以至于“得不偿失”，是目前用户干预/挽留领域中一个相当重要的待解决问题。

1.2 国内外研究现状

目前，通信，社交应用等领域中的用户流失和挽留问题已经成为了国内外学者研究的焦点。因此本节首先对不同应用场景的用户流失问题和解决方案进行了总结介绍，随后引出了关于用户离网原因推断的文献调研。最后，本节对用户干预与挽留的研究现状进行了介绍，以指导互联网卡用户挽留框架的设计。

1.2.1 用户流失/离网预测

用户流失/离网预测是指通过分析用户行为和历史数据，预测哪些用户可能会放弃使用某个产品或服务。这个问题在业界和学术界中都引起了广泛的关注和研究。

流失/离网预测问题在以下等领域进行了研究^[15-18]，如通信^[19]、社交应用^[20]、网络游戏^[21]、金融服务^[22]等。例如，文献 [23] 提出了一个通用框架，通过使用因果视角来建模用户流失预测的社会影响，这可以显著提高预测性能。Verbraken 等人 [13] 通过定义预期最大利润准则，提出了一个成本效益分析框架来解决用户流失问题。为了降低电信运营中的用户流失率，文献 [24] 通过分析 OSS 和 BSS 数据，提出了一种采用集成方法 (LIBFM 和 GBRT) 的用户流失预测系统。文献 [25] 通过分析 Snapchat 的用户行为数据，设计了一个连贯而健壮的框架，用于可解释的新用户聚类和流失预测，该框架可以使用深度学习算法准确预测流失用户。文献 [26] 设计了一个端到端神经网络 (ChurnPred)，利用用户在游戏中的行为和登录行为来解决在线游戏场景中的流失预测问题。此外，ChurnPred 可以通过使用 LSTM 算法捕捉活动序列的演变，并通过使用时间感知的过滤方案捕捉用户在游戏中的行为。为了减少在线游戏场景中的用户流失，文献 [27] 开发了一个难度感知框架 (DAF)，该框架可以通过使用难度相关特征来捕捉用户的个性化感知难度 (PPD) 和动态难度影响 (DDI)。此外，DAF 还可以在网络游戏场景

中提高用户留存率和动态调整难度。在空间众包 (SC) 场景下, 文献 [28] 提出了两阶段框架, 利用 LSTM 模型和历史数据提取员工流失预测阶段, 利用贪婪算法和 Kuhn-Munkras 算法实现任务分配的优化。文献 [29] 开发了一个流失预测系统, 通过对用户移动通信网络和地理位置的用户行为建模来预测新的迁移者。文献 [30] 开发了一种框架, 通过学习人类玩家的行为模式, 生成类似人类的动作序列进行训练, 从而模拟 RPG 用户的行为, 可以避免用户在游戏场景中大幅流失。

国内对于用户流失的研究大多集中在电信领域。比如文献 [31] 把 OSS 数据与 BSS 数据相结合, 使用基于图论、NLP、自动编码神经网络等原理的方法提取了相关特征, 改进了客户流失预测模型以获得最大期望利润。文献 [32] 针对互联网行业的用户流失预测问题, 提出了一种基于自助采样的 Stacking 集成学习方法 (BS-Stacking), 利用类滑窗的方式进行数据的扩充和特征提取。文献 [33] 将神经网络的算法跟实际电信业务问题相结合, 按照跨行业的数据挖掘流程 CRISP-DM, 使用 BP 神经网络建立客户的流失预测模型, 并将 BP 神经网络算法成功移植到了 Hadoop 平台上。文献 [34] 通过对用户通信行为的分析, 提出一种基于改进 GA-BP 的移动用户流失预测算法: 用改进的遗传算法对 BPNN 的权值和阈值进行初始化, 从而提高预测模型的准确率。文献 [35] 基于客户的历史数据和短期偶发数据, 提出了链型数据挖掘方法, 并结合决策树, 形成了一个综合的链型树分类器 (Chain Tree Classifier, CTC) 和用户行为预测模型。文献 [36] 对信息用户流失分析中的相关问题展开了研究, 建立了基于客户价值的流失预测模型。

然而, 由于通信运营商数据规模较大、时空特征以及用户离网行为的不确定性, 上述方法无法直接应用于互联网卡用户流失, 这也是本文研究的动机。此外, 我们从多维的互联网卡用户行为中提取相关特征, 并设计了一种深度学习模型来解决通信运营商系统中的用户离网预测问题。

1.2.2 用户流失原因推断

用户流失是企业面临的一个重要问题, 对于企业而言, 了解用户流失的原因可以帮助其改善产品和服务, 提高用户满意度, 进而减少用户流失。例如, 文献 [37] 指出, 确定用户流失的最重要原因可以提高对预测模型的理解, 同时节省大量费用和计算时间。因此, 流失原因推断也是一个备受关注的问题。以下是目前的研究现状。

文献 [38] 认为人们可以将流失用户分为三类, 包括随之对应的风险: 价值用户、个人用户和非付费用户。价值风险包括任何与公司服务相关的东西, 比如对糟糕服务的反应, 产品或服务的价格, 以及产品或服务的质量。这些风险都在公司的控制之下, 因此被定义为可控流失, 同文献 [39] 所描述的一致。个人风险包

括公司无法控制的所有风险，如移民或死亡。拒付风险包括与拒付有关的所有风险，例如滥用或盗窃产品或服务。个人风险和拒付款风险结合起来可被认为是不可控风险。

预测合同终止的原因还具有广泛的管理意义。正如文献 [40, 41] 所提到的，公司预测的总流失率足以评估一个组织的财务健康状况和用来估计用户群的价值。与此同时，有责任降低流失率的经理需要对用户流失的情况做出反应，即为具有高流失率倾向的用户提供正确的报价^[42]。例如，如果预期用户可能会因为服务相对较高的价格而流失，经理可以为该用户提供更有吸引力的产品，以更优惠的价格留住该用户。如果经理能够在用户计划终止合同之前这样做，经理将降低整体流失率。

我们可以发现，上述关于用户流失原因的国内外研究缺少表征用户离网偏好的方法，技术，模型等解决方案。因此本文提出的用以表征潜在流失用户对于不同离网原因权重偏好的离网偏好表征模块具有较为重要的研究意义。

1.2.3 用户干预与挽留

用户干预和挽留是指企业或组织在面临用户流失的情况下，采取一系列措施来挽回用户或让用户改变决策的过程。在互联网和移动应用的发展中，用户干预和挽留已经成为了重要的用户留存策略。目前，关于用户干预和挽留的研究已经逐渐成为了学术研究的热点之一。

部分研究关注于选择哪一部分用户进行挽留。比如，有些研究会考虑用户在公司社交网络中的位置。从社会的角度来看，一个有很多联系人的用户，或者与那些自己沟通密切的用户有很高的联系，可能是非常有价值的，因为他/她的背叛可能会导致其他人流失。比如一个新兴的研究机构正在考虑社交连通性对留存率的影响 [43, 44]。这种情况的适用程度可能取决于网络成员之间的连通性^[45]。但是在社交网络中处于中心位置的人流失的风险更低，因为离开的社会成本更高^[46]。由于个人倾向于与其他类似的人在社交网络中交往，高利润率的用户可能会对彼此产生强烈的影响，这进一步增加了锁定高客户生命周期价值 (CLV) 用户的价值。

部分研究会考虑哪些用户是值得瞄准的。因为用户挽留的目标是最大化用户生命周期价值 (CLV)，所以最容易保留的用户可能不是最有价值的用户。并且留住用户的一次性成本可能会超过用户的生命周期价值。Neslin 等人 [47] 在计算留存活动盈利时考虑了这一点。然而除此之外，挽留可能会带来长期成本，例如降低价格，从而降低用户的生命周期价值。Lemmens 和 Gupta^[48] 强调了在决定目标对象时考虑用户生命周期价值的重要性。事实可能会证明，可以留住的用

户并不值得公司为留住其而付出的成本，因此，公司应该让此类用户流失。

国内针对用户干预和挽留的研究也较少，主要开展的都是定性和理论分析的研究。比如文献[49]先从电信业、金融业、电子商务等行业分析了客户流失原因分析与评估行业案例，又分别分析了集中于基于定性/定量分析的客户挽留措施研究，提出了基于成本等多维约束的定量流失挽留的研究相对较少的观点。文献[50]以国内运营商作为研究主体，客观、深入分析用户流失与用户个人属性、订购属性、消费行为的关联关系，同时结合机器学习随机森林算法，对用户是否存在转网风险进行预测，并针对存在的潜在转网风险制定相应的应对策略。

针对上述研究中针对的焦点和未能解决的问题，本文试图构建一个能够在资源有限（如预算等）的上下文中，能够感知用户偏好的挽留模块，以一种性价比优先的方式在识别出的潜在离网用户群中挽留尽可能多的真实预离网用户。即将未来的客户生命周期价值与所需投资（即 $\Delta CLV/\Delta Investment$ ）结合起来，向具有较高离网风险的用户匹配合适的挽留策略，以便在解决预离网用户使用过程中痛点的同时，挽留对企业方来说较为重要的客户群。

1.3 主要研究内容

1.3.1 互联网卡用户离网预测模型研究

随着现代通信技术的快速发展，移动通信领域用户可以通过购买互联网卡从而以较低的价格就可以享受到优质的服务。但是中国的互联网卡市场竞争日趋激烈，需求逐步饱和，原有用户的离网问题也日益严重。互联网卡用户会因为套餐不满意、不愿使用异地号卡、网速不行等原因就离网。而发展新的互联网卡用户成本在 200 元左右，是维持一个老用户成本的 4 到 5 倍。有研究表明，一个公司如果将用户流失率降低 5%，就能增加 25% 至 85% 的利润。因此控制互联网卡用户离网是关系各大通信运营商未来生存和发展的一个关键问题。而互联网卡用户离网预测模块作为用户关系管理（CRM）方法和本文提出的互联网卡用户干预框架 UPRF 的一部分，能够有效帮助公司减少用户的流失，对公司增加营收和提高竞争力有重要意义。基于以上的问题和挑战，本文构建一个基于用户画像的互联网卡用户离网预测模型，旨在为通信运营商提供超前的预离网用户名单，以使得相关部门有足够的时间对这部分用户进行挽留。互联网卡用户离网预测模块将基于通信运营商给予的用户信息、流量记录、通话记录、APP 记录、停机记录等多维度数据，使用特征工程提取能够区分正常用户和预离网用户之间的特征，然后设计基于监督学习的深度学习模型，最后在每个月初给相关通信运营商输出当月的预离网用户名单以及他/她们各自的离网风险概率。

1.3.2 预离网用户离网偏好表征算法研究

当前有些运营商为了解决用户离网问题，也部署了一些简单算法/模型到实际生产环境当中，但是仅仅知道有哪些用户会在下个周期离网对于最终挽留住预离网用户也是不足的。其根本原因在于运营商们无法感知到他们的互联网卡用户是因为什么原因而流失的，从而无法对症下药。基于本文数据分析的结果，用户的离网原因会高达上百种，且往往会因为多种原因的叠加而导致用户放弃使用互联网卡。基于以上挑战和研究意义，本文设计和实现了一种表征互联网卡预离网用户的离网偏好表征算法。其中互联网卡预离网用户是指由互联网卡用户离网预测模块判定给出的超过某个阈值的潜在离网用户。首先本文会对离网原因分类，分成可以被数据反映的几个类别，然后基于相关性挑选和离网原因较为正相关或者较为负相关的偏好特征，再使用基于等频分箱的排名加权算法表征预离网用户的原始离网偏好，接着通过不可信用户过滤算法，将不活跃的预离网用户删去，使得有限的预算得到充分利用，最后设计实现了用户自适应的权重归一化方法，得到互联网卡预离网用户的离网偏好。

1.3.3 预离网用户挽留策略匹配算法研究

由于现阶段运营商的营销部门的挽留策略/措施设计得较为粗糙，例如充送话费、送通用流量/定向流量和通话时长等粗粒度挽留措施，无法为每个用户进行定制个性化的挽留措施，导致即使提早知道了预离网用户名单，也无法通过较低的挽留成本甚至无法将预离网用户留存下来。另外由于大多数用户都拥有两张手机卡，而互联网卡通常作为上网的副卡存在，因此有部分用户只有当主卡的流量消耗完之后才会使用副卡上网，导致互联网卡的使用活跃度较低。当营销部门联系这部分非活跃用户时接通率较其他预离网用户而言相当低。此外，营销部门还希望知道用户偏好来根据用户偏好进行精准的挽留措施匹配。基于以上三个挑战，本文提出构建一个感知用户偏好的挽留措施匹配算法，旨在为通信运营商提供精准的基于用户个性化的挽留措施，使得电信运营商在相同的预算下获得最大的回报和收益。基于用户偏好的挽留策略匹配算法将基于用户信息、流量记录、离网用户原因回访记录、APP 记录等多维度数据，感知用户的多维度偏好以及潜在离网原因偏好，然后基于强化学习和领域知识对每个用户提供一个或多个匹配的挽留措施，以匹配度高低排序，配合基于用户画像的互联网卡用户离网预测模型，在每个月月初给通信运营商输出当月的预离网用户名单以及他们各自的离网偏好以及适宜的挽留策略。

1.4 论文组织结构

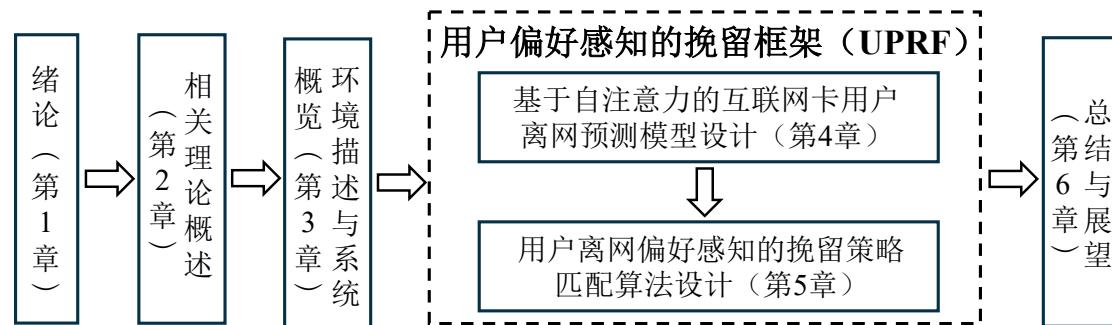


图 1-2 论文组织架构图

如图1-2所示，论文的主要研究内容包括离网预测、离网偏好推断和用户挽留，论文内容一共分为6章，后续章节的结构安排如下：

第2章对相关理论进行概述，包括用户画像、深度学习算法和强化学习算法。

第3章对本文所处的环境配置和所使用的数据情况进行了描述，然后形式化了用户挽留问题，阐述了URPF框架的设计思想和应用场景。

第4章对离网预测模块进行阐述，其中分为数据分析，特征工程，模型架构(ICCIP)设计与实现和针对离网预测模块进行的实验评估与结果分析。

第5章基于第4章给出的预离网用户集合表征对应的离网偏好，再形式化挽留策略匹配问题，然后在本文互联网卡的场景中，设计了ICSM算法并给出了离线训练过程，最后对挽留策略匹配模块进行了实验评估与结果分析。

第6章对全文工作进行总结，对下一步工作进行展望。

第2章 相关理论概述

本章将对相关理论技术做简要介绍。首先介绍用户行为和偏好，随后介绍循环神经网络和基于注意力的神经网络这些先进的深度学习算法，最后介绍强化学习基础概念与多臂老虎机的定义和分类。

2.1 用户画像

2.1.1 用户行为

以前大多数关于用户行为的研究工作都试图发现潜在的用户模式^[11, 51–55]。特别地，文献 [56] 提出了一种自动将用户应用程序日志划分为任务单元的方法，并通过使用用户 APP 使用模式将识别的问题建模为分类问题。为了发现共享汽车系统中的用户行为模式，文献 [13] 采用了定性和定量相结合的综合用户行为分析方法。在这种情况下，用户行为模式的发现可以指导在线汽车共享系统的汽车开发。为了研究移动应用的长期使用演变过程，文献 [57] 研究了 2012 年至 2017 年移动应用的使用模式，并提供了应用类别中用户行为的各种事实，可以帮助应用开发和开发者。为了提高阿里巴巴展示广告系统的点击率预测性能，文献 [58] 提出了一种多通道用户兴趣记忆网络 (MIMN) 架构，利用长顺序行为数据发现用户兴趣。此外，文献利用 UIC 模块和 MIMN 架构设计了一种协同设计方案，解决无限长度序列行为数据的用户兴趣建模问题。Luo 等人^[59] 研究了用户的时空特征，通过获取电信运营商的历史 MBB 数据来预测用户的活动水平，并提出了一种快速可扩展的在线期望最大化算法来提取紧凑的用户行为特征。论文 [10] 提出了一个应用程序使用预测系统，利用具有大规模移动数据访问记录的 POI 预测位置级应用程序使用情况，可以为操作系统和应用程序市场商店提供有用的启示。为了提高应用程序使用预测的准确性，文献 [52] 通过引入 APP 注意机制和基于 top-k 的损失函数，提出了一个框架 (AppUsage2Vec)。文献 [60] 提出了一个上下文感知的多任务学习框架 (DeepApp)，通过使用时空上下文和用户行为来预测应用程序的使用情况。文献 [61] 提出了一种队列模型来增强应用程序类别使用预测，目的是解决冷启动问题，提高应用程序使用类别的准确性。文献 [62] 提出了一种行为感知的群体检测系统，该系统结合用户移动信息和智能手机使用行为，通过使用新功能发现使用模式。

2.1.2 用户偏好

用户偏好分析是了解用户行为的有效方法，广泛应用于用户分析、用户流失、模型预测^[63–68] 等不同场景。Liu et 等人 [24] 提出了一种系统的统计分析，通

过收集到的 App 管理日志来预测用户的偏好，可以反映用户对 App 使用的态度。为了利用用户偏好和同行伙伴对人类移动性的影响，文献 [65] 提出了一个 JEPPI 框架，该框架通过引入等效强调度量方法来考虑同址和同访问行为。为了研究仅利用用户偏好来检测假新闻的局限性，文献 [69] 提出了一种 UPFD 框架，该框架结合内容建模和图形建模来捕捉不同的信号。在推荐系统中，文献 [52] 提出了一种及时推荐系统 (TimelyRec) 来预测感兴趣的项目，该系统使用了在时间感知场景中用户偏好的异构时间模式的定义唯一特征。为了研究特定场景和用户历史行为的局限性，文献 [61] 提出了一个元学习的特定场景兴趣网络，通过使用多个独立的模块来捕获感兴趣的项目来预测用户的偏好。在论文 [63] 中，文献通过分析移动场景下的阅读行为日志，发现点击信号并不总是与用户偏好一致。此外，本文提出偏好预测模型，综合考虑用户行为、新闻质量和交互上下文，预测用户对点击条目的实际偏好。Gao 等人 [70] 通过考虑多回合对话上下文和用户偏好的历史记录，提出了偏好增强的表情响应选择器 (PESRS) 模型，可以向用户推荐合适的表情。然而，这些工作主要是通过分析用户行为来研究传统卡用户的使用模式，这与本文对互联网卡用户的目标有很大的不同。此外，目前还没有对通信运营商互联网卡用户画像特征的研究，这将无助于运营商发现潜在的离网用户。

2.2 深度学习算法

深度学习是一种分层计算模型，能够学习数据的多级抽象表示^[71]。它使用反向传播算法来训练其参数，该参数可以将原始输入转换为有效的特定于任务的表示。深度学习中有几种著名的深度架构：卷积神经网络 (CNN)、循环神经网络 (RNN)、生成对抗网络 (GAN) 和基于多头自注意力机制的神经网络 (Transfomer)^[72-74]。

2.2.1 循环神经网络

循环神经网络 (RNN) 是一种处理序列数据的神经网络架构^[75, 76]。不像深度前向神经网络架构（比如，DBN，SAE 和 CNN 等），它不仅将输入模式映射到输出结果，而且通过采用隐藏单元之间的连接将隐藏状态转移到输出^[77]。通过使用这些隐藏的连接，循环神经网络 RNN 建模了时间依赖性，这导致了沿时间维度的对象之间的参数共享。它已被应用于各个领域，如语音分析^[78]，图像分析^[79] 和语言翻译^[80] 等，取得了优异的性能。

与深度前向神经网络架构类似，其计算也包括正向传递和反向传播阶段。在正向传递计算中，RNN 同时接受输入和隐藏状态。在反向传播计算中，它使用反向传播-时间算法通过时间步长来反向传播损失。

一些著名的 RNN 变体已经取得了令人印象深刻的性能^[81]。例如，为了模拟序列数据的双向依赖关系，Schuster 和 Paliwal 提出了双向 RNN，其中有两个独立的计算过程，分别编码向前依赖关系和向后依赖关系^[82]。另一个具有代表性的变体是长短期记忆网络 LSTM。该变体可以有效地打破了标准 RNN 架构不能通过引入内存块来很好地建模长时间依赖的限制^[83]。为了加快 RNN 的训练速度，Lei Tao 等人提出了一种轻量级循环单元 light recurrent unit，其中轻量级循环组件用于计算纠缠状态的依赖项，并引入公路网组件，从而可以自适应地组合输入和状态^[84]。Jang Myeongjun 等人设计了语义变分循环自编码器，以句对句的方式对全局文本特征建模^[85]。深度循环神经网络由几个循环连接的递归隐藏层堆叠而成。因此，它可以捕获对象方向的深度特征，以及沿着时间方向的深度特征。

2.2.2 基于注意力机制的神经网络

模仿人类注意力的想法首先出现在计算机视觉领域^[86]，文献 [87] 试图通过引入仅关注图像的特定区域而不是整个图像的模型来降低图像处理的计算复杂度，同时提高性能。虽然，本文今天所知道的注意力机制的真正起点通常被认为起源于自然语言处理领域^[88]。Bahdanau 等人^[88] 在机器翻译模型中实现了注意力，以解决循环神经网络结构的某些问题。在 Bahdanau 等人^[88] 强调注意力的优势之后，注意力技术得到了改进^[89]，并迅速流行于各种任务，如文本分类^[90, 91]，图像描述^[79, 92]，情感分析^[91, 93] 和语音识别^[94–96]。

注意力已经成为深度学习中的一种流行技术，原因有几个。首先，包含注意力机制的模型在所有前面提到的任务和许多其他任务中获得了最先进的结果。此外，大多数注意力机制可以与基础模型联合训练，例如使用常规反向传播的循环神经网络或卷积神经网络^[88]。此外，注意力将某种类型的解释引入神经网络模型^[79]，这些模型通常被认为是非常复杂的解释。此外，在引入 Transformer 模型^[74] 之后，注意力机制的普及程度进一步提高，这进一步证明了注意力的有效性。注意力最初是作为循环神经网络的扩展引入的^[97]。然而，文献 [74] 中提出的 Transformer 模型在注意力研究中取得了重大进展，因为它表明注意力机制足以构建最先进的模型。这意味着可以避免缺点，例如循环神经网络特别难以并行化的事。与引入原始注意力机制^[88] 的情况一样，Transformer 模型是为机器翻译创建的，但很快被用于其他任务，如图像处理^[98]，视频处理^[99] 和推荐系统^[100]。

2.3 强化学习算法

许多实际应用实际上都是序列决策问题，因此可以建模成强化学习中的多臂老虎机问题。具体来说，智能体必须从几个备选方案中选择最好的方案。此类应用

程序的示例包括临床试验^[101, 102] 推荐系统和异常检测^[103]。在某些情况下, 辅助信息/上下文, 每个动作(例如, 用户画像)和反馈/奖励是有限的。例如, 在临床试验^[101], 上下文是病人的医疗记录(例如, 健康状况、家族史等), 动作对应治疗方案, 奖励代表治疗的结果(例如, 成功或失败)。在这种情况下, 影响长期利益的一个重要方面是在探索(例如, 尝试一种新药)和利用(选择迄今为止最知名的药物)之间找到一个良好的平衡。

2.3.1 基于随机过程的多臂老虎机

探索与利用之间的这种内在权衡存在于许多序列决策问题中, 一般被表述为多臂老虎机(MAB)问题, 具体表述如下: 给定 K 个可能的动作或拉杆, 每个动作都与一个固定但未知的奖励概率分布^[104, 105] 相关联, 在每次迭代时(时间步), 智能体选择一个拉杆来玩并接收奖励, 从各自拉杆的概率分布中采样, 并且独立于之前的动作。智能体的任务是学习如何选择其行动, 以便随着时间的推移累积奖励最大化。请注意, 智能体需要尝试不同的拉杆来学习它们的奖励(即探索收益), 并使用这些学习到的信息来获得最好的收益(利用学习到的收益)。探索与利用之间存在一种天然的平衡。例如, 每只拉杆只尝试一次, 然后永远使用其中最好的一个, 当拉杆的奖励不确定时, 通常可能会导致高度次优的解决方案。基于随机公式^[104–106] 和贝叶斯公式^[107], 对该问题提出了不同的解决方案; 然而, 这些方法没有考虑到智能体可用的上下文或侧面信息。

值得注意的是, 多臂老虎机问题可以被视为强化学习的最简单形式, 其中智能体是无状态的。当系统不是无状态时, 操作会导致状态的变化, 并且奖励也取决于状态。因此, 在一般的强化学习中, 不同步骤中的奖励不是相互独立的。事实上, 强化学习(带状态)的经典算法经常使用多臂老虎机问题的解决方案作为(一般)强化学习中定义策略的子例程。例如, 多臂老虎机问题中众所周知的 ϵ -贪心算法经常与 Bellman 动态规划算法结合用于强化学习, 以定义行动的选择。此外, 许多强化学习算法在应用于无状态系统时, 会简化为多臂老虎机算法。

2.3.2 基于上下文的多臂老虎机

多臂老虎机(MAB)的一个特别有用的版本是上下文多臂老虎机(CMAB), 或者简单地说, 上下文老虎机, 在每次迭代中, 在选择一个拉杆之前, 智能体观察一个 n 维的上下文或特征向量。智能体使用这个上下文, 以及过去所玩拉杆的奖励, 来选择在当前迭代中玩哪个拉杆。随着时间的推移, 智能体的目标是收集足够多的关于上下文向量和奖励之间关系的信息, 这样它就可以通过查看当前上下文^[108, 109] 来预测下一个最佳的动作。针对一般情况, 提出了不同的算法, 包

括 LinUCB^[110], Neural Bandit^[111] 和上下文汤普森采样 (CTS)^[109]，其中通常假设行动的预期奖励与其上下文之间存在线性依赖。

2.4 本章小结

本章介绍了相关理论技术，包括用户画像技术，深度学习算法和强化学习算法技术，随后对基于注意力机制的神经网络和基于上下文的多臂老虎机作简要介绍，为下文展开做铺垫。

第3章 环境描述与系统概览

本章主要介绍本文所处的环境条件，包括使用的平台架构，数据字段和相应规模等。接着本章将介绍如何建模互联网卡用户挽留问题，并设计以了一种用户偏好感知的挽留框架（UPRF，User Preference-Aware Retention Framework），然后约定了每个模块和子模块的数据输入输出规范，以期望 UPRF 框架能够泛化到尽可能多的应用场景当中。

3.1 环境描述

3.1.1 平台描述

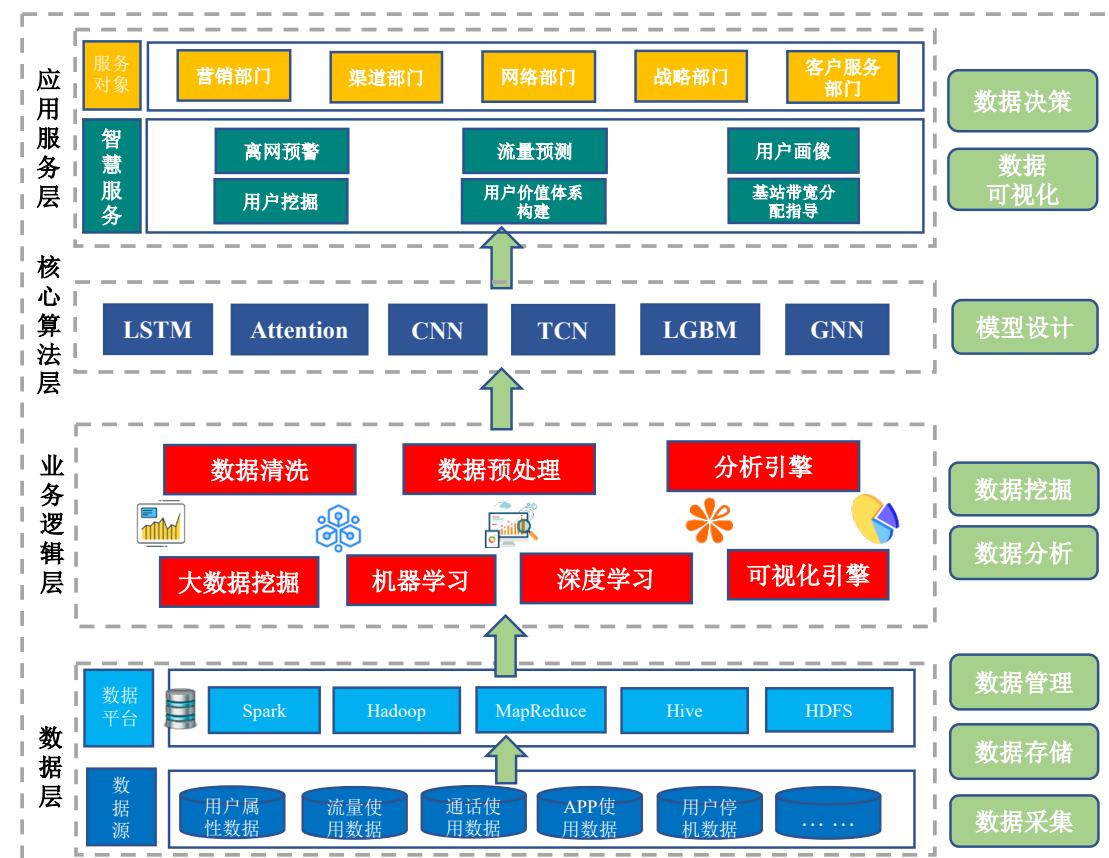


图 3-1 大数据平台系统架构图

运营商们每天都会生产和存储巨量的数据，其中分为业务支持系统（BSS）和运营支持系统（OSS），这两者也构建了大数据平台的底层，从而用来提升业务和运营表现。具体来说，图3-1展示了流量运营商的大数据平台架构，其中包括数据层、业务逻辑层、核心算法层和应用层。

首先是数据层，数据层主要是承担数据采集、数据存储和数据管理的功能。

首先从数据源中保存来自业务支持系统（BSS）和运营支持系统（OSS）的多维度数据，包括用户属性数据、用户流量使用数据、用户CDR数据、用户APP数据等。然后通过数据操作工具来做这些数据做周期性的更新、修改和删改工作从而提供给上层做其他工作。其中，Hadoop分布式文件系统（HDFS）通过分布式硬件平台来提供基础的数据存储功能。Hive/Spark SQL则是提供数据查询、清洗、过滤等功能，尤其是提高了针对海量数据的开发和处理效率。而MapReduce则是提供大数据的并行计算范式从而缩短数据处理时间。

然后是业务逻辑层，这层主要为不同的业务部门提供数据分析、挖掘和建模功能。举例来说，其中包括数据预处理、统计分析、特征工程、机器学习等模块。

接着是核心算法层，主要是实现一些机器学习和深度学习模型的核心算法，其中包括针对表格型数据的轻度梯度提升机（LGBM）和多层感知机（MLP）等模型，针对序列数据的长短期记忆网络（LSTM）、时域卷积网络（TCN）、基于自注意力机制的深度神经网络（Transformer）等模型，针对图像的卷积神经网络（CNN）、自注意力视觉神经网络（ViT）等模型。

最后是应用层，主要是提供经过开发人员开发和封装好的全流程自动的应用程序，为下游的营销部门、渠道部门等提供用户画像、离网预警等功能。

3.1.2 数据描述

首先，本文来描述一下用户侧数据，如图3-2所示。

时间范围：本文拥有2020年4到6月，11月到12月和2021年1到2月的7个月的数据。

用户类型：本文过滤掉了政企用户、家庭用户和其他用户，只留下互联网卡个人用户。

数据规模：在这7个月的数据中，一共有400万的互联网卡个人用户，400万条以月为粒度的属性表记录，35亿条以次为粒度的CDR（通话细节记录）表记录，400亿条以次为粒度的流量表记录，4亿条以月为粒度的APP（应用程序）表记录，1000万条以次为粒度的停机表记录。其中属性表记录的为用户属性数据，而其他四个表记录的为用户行为数据，尤其是流量表和CDR表的数据尤为珍贵，能够刻画用户的序列行为。但是从另一方面来说，如此海量的数据也给数据分析和模型训练推理带来了极大的硬件资源开销和方法性能要求。

接着，本文来描述挽留信息，如图3-3所示。

时间范围：本文拥有2020年11月12月和2021年12月的4个月的数据。

用户类型：本文也同样过滤掉了政企用户、家庭用户和其他用户，只留下互联网卡个人用户。

CDR 表							
主叫号码 F7D97A	被叫号码 BDA794	开始时间 20200421123236	结束时间 20200421123305	时长 29	基站 ID 218090	城市 ID 11
流量表							
加密号码 F7D97A	开始时间 20200406041136	结束时间 20200406051136	下行流量 3700375	上行流量 1371049	时长 3600	基站 ID 218090
用户属性表							
加密号码 F7D97A	年龄 18	性别 male	余额 304.75	出账金额 19.00	套餐金额 19	城市 ID 11	流量 21.47
月份 ID 202004	在网时长 16	经度 112.59	纬度 28.19	单停次数 3	双停次数 1	套餐 ID 1186881
APP 表							
加密号码 F7D97A	一级标签 社交软件	二级标签 通信	三级标签 微信	使用流量 323	使用次数 7812	天数 10
停机表							
加密号码 F7D97A	停机时间 2020.11.10	停机类型 单停	是否复机 否
2020.04 至 2021.02 的数据统计							
互联网卡用户数量:400 万	CDR 记录条数: 35 亿	属性表记录条数: 400 万	停机表记录条数: 1000 万条	流量表记录条数: 400 亿	APP 表记录条数: 4 亿		

图 3-2 用户侧数据描述

干预表							
加密号码 F7D97A	营销结果 挽留失败	离网原因 套餐不合适	营销时间 201123 13:58	通话时长 136	联系电话 13826011809	城市 岳阳
套餐信息表							
套餐名称 B 站权益卡	主套餐 ID 9013357	主套餐名称 20200406051136	套餐内容 19 元	可选包 ID 9015724	可选包名 流量优惠包	可选项 1GB 流量
2021.11 至 2021.02 的数据统计							
互联网卡用户数量:5 万	干预表记录条数: 5 万	套餐信息表记录条数: 80					

图 3-3 挽留信息描述

数据规模: 在这 4 个月的数据中, 一共有 20 万的离网的互联网卡个人用户, 20 万条以次为粒度的干预表记录, 80 条以个为粒度的套餐信息表记录。其中干预表记录的为运营商人工客服对离网用户的干预数据, 而套餐表记录的则为互联网卡套餐的相关数据。

3.2 UPRF 框架设计概览

3.2.1 挽留问题形式化

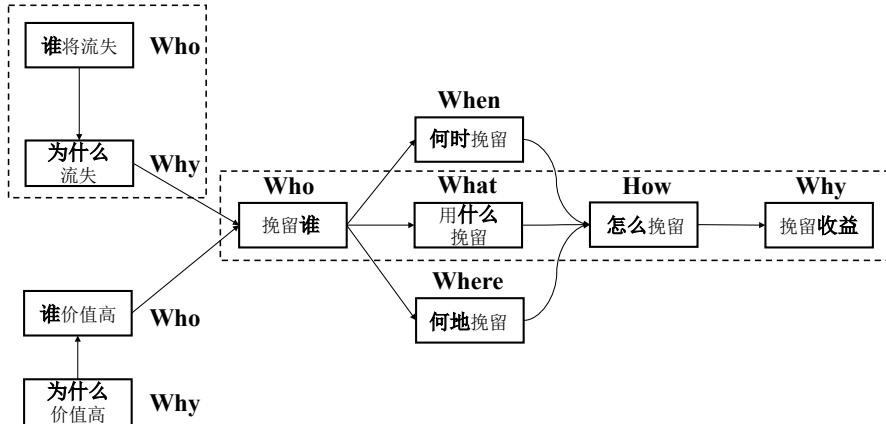


图 3-4 用户挽留问题分解图

为了解决精准和有效地挽留离网用户以帮助企业的长期利益最大化，本文将其分解成了如下子问题，并且建立了每个子问题之间的联系，如图3-4所示，其中虚线框中的为本文重点解决的问题。

首先是挽留谁的问题，我们从两个角度思考这个问题。首先是流失风险较高的用户，因为我们要解决客户流失的问题，对于那些没有流失意愿的客户，本文不考虑对他们分发相应的激励措施。其次是流失风险较高用户中的高价值用户。显然易见的，企业肯定更关注于价值更高的用户，因为后者能给企业带给更高的收益，尤其是在预算有限的情况下。然后知道了哪些用户流失风险较高并且价值较高之后，我们还得了解他们是为什么倾向于流失。如果是因为无使用需求等这种不可抗力的原因，企业就无需耗费额外精力对这部分用户进行干预。因为无论干不干预，这部分用户都会流失。如果是因为通用流量不够等原因，企业方就可以“对症下药”，向这些用户匹配相应合适的挽留策略。但是哪些用户将流失，为什么流失，哪些用户价值高，为什么价值高都需要一种算法/模型来给出相应结果，这些不会从数据中直接反映出来。

其次是用什么挽留的问题。这部分对应企业方的挽留策略，又称干预措施等。具体可分为沟通互动、营销活动、优惠政策等几大类。具体内容由面向不同应用场景的企业所决定。假设能设计某个模型/算法感知到流失风险较高用户的离网原因，那么企业方就可以针对大多数群体离网的原因，设计相应的挽留策略，以减缓用户流失的情况。

接着是怎么挽留的问题。假设能设计某个模型/算法感知到流失风险较高用户的离网原因，那么企业方就可以针对每个用户个性化的需求和离网原因，匹配

相应设计好的挽留策略。但是如果采用人工或者规则式这种较为死板的匹配策略，则最终效果可能不会很好。最后是挽留收益的问题。本文选取某个评价指标来衡量挽留的最终收益，然后根据这个指标来衡量整个系统性能的好坏。该评价指标能够抽取不同场景的共同需求，泛化到尽可能多的应用场景。此外最好有直观，可解释性好等特点。

3.2.2 总体框架

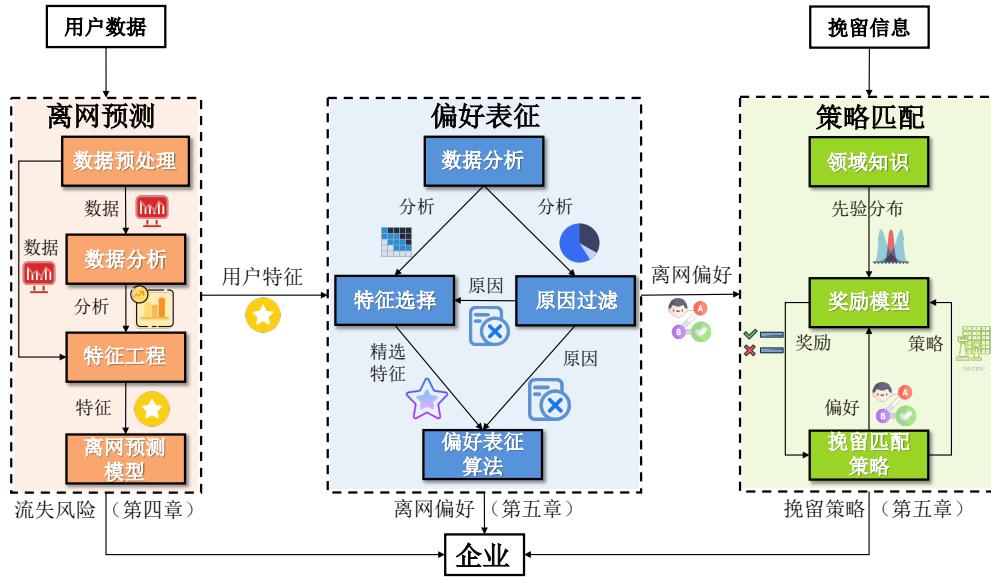


图 3-5 UPRF 框架总体示意图

本文设计的用户偏好的挽留框架（UPRF, User Preference-Aware Retention Framework）总体示意图如图3-5所示。我们将在第4章讲解离网预测模块的详细内容，之后会在第5章分别介绍偏好表征模块和用户干预模块的具体内容。

3.2.3 数据输入输出规范

为了使本文提出的UPRF框架能够泛化到其他更多的应用场景，如游戏用户挽留、社交平台用户挽留等，本文试图规范UPRF各个模块的输入和输出数据。宏观包括三个功能模块，包括离网预测模块，偏好表征模块和用户干预模块的输入输出规范。微观包括如数据预处理，数据分析等算法模块。如此一来，后续的研究者便可根据自己的场景与UPRF框架的适配度，选择迁移所有模块或是只迁移功能模块到自己的场景中，然后再填充相应的数据和实例化具体的参数。

离网预测模块：输入：用户 ID，[属性数据]，[行为数据]（不能同时为空）。
输出：用户 ID，用户特征，是否即将离网/流失，用户离网/流失风险。

1) 数据预处理：输入：用户 ID，[属性数据]，[行为数据]（不能同时为空）。
输出：用户 ID（脱敏），[属性数据（清洗后）]，[行为数据（清洗后）]。

2) 数据分析: 输入: 用户 ID (脱敏), [属性数据 (清洗后)], [行为数据 (清洗后)]。输出: 用户 ID (组), 分析结果。

3) 特征工程: 输入: 用户 ID (脱敏), [属性数据 (清洗后)], [行为数据 (清洗后)]; 用户 ID (组), 分析结果。输出: 用户 ID, [画像特征], [序列特征], 标签。

4) 离网预测模型: 输入: 用户 ID, [画像特征], [序列特征], 标签。输出: 用户 ID, 用户特征, 是否即将离网/流失, 用户离网/流失风险。

偏好表征模块: 输入: 预离网用户 ID, 用户特征。输出: 待干预用户 ID, 用户离网偏好。

1) 数据分析: 输入: 预离网用户 ID, 用户特征。输出: 用户 ID (组), 分析结果。

2) 离网原因选择: 输入: 用户 ID (组), 分析结果。输出: 用户 ID, 离网原因。

3) 离网偏好特征选择: 输入: 用户 ID (组), 分析结果; 用户 ID, 离网原因。输出: 离网原因相关的偏好特征, 相关性。

4) 离网偏好表征: 输入: 用户 ID, 离网原因; 离网原因相关的偏好特征, 相关性。输出: 待干预用户 ID, 用户离网偏好。

用户干预模块: 输入: 待干预用户 ID, 用户流失风险, 用户离网偏好。输出: 干预用户 ID, 挽留策略。

1) 领域知识: 输入: 离网原因, 挽留策略。输出: 先验分布。

2) 奖励模型: 输入: 待干预用户 ID, 用户离网偏好, 挽留策略。输出: 奖励。

3) 策略匹配算法: 输入: 待干预用户 ID, 用户流失风险; 挽留策略。输出: 干预用户 ID, 挽留策略。

3.3 本章小结

本章主要介绍了本文所使用的大数据平台系统架构, 用户侧和挽留信息的数据构成和相应规模。然后介绍了如何形式化用户挽留问题和用户偏好感知的挽留框架 *UPRF* 的总体示意图, 最后约定了每个功能模块和子模块的数据输入输出规范, 以方便后续的研究者便可根据自己的场景与 *UPRF* 框架的适配度, 选择迁移所有或部分模块到自己的场景中。

第4章 基于自注意力的互联网卡用户离网预测模型设计

在本章中，本文会首先介绍离网预测模块的总体架构，接着进行了三个方面的数据分析，然后进行了相应的特征工程提取了能够明显区分互联网卡正常用户和离网用户的画像特征和序列特征，最后融合了主成分分析算法和自注意力机制，设计并实现了一种互联网卡离网预测模型。

4.1 离网预测模块描述

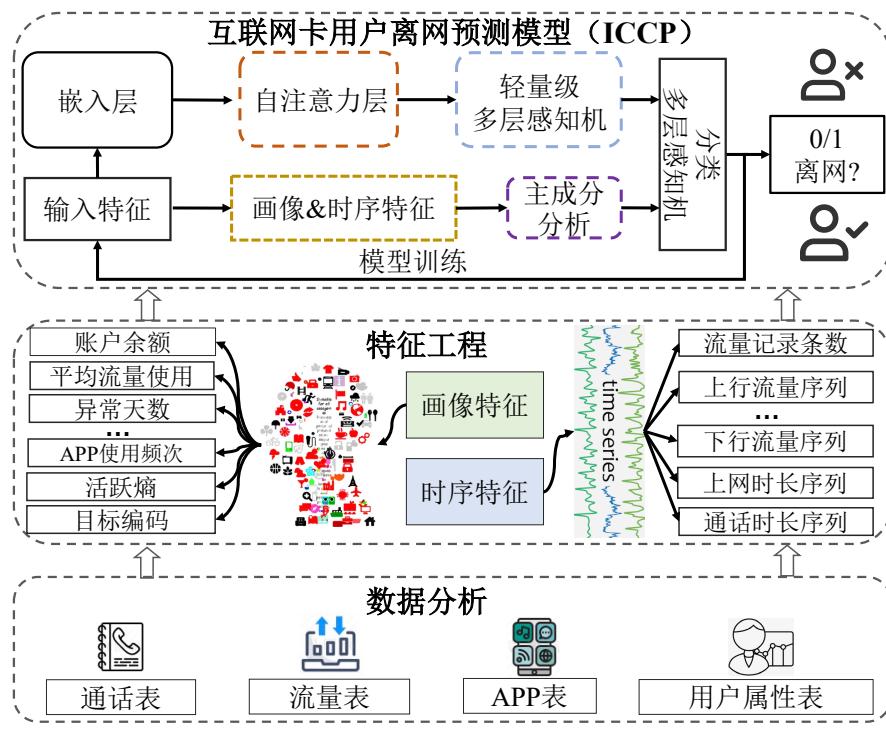


图 4-1 离网预测模块示意图

如图4-1所示，这是离网预测模块的具体工作流程图。本文首先对用户属性表等表做了数据分析，然后从通话表、流量表、APP 表等表中提取能最大化表征互联网卡正常用户和离网用户的特征，具体又分为画像特征和时序特征。最后本模块设计了一个融合主成分分析算法和自注意力机制的互联网卡用户离网预测模型，从而充分利用了画像特征和时序特征各自的潜在信息以及交叉后带来的信息增益。接下来，4.2 节将描述数据分析的具体工作，4.3 节将介绍特征工程的详细内容，4.4 节将阐述离网预测模型的系统架构。

4.2 数据分析

在本节中，本文会首先针对互联网卡正常用户和离网用户做全面的数据分析，接着探索在哪些属性和行为数据上互联网卡离网用户和正常用户表现出较

大差异，然后针对这些数据做相应的特征计算，提取用以区分互联网卡正常用户和离网用户的关键特征。

本文首先定义了互联网卡离网用户，然后分析了互联网卡的离网趋势以及互联网卡用户的离网原因分布。

离网用户定义：离网用户也被称为流失用户，往往是用户在使用过程中因服务不满意、资费贵、改用其他竞品等原因而选择不再使用互联网卡。其中又分为两种，分别是主动性离网和被动性离网。其中主动性离网是指用户主动到运营商营业厅提出销卡的请求，还包括退还余额等行为。而被动性离网则指用户保持了至少两周 14 天的双停状态，没有通过充值话费等行为使得相应手机号复机。则运营商会主动将这类号码销户，之后再销售给其他用户。本文的研究主要是针对被动性离网，因为主动性离网行为只占互联网卡所有离网行为的不到 10%，尚且不受运营商们重视。

4.2.1 互联网卡趋势

为了了解互联网卡这个业务的发展趋势，本文绘制了从 2020 年 4 月到 2021 年 2 月的发展趋势图。

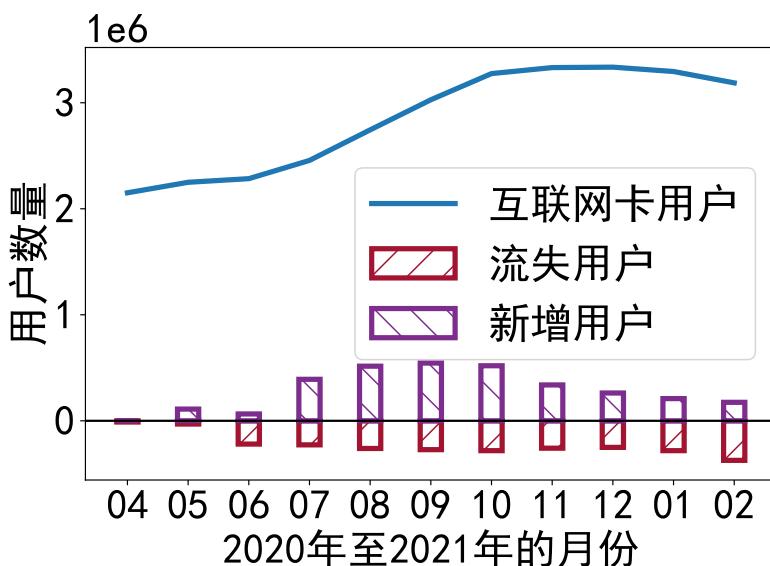


图 4-2 互联网卡用户发展趋势图

如图4-2所示，从图中，本文可以观察到互联网卡在初期增长得十分迅速，但是后期增长趋势放缓，从 2020 年 4 月到 2021 年 2 月一共增长了 50% 的用户，数量约为 100 万。究其背后的原因是因为尽管在一开始互联网卡新增用户占大多数，但是随着时间流逝，离网用户的数量迅速增长，甚至超过了月新增用户。这使得离网问题变得日益严重起来，对运营商维系互联网卡业务的稳定性提出了挑战。

4.2.2 离网时间分析

为了进一步地理解互联网卡用户的离网行为，本文分析了互联网卡用户 7 个月的停机数据并分析了每个用户的离网时间。

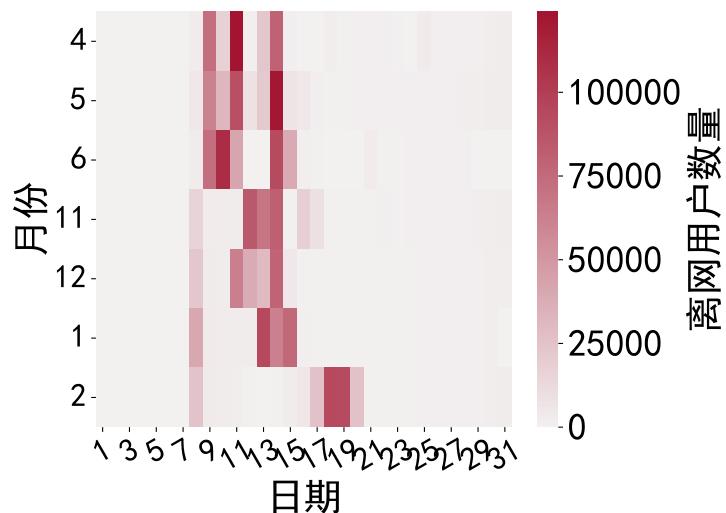


图 4-3 互联网卡离网用户数量-日期热力图

图4-3展示了 7 个月份内不同日期的离网用户数量，我们可以观察到在每个月的 9 号至 19 号拥有绝大多数的离网用户（超过了 95%）。我们还可以发现不同月份的离网用户数量和离网时间分布具有一定差异。举例来说，2021 年 1 月 14 日的离网用户数量可以达到 122029 个，然而其他月份只有更少的离网用户。此外我们还观察到在每个月的月初和月末都基本没有互联网卡用户离网。这可能是与运营商的工作特点有关联，运营商的每个月初和月末常常需要做些清点工作。

上述发现带给本文两个启示，首先，由于用户的离网行为在每月都有相同和不同之处，不是非常稳定，这带给整个系统的建模带来了一定挑战。其次，这也启示本文互联网卡用户偏好在月中离网，因此本文应当在上月末或者当月初就完成当月互联网卡的离网用户预测，才对运营商有实际意义。又因为互联网卡庞大的用户体量，运营商只能在每月初才能完成对所有数据的采集和基本处理工作，因此本文的工作最终也是在每月月初进行推理和产出的。

4.2.3 离网原因分析

为了理解为什么一部分互联网卡用户倾向于离网，本文基于运营商客服收集的离网用户反馈数据对用户离网原因进行了分类。

图4-4展示了互联网卡用户离网的数量最大的前 10 个原因。我们可以看到互

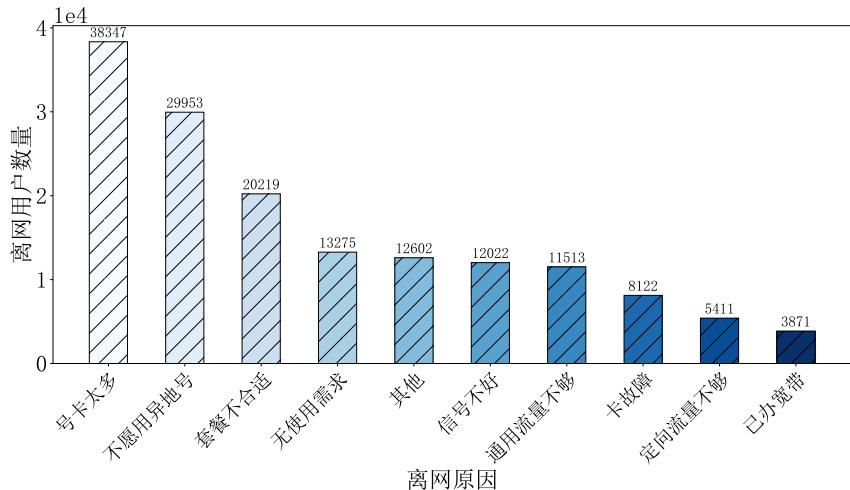


图 4-4 互联网卡用户 Top10 离网原因分布图

联网卡用户最多是因为“号卡太多”这个原因离网的。因为现在不同的运营商都在计划占据整个互联网卡市场。他们通过向新用户频繁宣传和给予大量折扣的优惠来吸引他们使用自家的互联网卡。因此，部分互联网卡用户可能会被其他运营商的优惠政策所吸引，从而离网转向使用其他运营商的互联网卡。第二大离网原因是互联网卡用户不愿使用异地号。因为运营商的不同省份都是各自独立的，都会向全国各地兜售互联网卡。因此部分互联网卡用户使用的互联网卡的负责公司所出的省份与自己所处的省份并不同，在接听和拨打电话时常常会引起误会。并且由于异地的关系，手机信号和网络可能变得不稳定，从而影响用户的使用体验。这些现象导致了部分用户不想使用异地的互联网卡。此外，套餐不合适和无使用需求也占据了相当大的比例，这些是能被运营商优化的。从长期来说，互联网卡用户和原因的分布随着时间流逝和新用户的加入可能会变得不同。因此，本文只关注用户离网原因的类别。然后，本文可以为不同离网原因类别匹配相应的挽留策略从而挽留住那些已经离网或者将要离网的互联网卡用户。总的来说，用户离网原因分布的改变并不会影响系统的总体性能。

因为运营商通过向互联网卡用户收取基本的套餐费用以及额外的服务费用来赚取利润的，所以互联网卡这个业务市场高度依赖于互联网卡用户的数量。又因为用户离网问题对运营商来说至关重要，所以本文设计和实现的系统不得不理解互联网卡离网用户的潜在行为，并且提前预测用户的离网行为从而发起早期的干预。综上所述，本文迫切需要了解互联网卡用户特征，在此基础上制定和匹配更有效的业务策略，防止他们离网，这也是本工作的动力之一。

4.3 特征工程

在本小节中，本文会展示基于数据分析的一些重要特征，主要分成两类，一类是静态画像特征，另一类是时间序列特征。

4.3.1 画像特征工程

账户余额：当互联网卡用户即将离网的时候，他们通常倾向于花光账户里的余额，因此账户余额越低，用户越容易离开运营商。

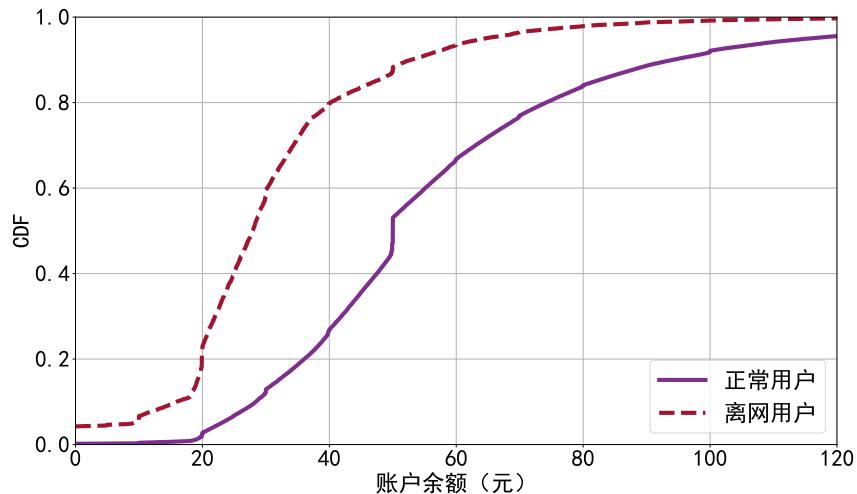


图 4-5 互联网卡离网用户和正常用户账户余额对比图

图4-5展示了互联网卡正常用户和离网用户关于账户余额属相的累积分布函数(CDF)图，可以看出这两条曲线有着非常大的差距。详细来说，对于80%的用户来说，离网用户的账户余额都小于40元，而正常用户的账户余额都小于75元，这意味着账户余额对于判断用户是否会发生离网行为是一条关键的线索。

平均流量消耗阶段：对于即将离网的用户来说，他们的网络行为往往会发生变化。为了捕捉这个特征，本文把每个月份平均分成三个等长的阶段，分别是上旬，中旬和下旬。

图4-6显示了正常用户和离网用户在月份不同阶段的流量消耗变化。从中可以观察到对于正常用户来说，不同阶段的平均流量消耗并没有什么区别。但是在离网用户的三个不同阶段，流量消耗曲线有很明显的差距。举个例子，在上旬，中旬和下旬，平均消耗流量为0的用户在所有离网用户占比分别达到了30%，80% 和 96%。这个现象启示我们互联网卡用户的流量衰减行为往往暗示了他们的离网行为。

APP 使用频次：为了捕捉互联网卡用户的APP使用习惯，本文基于采集的APP表计算了每个互联网卡用户在一个月内的所有APP使用频次。

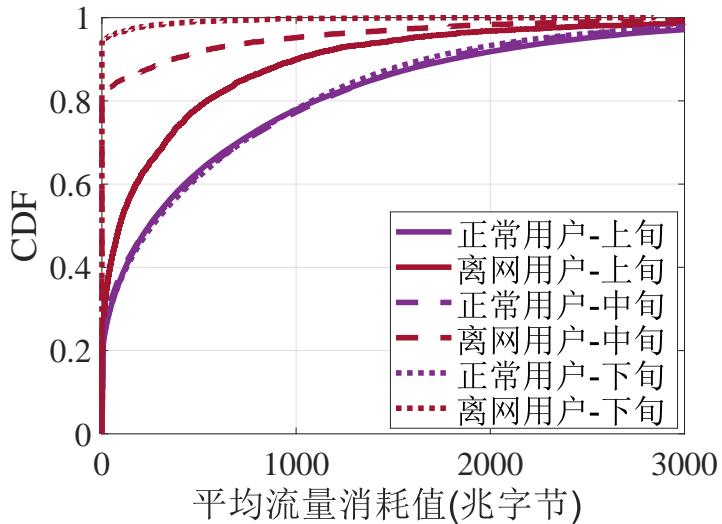


图 4-6 月不同阶段的互联网卡用户平均消耗流量值对比图

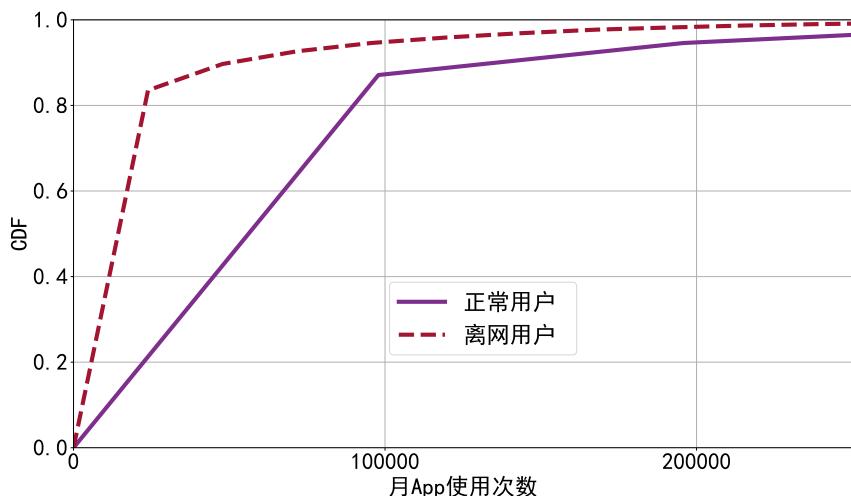


图 4-7 互联网卡用户月 APP 使用频次对比图

在图4-7中，本文描绘了正常用户和离网用户关于 APP 使用频次的对比 CDF 图，并且其中有非常大的不同。具体来说，正常用户的 APP 使用频次的中位数是 36075 次，而离网用户的对应中位则是 18442 次。这意味着 APP 使用频次对于互联网卡用户来说是一个非常有价值的特征，可以用来区别正常用户和离网用户。

活跃熵：和上述思路保持一致，本文基于香农信息熵探索了在一个月内日指标观察值（包括，使用流量大小，流量记录条数，上网时长等）的不确定性。对于某个互联网卡用户 u 来说，他关于上网时长序列的活跃熵 $H(D_u)$ 可以被如下公式(4-1)计算。

$$H(D_u) = \sum_{k=0}^{\min(\text{maxbin}, \text{len}(D_u))} p_k \log \frac{1}{p_k} \quad (4-1)$$

其中 D_u 是用户 u 的上网时长序列， p_k 表示上网时长序列中的数值落在第 k 个箱

子的概率。此外， $maxbin$ 是分箱的数量， $len(D_u)$ 是 D_u 的长度。如果上网时序列的活跃熵比较大，这意味着上网时长序列中的数值在区间 $[min(D), max(D)]$ 中更为分散和混乱。否则，如果上网时长序列的活跃熵比较小，这意味着上网时长序列中的数值都集中在某个较小的确定区间内。

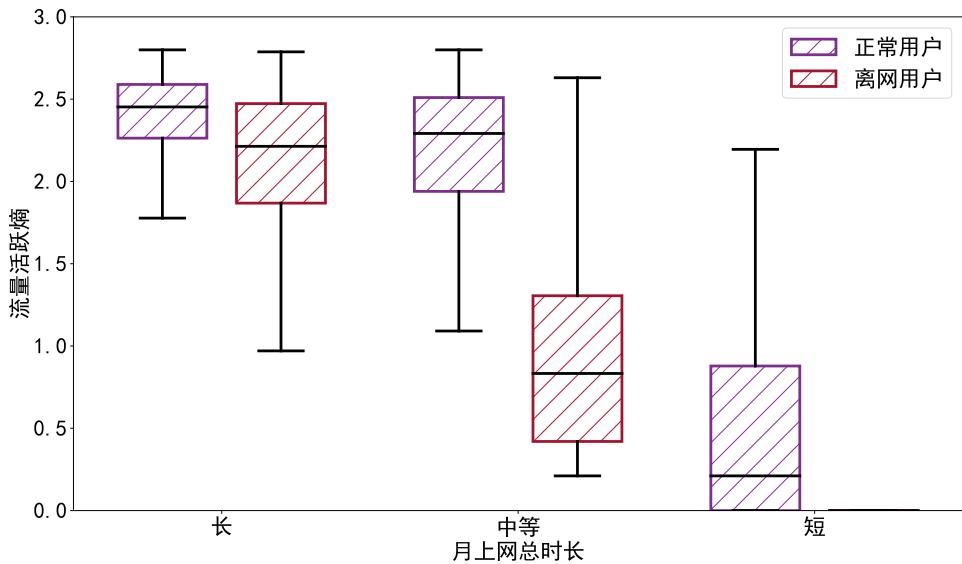


图 4-8 互联网卡用户流量活跃熵对比图

在图4-8中，本文同时绘制了正常用户和离网用户关于日上网时长活跃熵的箱线图。并且用户们被分成了三组，分别是上网时长较长，上网时长中等和上网时长较短。本文可以观察到两种类型用户的不同行为模式，其中离网用户有着更小的熵值，这显示了他们有这更简单的网络行为模式，从而使得他们能够同正常用户区分开来。

目标编码：为了构建目标编码，比如将分类特征替换为相应目标的后验概率，本文首先根据用户的流量消耗值将互联网卡用户分组。特别地，本文将流量数据等宽地平均分到了 k 个箱子中，每个箱子的宽度 (w) 可由下列公式(4-2)计算。

$$w = (Max - Min)/k \quad (4-2)$$

其中 Max 和 Min 分别代表了用户在一个月内的总流量使用值的最大值和最小值，并且每个箱子的边界值分别是 $\{Min + w, Min + 2w, \dots, Min + (k - 1)w\}$ 。因此，针对流量分箱的目标编码值，比如以符号 \vec{R} 表示，可以被如下公式(4-3)计算。

$$\vec{R} = Concat(\frac{\sum_{j=1}^{n_i} u_{ij} \cdot y_{ij}}{n_i}), i = 1, 2, \dots, k, \quad (4-3)$$

其中 n_i 表示在第 i 个箱子中的用户数量， u_{ij} 表示在第 i 个箱子中的第 j 个用户，

$y_{ij} \in \{0, 1\}$ 表示目标值，比如， $y_{ij} = 1$ 表示这个用户是离网用户，否则，这个用户就是正常用户。此外，*Concat* 函数用于拼接 k 个值到向量 \vec{R} 中。

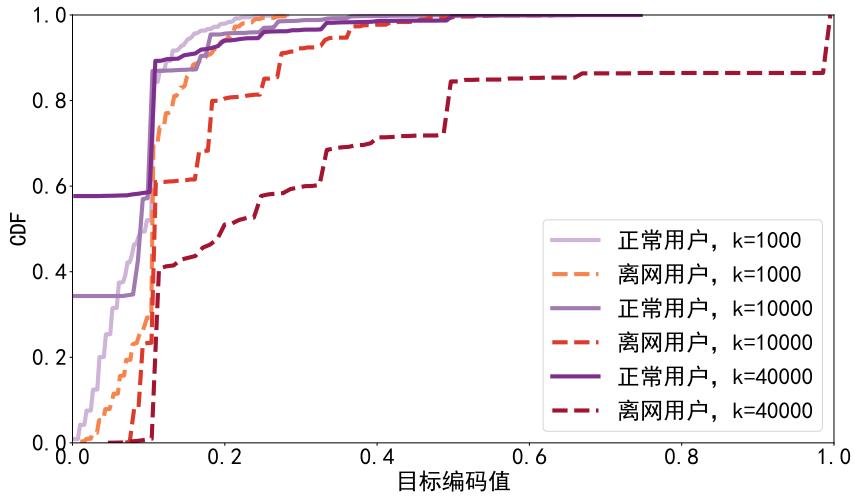


图 4-9 互联网卡用户目标编码值对比图

图4-9描绘了在分箱数量不同时正常用户和离网用户的目标编码值的 CDF 对比图。本文可以观察到，当 $k=1000$ 时，离网用户和正常用户之间的差距还不是特别明显。但是，当分箱数量逐渐增加的时候，比如 $k=40000$ 时，一个良好的性能差距就浮现出来，这也意味着正常用户和离网用户被分发到不同的箱子后计算的目标编码值可以有效地区分两者。

值得注意的是，除了上述提到的重要特征，其他基础画像特征，比如年龄、性别、开卡日期和终端类型等也被提取和注入到后续的离网预测模型当中了。

4.3.2 时序特征工程

除了静态特征，时序特征对于学习模型来说也是非常重要的。因为离网行为通常是一个渐进进程而不是一个突发事件。

流量序列：

图4-10展示了在一个月内的互联网卡用户的日产生流量记录条数的箱线图。我们可以从中观察到正常用户每日通常比离网用户都产生了更多数量的流量记录条数。更加重要的是，对于正常用户来说，时序行为的差异十分小，但是对于离网用户来说，他们的流量使用行为显得更不稳定。这也意味着这种时间相关性可以被加以利用来区别这两种类型的用户。需要指出的是，除了每日流量记录，其他日粒度特征还包括上行流量值，下行流量值，上网时长，通话次数等，也都被提取成时序特征并且输入给了后续的学习模型。

流量异常天数：

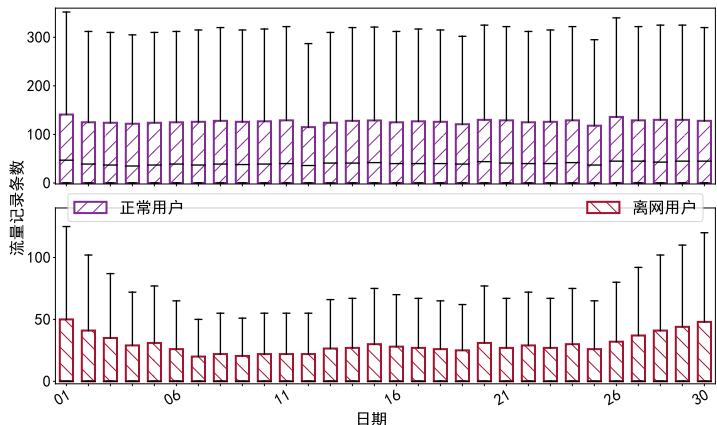


图 4-10 互联网卡用户日流量记录条数序列对比图

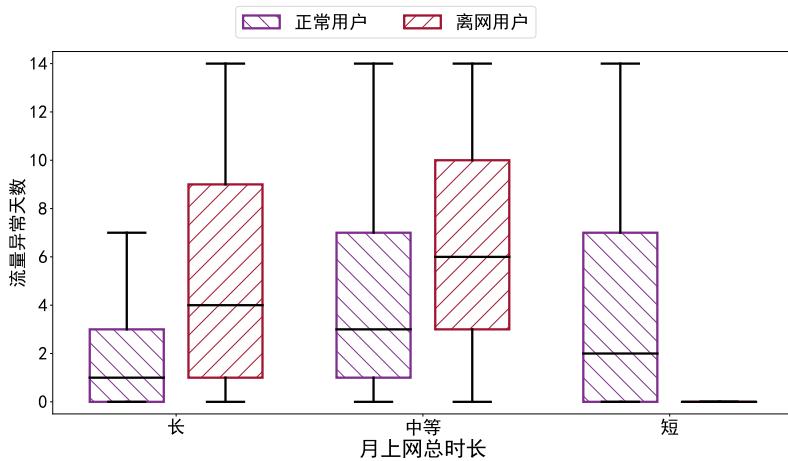


图 4-11 互联网卡用户流量异常天数对比图

除了分析互联网卡用户的流量统计特征，本文还检测了互联网卡用户在一个月内的哪些日期出现了流量异常行为，因为异常值往往表征着此用户表现出了与以往不同的行为，很有可能会趋向离网。

明确来说，基于用户的日序列行为，本文对所有用户累加了使用特征值，包括上行流量值，下行流量值，上网时长和流量记录条数。因此，对每个序列特征来说，它都能被表征为 $X = [B_1, B_2, \dots, B_i, \dots, B_n]$ ，其中 B_i 表示这个月内第 i 天的统计特征。为了获得更平稳的序列特征，本文对上述得到的序列特征计算了它们的一阶前向差分形式，用 $X' = [F_1, F_2, \dots, F_i, \dots, F_{n-1}]$ 来表示。 X' 可以用以下公式(4-4)计算。

$$F_i = B_{i+1} - b_i \quad (4-4)$$

然后，本文定义了异常值 $E(X')$ ，可以通过使用四分位距（IQR）加上以下公式(4-5)来判定。

$$E(X') > Q_u + \gamma * IQR \quad | \quad E(X') < Q_l * IQR \quad (4-5)$$

其中 $IQR = Q_u - Q_l$, $\gamma = 1.5$ 。 Q_u 是上四分位值, 显示只有 $1/4$ 的观察值比它大, 然后 Q_l 是下四分位值, 这就意味着只有 $1/4$ 的观察值比它小。因此, 每天的流量行为是否是异常值可以通过计算用户序列特征前向差分值的异常值来判断。

在图4-11中, 本文为正常用户和离网用户都描绘了月异常天数的箱线图。类似地, 其中用户也被分成了三组, 按照在一个月内的总上网时长从高到低依次排序。具体来说, 其中上网时长较高和中等的离网用户组明显拥有更多的异常天数, 能够被利用来识别离网事件。但是对于使用较少的离网用户组来说, 离网用户比正常用户有着更少的异常天数。这是合理的, 因为他们有着稀疏的上网行为, 这也导致了没有异常值产生。

4.4 离网预测模型设计与实现

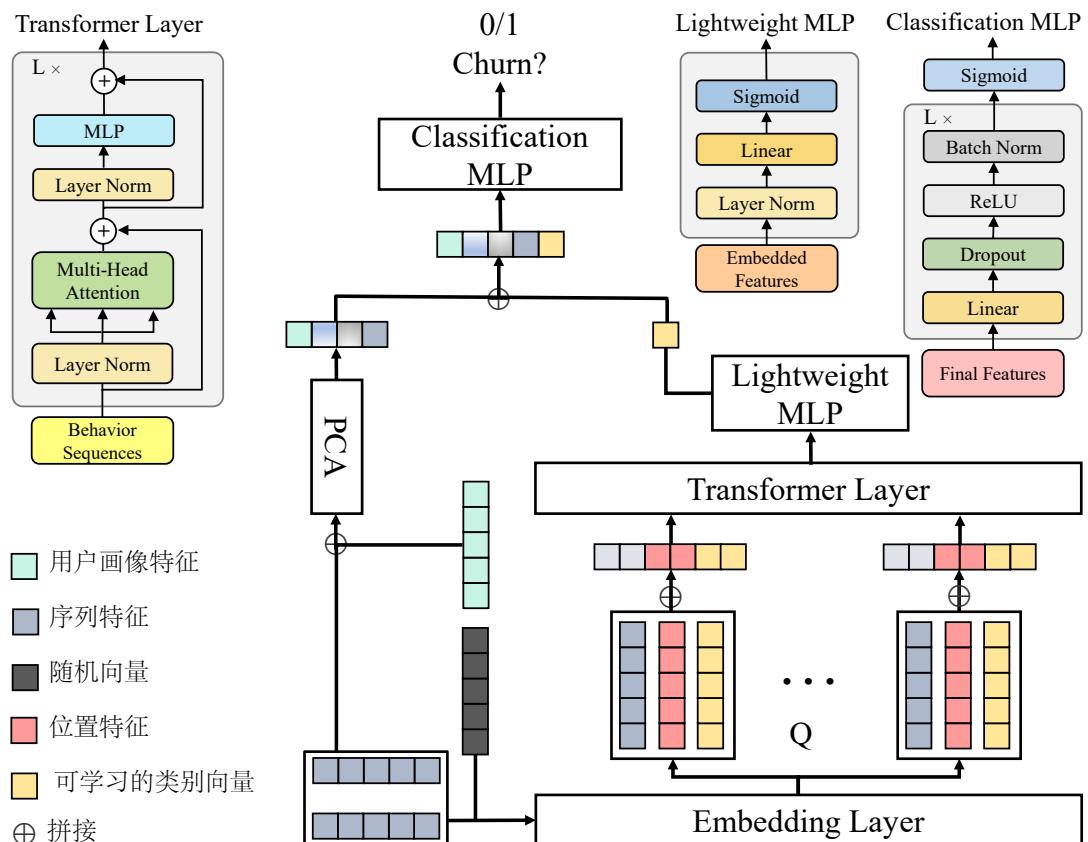


图 4-12 互联网卡用户离网预测模型架构

为了预测潜在的互联网卡离网用户, 本文设计了一个可学习的模型架构: 互联网卡离网预测模型Internet Card Churn Prediction (ICCP), 其中主要包括基于主成分分析算法的特征降维算法, 基于自注意力机制的编码算法, 轻量级的多层感知机和分类多层感知机, 如图4-12所示。

模型输入: 本文基于采集的数据构建了特征工程来提取用户画像和行为特

征。对于这两种类型的特征，本文定义符号 $\mathcal{P} \in \mathbb{R}^{1 \times M}$ 来表示画像特征矩阵，其中 M 表示所有静态特征的数量，定义符号 $\mathcal{T} \in \mathbb{R}^{Q \times D}$ 来表示时序特征矩阵，其中 Q 是所有日粒度特征的数量， D 是序列特征的长度。在为所有用户计算完这两类特征值后，它们将和离网标签一起被输入到可学习的模型来做监督学习。

模型输出：*ICCP* 模型将为测试集的每个互联网卡用户输出一个对应的离网风险值 $r \in [0, 1]$ ，然后 *ICCP* 模型将根据从验证集学习的阈值 t ，划分离网风险值 $r \geq t$ 的用户为潜在的离网用户。

4.4.1 基于自注意力机制的编码算法

算法 4-1 针对多重序列特征的嵌入变换算法

Input: 时序特征 $T^{(N \times L)}$ ，嵌入向量数量 Q ，块长度 V ，块宽度 W ，嵌入向量大小 D ，变换块数量 L'

Output: 用户时序特征的编码向量 $E^{(Q \times D)}$

- 1: 把时序特征 $T^{(N \times L)}$ 变形成块 $B^{Q \times (V \times W)}$;
 - 2: 训练一个全连接神经网络来编码块 $B^{Q \times (V \times W)}$ 到块 $B^{Q \times D}$;
 - 3: 随机初始化一个可学习的服从高斯分布的向量 X^D ;
 - 4: 随机初始化一个可训练的服从高斯分布的位置嵌入矩阵 $M^{(Q+1) \times D}$;
 - 5: 拼接块 $B^{Q \times D}$ ，向量 X^D ，矩阵 $M^{(Q+1) \times D}$ 成 Z_0 ;
 - 6: 初始化 $Q_i = W_i^Q * Z_0, K_i = W_i^K * Z_0, V_i = W_i^V * Z_0, i = 1, \dots, 3$;
 - 7: 计算 $Head_i = \text{softmax}\left(\frac{Q_i * K_i^T}{\sqrt{d_{k_i}}}\right) V_i, i = 1, \dots, 3$;
 - 8: 计算 $MSA(Z_0) = \text{Concatenate}(Head_1, \dots, Head_3) * W^O$;
 - 9: 计算 $Z'_l = MSA(LN(Z_{l-1})) + Z_{l-1}, l = 1 \dots L'$;
 - 10: 计算 $Z_l = MLP(LN(Z'_{l-1})) + Z'_{l-1}, l = 1 \dots L'$;
 - 11: 计算 $E^{(Q \times D)} = LN(Z_L^0)$;
 - 12: 返回 $E^{(Q \times D)}$.
-

为了捕捉潜在的时间关联性，矩阵 \mathcal{T} 和一个随机向量会首先被喂入到一个嵌入层（Embedding layer），它会输出一个固定维度大小的低维空间向量 Q ，在图4-12可以看出，这个向量 Q 包含序列，位置和类别信息，并用不同的颜色标注了出来。然后这个向量 Q 被输入到了变形层（Transformer Layer），其中包括 L 个块，每个块中包含层归一化（LN），多头自注意力（MSA）和多层次感知机（MLP），这相对应的函数可以被如下公式计算。

$$z_0 = [s_{class}; \mathcal{T}^1; \mathcal{T}^2; \dots; \mathcal{T}^{|D|}; \mathcal{T}_{pos}^1; \mathcal{T}_{pos}^2; \dots; \mathcal{T}_{pos}^D], \quad (4-6-a)$$

$$z'_l = MSA(LN(z_{l-1})) + z_{l-1}, l = 1 \dots L \quad (4-6-b)$$

$$z_l = MLP(LN(z'_l)) + z'_l, \quad (4-6-c)$$

$$y = LN(z_L^0), \quad (4-6-d)$$

其中 z_0 是嵌入层的输出, \mathcal{T}^i 表示第 i 个时序特征的信息, 而 \mathcal{T}_{pos}^i 表示 \mathcal{T}^i 的位置嵌入信息。嵌入层和变形层的具体工作流程可见算法4-1。在这之后, 变形层的输出将被输入到轻量级的多层感知机 (Lightweight MLP), 其中包括层归一化, 全连接层和 Sigmoid 层。然后轻量级的多层感知机将会输出一个离网概率值, 后者将被视为一个新特征注入到之后的分类多层感知机中。

4.4.2 基于主成分分析算法的特征降维算法

为了捕捉用户的画像信息, 本文首先将用户画像特征和时序特征拼接成一个一维向量, 比如说, $V_i = \{x_1, x_2, \dots, x_{M+Q \times D}\}$ 。然后这个向量将被输入到主成分分析算法这个组件。它会输出一个压缩向量 $W_i^* = \{w_1, w_2, \dots, w_{d'}\}$, 其中 $w_{d'}$ 是新维度的大小。接着这个新向量和轻量级多层感知机的输出会被拼接, 然后输入到最终的分类多层感知机中。需要特别指出的是, 针对画像特征和时序特征的主成分分析算法能够在保持大多数特征成分的同时, 比如最大限度地保留原始信息, 这也能够减少用于分类的特征的复杂度, 加速模型训练和收敛。具体的工作流可见算法4-2。

算法 4-2 针对画像特征和时序特征的主成分分析

Input: 用户画像特征 P , 时序特征 T , 信息阈值 I

Output: 被信息阈值截断的关于用户特征的主成分 P_c

- 1: 初始化时序矩阵 t 为空;
 - 2: 初始化信息权重 w 为 0 和主成分数量 n 为 0;
 - 3: **for** $i \leftarrow 1 \cdots Q$ **do**
 - 4: $t \leftarrow$ 拼接 t 和 T 的第 i_{th} 个时序特征;
 - 5: **end for**
 - 6: $P \leftarrow$ 拼接 t 和 P ;
 - 7: 并行对所有特征去中心化 $P_i = P_i - \frac{1}{M+Q*D} \sum_{j=1}^{M+Q*D} P_j$;
 - 8: 计算特征的协方差矩阵 $C = \frac{1}{M+Q*D} P P^T$;
 - 9: 计算特征值 λ 和协方差矩阵 C 对应的特征向量 \vec{v} ;
 - 10: 根据 λ 降序排列 \vec{v} 来得到矩阵 C' ;
 - 11: **repeat**
 - 12: $w = \frac{\sum_{i=1}^n \lambda_i}{\sum_{i=1}^{M+Q*D} \lambda_i};$
 - 13: $n \leftarrow n + 1$;
 - 14: **until** $w < I$
 - 15: 选择 C' 的前 n 行来得到变换矩阵 A ;
 - 16: $P_c = AP$;
 - 17: 返回 P_c .
-

4.4.3 基于多层感知机的分类器设计

为了分类一个互联网卡用户是否是离网用户，本文将其建模成一个二分类的问题。本文通过使用分类多层感知机，其中包括 L 个块，每个块包含小批量归一化 (Batch Norm)，ReLU，Dropout 和全连接层。

为了训练这个模型，本文采用交叉熵作为损失函数，可以被以下公式(4-7)所计算。

$$\mathcal{L} = \frac{1}{N} \sum_i -[y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i)] \quad (4-7)$$

其中 p_i 表示用户 i 离网概率值，而 $y_i \in \{0, 1\}$ 是表示用户是否离网的标签，具体来说， $y_i = 1$ 代表此用户是一个离网用户，否则， $y_i = 0$ 此用户是一个正常用户。 N 表示所有训练样本的数量。

4.5 实验评估与结果分析

本小节将根据真实世界中互联网卡用户的属性，流量等多维度数据和离网行为数据来验证 *ICCP* 模型的有效性。数据集来自于某个通信运营商。

4.5.1 实验设置

为了评估 *ICCP* 模型的性能，本文首先使用了某个运营商的互联网卡用户离网信息来标记离网用户，比如，如果一个互联网卡用户双停超过两个礼拜并且没有复机行为，那该用户就会被标记为离网用户。

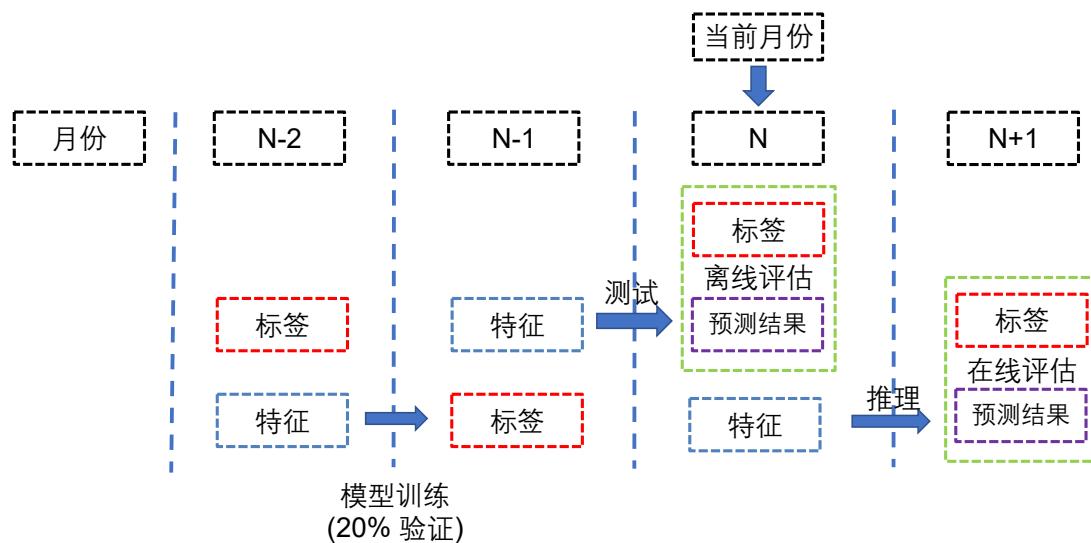


图 4-13 基于滑动窗口的离网预测模型实验设置图

图4-13展示了在不同月份基于滑动窗口的训练和预测实验设置。需要特别指出的是，假设当前月份是 N 月，本文首先会使用 $N - 1$ 月的用户离网信息来标

记拥有 $N - 2$ 月特征的用户，接着用相同的方法使用 N 月的用户离网信息来标记拥有 $N - 1$ 月特征的用户。然后，本文使用拥有 $N - 2$ 月特征的用户和 $N - 1$ 月的标签来训练 *ICCP*，其中 20% 的数据样本用于验证。下一步，本文使用拥有 $N - 1$ 月特征的用户和 N 月的标签来测试 *ICCP* 的离线性能。最后，同上述机制一致，本文把 N 月无标签的用户特征数据输入到 *ICCP* 中，就可以得到下一个月的互联网卡离网用户名单，并且可以在下月评估 *ICCP* 的在线真实性能。综上所述，本文利用滑动窗口机制，通过将窗口从上个月移动到当前月实现用户的特征捕捉，然后使用 *ICCP* 模型来预测下月的潜在离网用户。

对于特征工程和性能评估，本文使用了横跨五个月采集的数据，分别是 2020 年的 5 月、6 月，11 月、12 月和 2021 年的 1 月。其中 2020 年的 6 月、12 月和 2021 年的 1 月的数据分别用来标注 2020 年 5 月、11 月和 12 月互联网卡用户（是离网用户还是正常用户）。然后，本文使用相应的数据样本来进行离网预测模型的训练和测试。由于系统资源的限制，本文分别随机挑选了 50 万和 95 万的互联网卡用户作为一个月的数据样本，其中在 2020 年 5 月有 493251 个正常用户和 6749 个离网用户。而对于 2020 年 11 月和 12 月的互联网卡用户而言，则有 871049 个正常用户和 73289 个离网用户。因此，本文在 2020 年 5 月、6 月、11 月和 12 月的 500000 个和 944338 个数据样本上构建了实验，其中 80% 的样本用于训练，剩下 20% 的样本用于测试。

基准模型：为了显示本文提出的 *ICCP* 模型的优越性，本文设计和实现了一下可以比较的用来解决分类问题的基准模型，包括机器学习和深度学习模型。值得注意的是，虽然这些算法在科研文献中被广泛采纳用来解决分类问题，在其中却没有解决互联网卡用户离网分类和预测的。另外，为了保证比较的公平性，所有的基准模型的特征输入都与 *ICCP* 模型保持一致。

- **随机森林 (RF)**：是一种被广泛采纳用来解决分类问题的基于决策树的传统机器学习算法。
- **轻量梯度提升机 (LGBM)**：是一种基于决策树算法的分布式梯度提升机器学习框架。这种机器学习能够提供高效率并行训练，低内存消耗，更高准确率和大量数据的快速处理。
- **长短期记忆网络 (LSTM)**：是深度学习领域内的一种循环神经网络架构 (RNN)。它能很好地捕捉序列数据中的短期时间相关性。
- **多层感知机 (MLP)**：是人工神经网络中的一种基础模型。它利用反向传播机制来进行模型训练。多层感知机一般是由包含全连接层，批量归一化 (BN) 层，ReLU 层，Dropout 层的块堆积而成的。
- **残差前馈神经网络 (ResMLP)**：是一种基于残差连接的神经网络架构。其中

包括一个隐层前馈神经网络和一个线性的残差连接。和多层感知机相比，残差前馈神经网络是一种拥有三个块层的更简单的残差网络架构。在本文离网预测场景当中，本文在每三个块层中添加了一个残差连接用来解决反向传播过程当中的梯度消失问题。

评估指标：对于离网预测问题来说，基于以下这四个基础测试结果，分别是真阳性样本 (TP)，假阳性样本 (FP)，真阴性样本 (TN)，假阴性样本 (FN)，本文采用了以下 5 个评价指标来评估相应性能。

- **精准率 (Precision)：**指的是一个被预测为离网的用户被正确预测的概率，具体公式为， $\frac{TP}{TP+FP}$ 。
- **召回率 (Recall)：**指的是在真实标签中所有离网用户被正确预测的概率，具体公式为， $\frac{TP}{TP+FN}$ 。
- **F1 分数 (F1-Score)：**被定义为精准率和召回率的调和平均数，具体公式为， $2 \times \frac{Precision \times Recall}{Precision + Recall}$ 。
- **接收者操作特征曲线下面积 (AUC)：**被定义为随机挑选一个正样本和负样本，正样本能排在负样本之前的概率。该评价指标用来判断模型是否擅长分类。具体公式为， $\frac{\sum_{i \in positiveClass} rank_i - \frac{M(M+1)}{2}}{M \times N}$ ，其中 M 和 N 分别表示正样本和负样本的数量。
- **精准率-召回率曲线下面积 (PR-AUC)：**被定义为根据不同阈值同时画出的精准率-召回率曲线下的面积。这项评价指标等同于根据不同阈值计算的召回率和精准率的平均乘积累加和。具体公式为， $\sum_{k=1}^N P(k) \Delta R(k)$ 。

4.5.2 用户离网预测模型性能评估

系统总体性能：本文首先通过与基线模型的对比来检验本文提出的模型 ICCP 的系统总体性能。具体方法为把所有数据平均分成 5 组后（比如，k 折交叉验证，其中 k=5）来计算性能的平均值和上下界。

图4-14展示了不同分类模型的性能表现。本文可以做出以下推断：首先就 AUC，PR-AUC 和 F1 分数而言，本文提出的 ICCP 模型可以显著超越基线模型。具体来说，随机森林，轻量梯度提升机，长短期记忆网络，多层感知机和残差前馈神经网络的平均 PR-AUC 分数分别为 0.54，0.67，0.23，0.69 和 0.68，在另一方面，ICCP 的平均 PR-AUC 分数为 0.77。其次，与其他基准预测模型相对比而言，长短期记忆网络表现出了最差的性能，这是因为长短期记忆网络只能捕捉时序特征而忽略了静态画像特征。第三，通过比较随机森林、轻量梯度提升机和长短期记忆网络、多层感知机和残差前馈神经网络，本文可以发现深度学习模型展示了提高互联网卡用户离网预测准确率的潜力。这里面的主要原因为深度学习

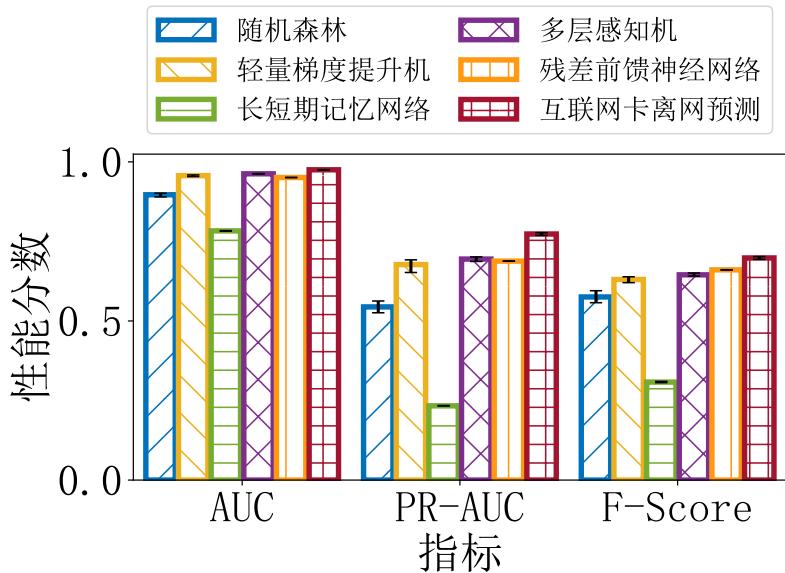


图 4-14 离网预测模型总体性能对比图

模型可以通过利用多维度特征学习隐含信息表示。需要指出的是，本文也测试了其他机器学习模型，包括决策树，支持向量机和梯度提升树等，最终本文选取了表现性能最好的随机森林和轻量梯度提升机作为机器学习模型的代表。

Top-U 用户的性能：

为了进一步评估离网预测模型的性能，本文测试了 Top-U 个离网风险最高的互联网卡用户的模型预测性能表现。接着本文评估了他们的预测性能。这个 Top-U 用户的评价指标可以作为运营商决策的重要参考。

图4-15中的(a), (b), (c)子图分别展示了 Top-U 用户的精准率 (Precision@U)、召回率 (Recall@U) 和 F1 分数 (F1-Score@U)。其中用户范围是从前 2000 个一直到前 20000 个。本文做出了以下的主要观察。

首先，在 Top-U 用户的设置下，本文提出的 *ICCP* 模型能在 Recall@U 和 F1-Score@U 这两项指标上明显超过其他基准模型。举例来说，*ICCP* 的 Precision@20000, Recall@20000, F1-Score@20000 分数为 {0.77, 0.60, 0.65}，与此同时残差前馈神经网络，多层感知机，轻量梯度提升机，长短期记忆网络和随机森林的对应分数分别为 {0.84, 0.49, 0.62}, {0.70, 0.52, 0.53}, {0.69, 0.51, 0.59}, {0.65, 0.48, 0.55} 和 {0.41, 0.06, 0.11}。第二，对于 Precision@U 和 Recall@U 这两个评价指标而言，随着用户 U 数量的增加，精准率是逐渐下降的，与此同时，召回率却是逐渐上升的。这是合理的，因为在用户 U 很少的情况下，这些被识别出来的预离网用户往往拥有更高的可能性离网，这导致了精确率较高，但在另一方面，由于用户基数较少，也导致召回率较低。第三，随着用户 U 的增加，

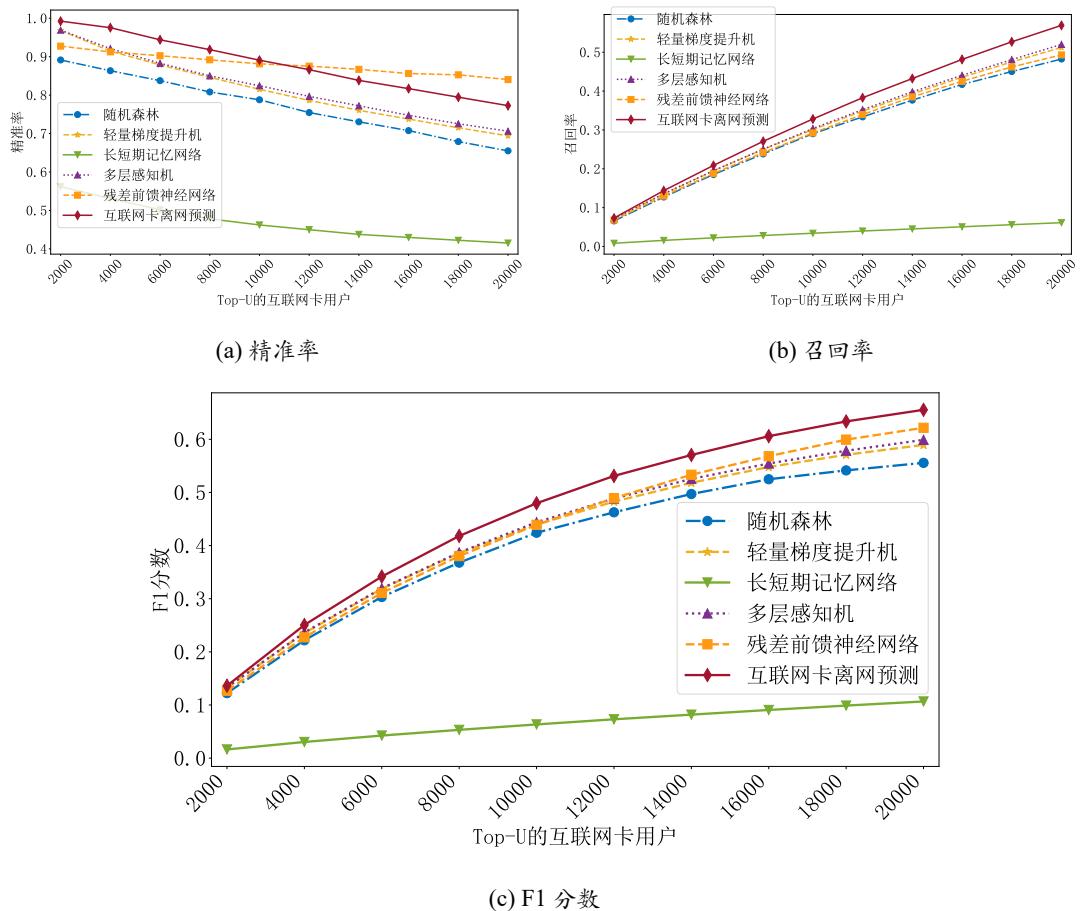


图 4-15 互联网卡 Top-U 用户的分类指标性能对比图

Precision@U 的下降趋势和 Recall@U 的增长逐渐放缓的趋势共同说明了随着用户 U 的增加，从中识别出离网用户变得越来越困难。此外，当 Top 用户数量大于 12000 时，残差前馈神经网络的精确率要高于其他方法是因为被添加到残差前馈神经网络中的残差连接结构。这个结构大大改善了在反向传播中的梯度消失问题，同时也使得残差前馈神经网络在预测 Top-U 用户时更加平衡，下降趋势也更加平缓。但是，本文提出的 ICCP 模型在 F1 分数这个综合指标上能超过残差前馈神经网络这个基线模型，是因为后者在召回率分数上增长缓慢。

4.5.3 参数影响

在保证了预测性能后，本文进一步探讨了用户性别、年龄、App 使用情况、套餐选择等用户属性参数对预测性能的影响。

性别参数的影响：本文将用户样本分为男性和女性两个子集，采用 $k = 5$ 的 k 折交叉验证方法分别评估模型性能。

图4-16绘制了平均性能度量分数，其中男性和女性用户都有错误条，用来显示模型性能的上下界。本文可以得到以下结论：ICCP 模型对男性和女性均是有

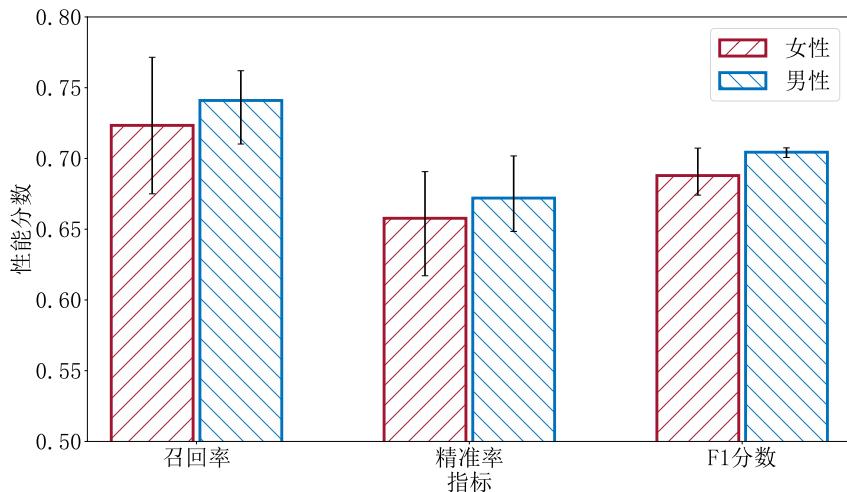


图 4-16 探索性别参数影响的性能对比图

效的，他们的指标得分非常相似，并且与系统的整体性能相当。如，对于召回率、精准率和 F1 分数的指标，女性用户可以分别获得 0.72、0.66 和 0.69 的平均分，而男性用户可以分别获得 0.74、0.67 和 0.71 的平均分。另一方面，本文可以发现男性的指标得分略大于女性用户，这与男性用户比女性用户有更多的流量消耗行为是一致的。这个现象可以解释为，流量消费较多的男性用户离开运营商的行为，更容易被学习模型被捕捉到。

年龄参数的影响：为了研究用户年龄的影响，本文将 IC 用户分为 13 个年龄组，年龄从 16 岁到 80 岁，每个年龄组的范围为 5 岁。

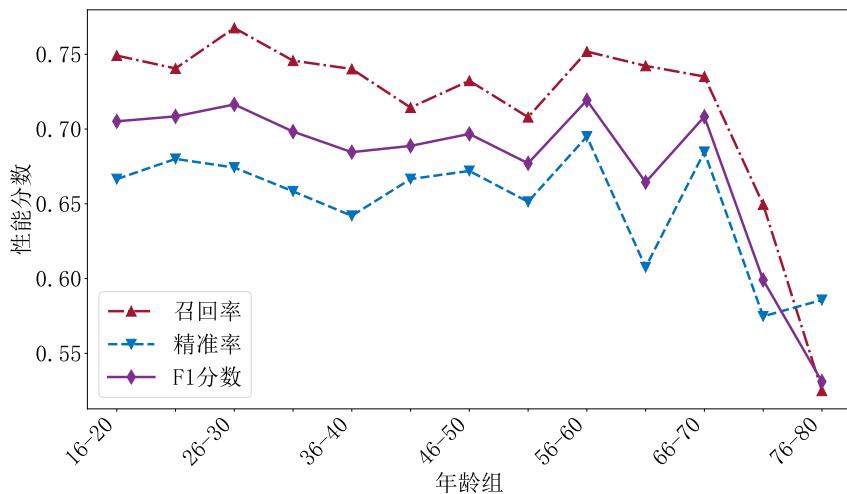


图 4-17 探索年龄参数影响的性能对比图

图4-17显示了ICCP模型在不同年龄组中获得的召回率、精准率和F1分数的平均指标得分。虽然16岁至60岁用户的分数略有变化，但几乎所有的分数都

在 0.7 以上，这意味着 *ICCP* 可以在所有用户上稳健运行，而不受用户年龄影响。另外，对于 16 岁至 35 岁的用户，他们可以获得最高的精度分数，这是因为年轻用户在互联网服务中更活跃，他们在离开系统前的异常行为更容易被识别出来。另一方面，对于 61 岁至 80 岁的用户，本文可以看到指标得分有严重的抖动，这是由于老年用户在互联网服务中不太活跃，很难捕捉他们的网络使用行为导致的。

APP 使用频次参数的影响：本文通过对用户应用程序使用频率的排序，将用户样本分为三个级别，即：高、中、低。

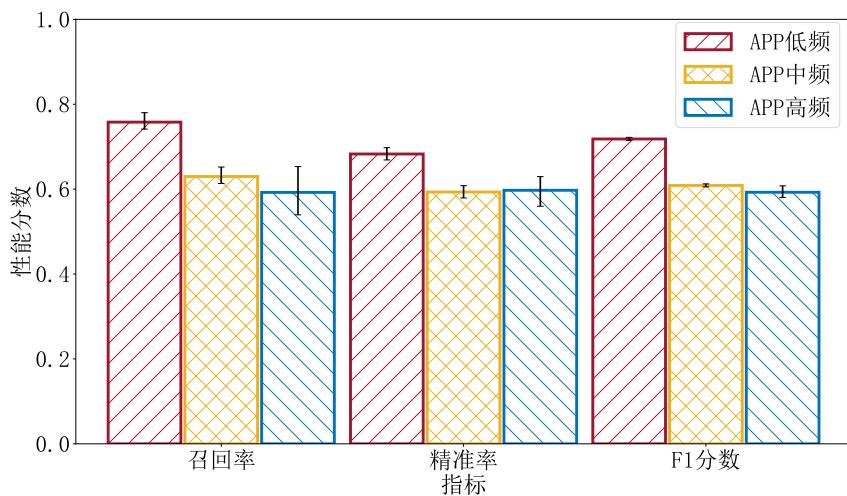


图 4-18 探索 APP 使用频次参数影响的性能对比图

图4-18显示了采用 $k = 5$ 的 k 折交叉验证方法对三组 APP 使用水平不同的互联网卡用户的平均度量得分和误差条。我们可以看到，*ICCP* 模型在 APP 使用频率中等和较高的用户中都能很好地工作，这两个用户的指标得分非常相似。但是可以观察到，APP 使用频率较低用户的指标得分比其他 App 使用级别的用户要大，这与本文之前的分析是一致的，低 App 使用频率的特征可以有效区分出离网用户。例如，对于召回率、精确度和 F1 分数的指标，APP 使用频率较低用户组可以分别获得 0.76、0.68 和 0.72 的平均分，APP 使用频率中等用户组可以分别获得 0.63、0.59 和 0.61 的平均分，而 APP 使用频率较高用户组用户可以分别获得 0.59、0.58 和 0.59 的平均分。

套餐价格参数的影响：为了检验用户套餐选择的影响，本文采用 k 折交叉验证方法，用误差条图绘制前 2 个受欢迎套餐（例如，19 元和 39 元）的平均度量分数，如图4-19所示。本文可以观察到，*ICCP* 对这两种套餐的用户都可以稳健地工作，其中他们的精准率度量得分非常相似，并且与系统的总体性能相当。此外，本文可以看到 39 元套餐的指标得分（例如，召回率和 F1 分数）比 19 元套

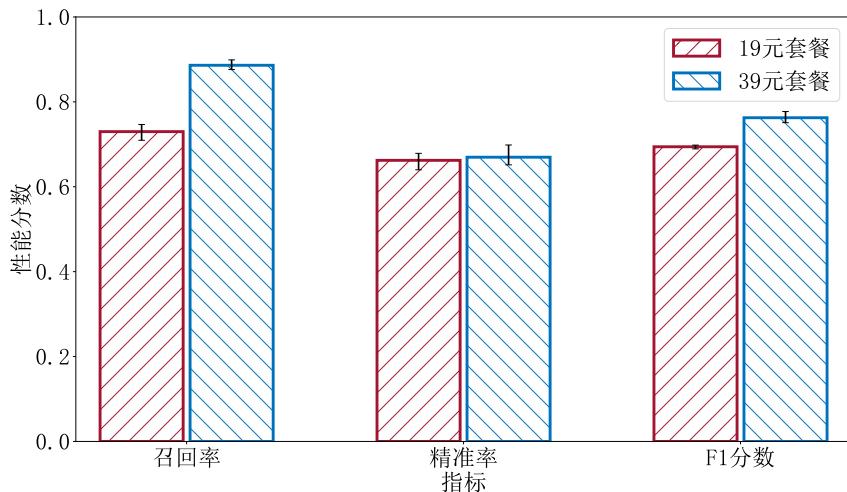


图 4-19 探索套餐价格参数影响的性能对比图

餐的用户略大，这是因为 19 元套餐比 39 元套餐有更多的离网用户，从而带来了更多的预测挑战。

4.5.4 消融实验

表 4-1 消融实验

	AUC	PR-AUC	F1 分数	召回率	精准率
所有特征	0.9754	0.7749	0.7022	0.7464	0.6630
-目标编码	0.8656	0.4646	0.4548	0.4783	0.4335
-账户余额	0.9441	0.6420	0.5750	0.5795	0.5706
-CDR 序列	0.9727	0.7380	0.6781	0.7378	0.6274
-异常天数	0.9752	0.7742	0.7014	0.7513	0.6577
-开卡月份	0.9745	0.7699	0.6970	0.7392	0.6593
-流量序列	0.9735	0.7624	0.6912	0.7336	0.6535
-年龄	0.9735	0.7624	0.6912	0.7336	0.6535
-活跃熵	0.9439	0.6411	0.5716	0.6355	0.5195
-APP 使用频次	0.9712	0.7321	0.6754	0.7668	0.6035

在本小节中，本文将进行消融实验来验证提取特征的有效性。消融实验结果如表4-1所示。本文可以观察到，对于本文提取的主要特征，它们可以显著地影响预测性能，特别是目标编码和帐户余额这两个特征。特别是，当去除目标编码、账户余额和活跃熵特征时，精度从 0.6630 下降到 0.4335、0.5706 和 0.5195，性能分别下降 34.6%、13.9% 和 21.6%。同样地，对于 F1 分数和召回率，分数可以分别从 0.7022 降低到 0.4548、0.5750 和 0.5716，从 0.7464 降低到 0.4783、0.5795

和 0.6355。

4.6 本章小结

由于运营商互联网卡的用户数据规模较大，异构特征显著，且离网时间没有固定规律，因此对互联网卡用户离网用户做出全面、精准和高效的预测是非常困难的。首先，本章从互联网卡用户离网趋势、离网行为和离网原因等做了详细的分析，得到本模块需在本月初就给出离网预测结果的结论。然后，本章基于数据分析的结果从用户的属性和行为两类数据中分别提取了能够明显区别互联网卡离网用户和正常用户的静态画像特征和序列特征。最后，本章设计和实现了一种融合主成分分析算法和自注意力机制的互联网卡用户离网预测模型，能够高效利用用户的画像特征和序列特征，最后在当月初向运营商和以下两个模块输出当月的潜在离网用户名单和对应的离网风险值列表，为后续工作展开做铺垫。本章还使用真实世界的某个运营商的数据来检验模型真实性能。从总体性能评估、参数影响和消融实验等角度全面地验证了 *ICCP* 模型的有效性。此外还评估了不同参数对于 *ICCP* 模型有效性的影响。通过分析上述实验结果，本文发现 *ICCP* 在不同参数设置的情况下，都具有较好的健壮性。

第5章 用户离网偏好感知的挽留策略匹配算法设计

在得到了互联网卡用户离网预测模块给出的潜在用户离网名单和对应的离网风险值后，本文把这样的用户称之为预离网用户。接下来，本文将从数据、特征等上下文中提取相关偏好特征，以推断预离网用户个性化的离网偏好，以便于针对离网偏好匹配相应的挽留策略。最后，本文针对实际应用场景设计了一种在资源有限上下文中的感知用户离网偏好的挽留策略匹配模块，用以向预离网用户匹配合适且性价比最佳的挽留策略。

5.1 离网偏好模块描述

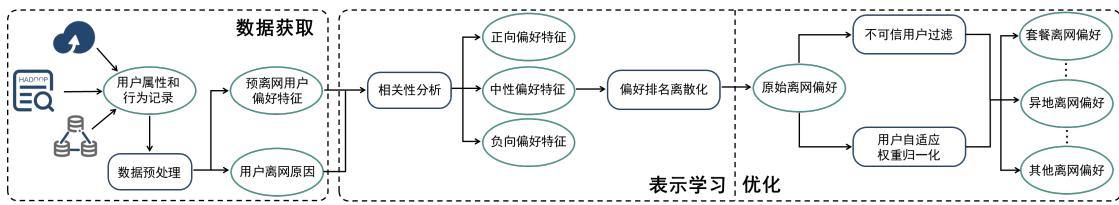


图 5-1 离网偏好表征模块示意图

离网偏好模块的目标是找到一个准确的、可解释的表示方法来表示离网预测模块给出的预离网用户的离网偏好。因此，本章首先限制了可用数据所能反映的离网原因的范围。在此基础上，运用耦合分析方法检验了各离网原因的独立性。接下来，本章通过提出的偏好排序归一化技术提取用户离网偏好。最后，对不可靠用户进行筛选，并实现用户自适应的权重归一化技术，来表征预离网用户的离网偏好。其中，5.2 节将介绍数据分析的详细内容，5.3 节将阐述离网偏好表征的具体流程。

5.2 离网偏好相关数据分析

5.2.1 离网原因与偏好的相关性分析

如图5-2所示为互联网卡用户离网原因分布，从中可以看出，离网原因有几十种，且各不相同。因此，本文选取用户数量排名前 10 位的离网原因，并绘制出相应的分布。

如图5-3所示，离网原因服从长尾分布，前 10 名离网原因的人数占总离网原因人数的 90%。因此，本文选择前 10 个离网原因来代表互联网卡用户的离网偏好是合理的。然而，由于现有数据表达能力有限，本文在 10 大离网原因中取消了 5 个，分别是号卡太多、无使用需求、其他、卡故障和已办宽带。具体来说，在现有的用户属性表/通话表/流量表/APP 表/停机表等表中，没有与上述 5 个原

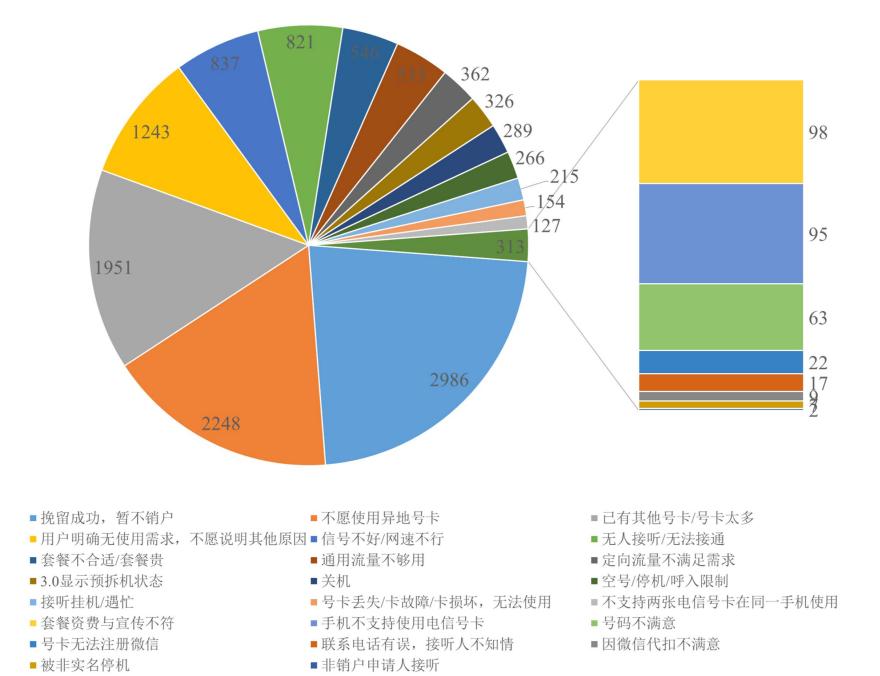


图 5-2 互联网卡用户所有离网原因示意图

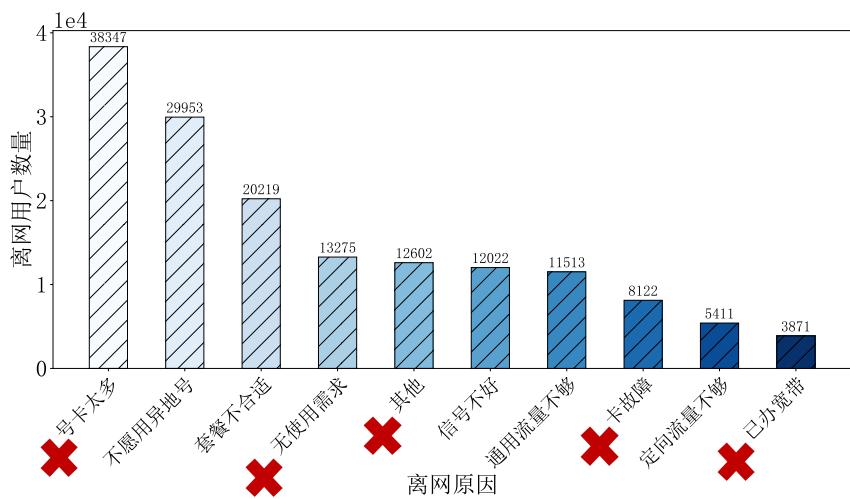


图 5-3 互联网卡用户可建模的离网原因示意图

因直接甚至间接相关的字段，比如互联网卡用户的号卡信息，SIM 卡质量信息，是否已办宽带信息等，因此无法从现有数据分析出因为上述 5 个原因而离网的用户。

本文想知道，单一的离网原因是否可以完全代表预离网用户的离网偏好。因此，本文选取 20 万个离网用户来计算每两个离网原因之间的重叠程度。

本文用杰卡德相似系数来计算重叠度，计算公式(5-1)如下式所示。

$$J(R_A, R_B) = \frac{|R_A \cap R_B|}{|R_A \cup R_B|} \quad (5-1)$$

其中 R_A, R_B 分别表示因为离网原因 A 和 B 的离网用户 ID 集合。

表 5-1 离网原因耦合分析表

	套餐不合适	信号不好	异地号卡	通用流量不够	定向流量不够
套餐不合适	1	0.04	0.63	0.71	0.06
信号不好	-	1	0	0	0
异地号卡	-	-	1	0.75	0.05
通用流量不够	-	-	-	1	0
定向流量不够	-	-	-	-	1

从表5-1中，本文可以得出这样的结论：由于套餐昂贵、异地号卡、通用流量不足等原因高度重叠，从而一起导致了用户的离网。这个现象暗示本文，部分离网用户的离网原因分布与个人偏好相关，可能有多个离网原因导致用户离网。此外，因信号不好或定向流量不足而离网的离网用户相对独立，而高使用频次和高消费的离网用户大多为具有显著维系价值的外地用户。

综上所述，本文需要一个不同权重的离网原因数据结构来捕捉潜在离网用户的离网偏好。严格来说，本文定义了一个离网原因向量 $\vec{Cp} = [r_1, \dots, r_n]$ ，本文把这称之为叫做离网偏好向量，用来表示潜在离网用户的离网偏好。然后本文定义 $r_i \in \vec{Cp}$ 表示潜在离网用户的第 i 个离网原因的权重，其中 n 表示离网原因的数量。因此，本文得到约束如下： $r_c^1 + r_c^2 + \dots + r_c^n = 1$ 。具体来说，在本文的场景中，离网原因包括套餐昂贵、网速低、定向流量不足、非本地互联网卡和通用流量不足，即 $n = 5$ 。

5.2.2 偏好特征双重排名离散化

相关特征选择：

表 5-2 离网原因-偏好特征对应表

	偏好特征 1	相关性 1	偏好特征 2	相关性 2
套餐不合适	出账金额	正向	账户余额	负向
信号不好	最大网速	负向	平均网速	负向
异地号卡	异地流量记录条数	正向	异地流量消耗值	正向
通用流量不够	通用流量记录条数	正向	通用流量消耗值	正向
定向流量不够	定向流量记录条数	正向	定向流量消耗值	正向

本文首先人工选择了与相应离网原因高度相关的偏好特征。例如，如表5-2所

示，本文为套餐不适合这个离网原因选择了出账金额和账户余额这两个偏好特征。

基于等频分箱的双重排名离散化：

为了表示离网预测模块给出的预离网用户的离网偏好，本文要计算出某一特定预离网用户在所有潜在离网用户中所处的水平。具体来说，如果某个预离网用户 c 在某个特定离网原因 cr 所属的偏好特征上排名超过了绝大多数用户，那么本文假设该预离网用户 c 很有可能因为离网原因 cr 而离网。此外，由于每个偏好特征的分布和性质不同，本文需要一种方法来推导出离网原因的权重并且能够与用户排名成比例。基于以上假设，本文采用等频分箱技术对表5-2中的上述特征分别进行离散化处理。接着，本文能把每个偏好特征从值域 $[min_val, max_val]$ 映射到值域 $[1, n_c]$ ，其中 min_val , max_val 和 n_c 分别表示偏好特征的最小值，最大值和分箱数量。在本文的设置当中， $n_c = 100$ 。

对于和对应离网原因是正相关关系的偏好特征向量 \vec{x} 来说，特征 x 的排名向量 $\overrightarrow{R_x}$ 等于

$$\overrightarrow{R_x} = \frac{\vec{x} - min_val}{max_val - min_val} * (n_c - 1) + 1. \quad (5-2)$$

对于和对应离网原因是负相关关系的偏好特征向量 \vec{y} 来说，特征 y 的排名向量 $\overrightarrow{R_y}$ 等于

$$\overrightarrow{R_y} = \frac{\vec{y} - min_val}{max_val - min_val} * (n_c - 1) + 1. \quad (5-3)$$

5.3 离网偏好表征

5.3.1 加权表征离网偏好

在推导出所有偏好特征的排名向量集合之后，本文可以依次计算出每个预离网用户的原始离网偏好向量

$$\overrightarrow{C_{pr}} = [pr_1, \dots, pr_n] = Concat(\sum_{j=1}^2 0.5 \times R_{ij}, for i = 1, \dots, n). \quad (5-4)$$

其中 i 表示第 i 个离网原因， R_{ij} 表示互联网卡预离网用户第 i 个离网原因对应的第 j 个偏好特征的排名， $Concat$ 函数负责将 5 个离网原因的权重拼接成一个原始离网偏好向量 $\overrightarrow{C_{pr}}$ 。具体来说，例如，某个预离网用户 c 的原始离网偏好向量 $\overrightarrow{C_{pr}}$ 可能等于 $[0.9, 0.7, 0.01, 0.02, 0.4]$ ，这意味着因为套餐不合适、低网速、定向流量不足、非本地互联网卡和通用流量不足而离网的权重分别为 0.9, 0.7, 0.01, 0.02 和 0.4。

5.3.2 不可信用户过滤机制

首先，虽然离网预测模型已经过滤掉了大部分正常用户，但仍有少数正常用户被遗漏。其次，干预的预算有限，只能覆盖部分离网用户。第三，典型活跃离网用户的离网偏好特征的排名和要高得多。基于以上三个原因，本文在表征用户离网偏好之后设置了一个不可信用户过滤模块。具体来说，排名和小于预先定义的阈值 t 的预离网用户将被过滤，即离网偏好字段的平均排名小于 t/n 。由于这些预离网用户的离网偏好与其他预离网用户相比并不值得注意，这些预离网用户将被移除用来保证有限预算的投资回报率 (ROI)。

5.3.3 用户自适应权重归一化

虽然预离网用户的离网偏好是个性化的，但对于每一个预离网用户来说，离网原因权重的贡献率之和应该等于 1。为了统一离网偏好向量元素的量级，本文采用改进的 softmax 函数，通过用户自适应的方式表示预离网用户的离网偏好向量 \vec{C}_p ，如下公式 5-5 所示。

$$\vec{C}_p = \frac{e^{pr_i - \max(\vec{C}_{pr})}}{\sum_{i=1}^n e^{pr_i - \max(\vec{C}_{pr})}} \quad (5-5)$$

其中 $\max(\vec{C}_{pr})$ 表示原始离网偏好向量 \vec{C}_{pr} 的最大值， e 表示自然常数。最后，本文可以获得预离网用户 c 的离网偏好向量 \vec{C}_{pc} 和预离网用户集 C 的离网偏好矩阵 \vec{C}_p 。

5.4 挽留策略匹配模块描述

5.4.1 挽留策略匹配问题形式化

为了建模挽留策略匹配模块，本文首先需要把匹配问题形式化，以保证本文的框架能够泛化到其他不同应用场景并且用支持不同算法、模型等实现具体功能。以下是具体描述。

对于运营商等企业，他们会采取一些挽留策略，如营销宣传、优惠政策等来维系预离网用户。为保持通用性，本文定义挽留策略集 $\vec{E} = [E_0, E_1, E_2, \dots, E_i, \dots, E_M]$ ，其中 0 表示不进行任何干预， E_i 表示第 i 个的挽留策略。在本文的情景中，挽留策略可以分为以下四种：话费、流量、通话和 APP。

为了使本文提出的框架能够感知预算，挽留策略的成本被形式化为向量 $\vec{E} = [E_0, E_1, E_2, \dots, E_i, \dots, E_M]$ ，其中 E_i 表示第 i 个挽留策略的成本。其中， $E_0 = 0$ 表示企业对预离网用户不做任何干预时，成本等于 0。

对于在由离网预测模块给出的预离网用户集合 C 中的任何一个预离网用户

c , 本文定义一个二元状态变量 y_c 来表示下个月该预离网用户 c 是否会真的离网, 其中 $y_c = 1$ 表示下个月预离网用户 c 会离网, $y_c = 0$ 则表示相反的意思。本文还定义了一个二元状态变量 z_c 来表示在执行干预后, 预离网用户 c 是否被成功挽留, 其中 $z_c = 1$ 表示预离网用户 c 被成功挽留, $z_c = 0$ 则相反。 \vec{x}_c 被定义为企业实施到预离网用户 c 的挽留策略。 $\vec{x}_c = [x_{c0}, x_{c1}, \dots, x_{cj}, \dots, x_{cM}]$, 其中 $x_{cj} = 1$ 表示用户 c 采用了第 j 个挽留策略, $x_{cj} = 0$ 表示相反. 需要特别指出的是, $x_{c0} = 1$ 表示企业对预离网用户 c 不采取任何干预措施。

因此, 匹配模块的优化目标可以形式化为

$$\begin{aligned} & \max \sum_{c \in \mathcal{C}} y_c z_c \\ \text{s.t. } & \sum_{\forall c} \vec{x}_c \cdot \vec{E} \leq B, \\ & LV_c \geq \vec{x}_c \cdot \vec{E}, \forall c \end{aligned} \quad (5-6)$$

其中 B 表示为企业预先设定的预算, LV_c 表示为预离网用户 c 的生命周期价值。公式(5-6)代表的意义为企业预先给定的预算 B 的前提下, 本模块的目标是最大化挽留成功的离网用户数。第一个约束意味着所有的挽留策略投入成本和要小于等于预算 B . 第二个约束旨在通过限制投入到预离网用户 c 的成本之和要小于等于其生命周期价值, 即用贪心方式来保证企业的最终收益是非负的。

5.4.2 模块设计思想

本文对于匹配模块的设计思想是把挽留策略匹配问题建模成一个多臂老虎机问题。原因如下:

1. 本文只给每个用户匹配一个挽留策略。
2. 假设每个挽留策略对某个用户是否干预成功的指示变量是服从某一概率分布的, 但是每个挽留策略不一定是独立的, 所以不同的拉杆之间可能有耦合关系。
3. 目的是最大化挽留收益。这些都符合典型的多臂老虎机问题设置, 其中一个时间步对应干预一个用户, 一个拉杆对应一个挽留策略, 老虎机的累积奖励对应企业的最终挽留收益。

基于上述原因, 本文设计了如下架构, 如图5-4所示。

1. 为了弥补缺失直接用户偏好数据的问题, 本文基于离网偏好模块给出的预离网用户离网偏好和挽留成功率的先验分布初始化一个奖励生成模型。
2. 为了给互联网卡预离网用户匹配合适的挽留策略, 本文设计了策略匹配算法。它通过接收离网预测模块给出的预离网用户 ID 和离网风险, 输出其判定合

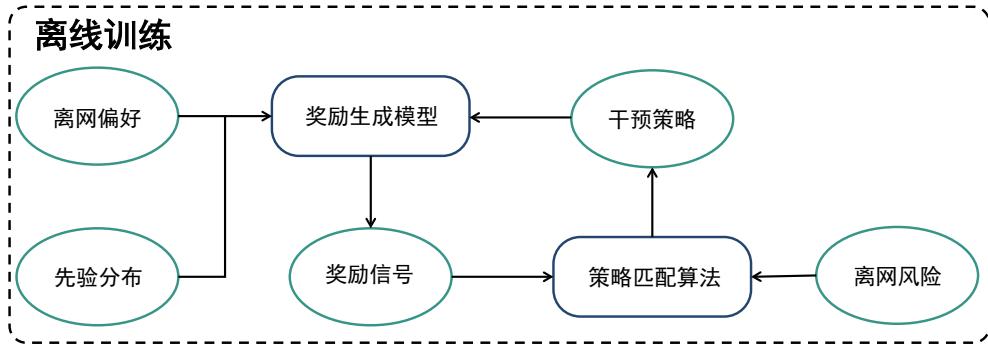


图 5-4 挽留策略匹配模块图

适的挽留策略给奖励生成模型。然后奖励生成模型接收预离网用户 ID 和挽留策略返回相应的奖励信号。最后策略匹配算法根据相应的奖励信号调整自身参数。

5.4.3 挽留策略匹配问题建模

在本文的场景中，多臂老虎机问题可以表示为五元组 $\langle \mathcal{A}, \mathcal{E}, \mathcal{C}, \mathcal{A}', \mathcal{R} \rangle$ 。

智能体 (\mathcal{A}) MAB 问题的目标是最大化离网预测模块输出的预离网用户集 \mathcal{C} 中的挽留成功的真实离网用户数，如下所示。

$$\begin{aligned} & \max \sum_{c \in \mathcal{C}} y_c r_c, \quad s_c \sim \mathcal{R}(\cdot | s_c) \\ & \text{s.t. } E_{s_c} \leq B, \\ & LV_c \geq E_{s_c}, \forall c \end{aligned} \tag{5-7}$$

公式(5-7)是公式(5-6)的具体实现之一，其中 s_c , r_c 分别表示与预离网用户 c 匹配的挽留策略，匹配挽留策略 s_c 后所得的奖励。

环境 (\mathcal{E}) \mathcal{E} 包含用户侧信息和物品侧信息。更具体地说，本文接受离网预测模块生成的预离网用户集合 \mathcal{C} 作为用户侧信息。此外，本文将互联网卡挽留策略集 \mathcal{S} 定义为物品侧信息，这其也是通用挽留策略集 \mathcal{M} 的具体实现。因此，互联网卡挽留策略集 \mathcal{S} 等于集合 $\{s_0, \dots, s_M\}$ ，本文定义了 $s_m \in \mathcal{S}$ 来表示任何在挽留策略空间中的挽留策略。相应的，挽留策略集的成本集合被形式化为向量 $\vec{E} = [E_0, E_1, E_2, \dots, E_i, \dots, E_M]$ ，其中 E_i 表示第 i 个挽留策略的成本。需要特别指出的是，其中 $E_0 = 0$ 表示企业在预离网用户不做任何干预时，成本等于 0。

上下文 (\mathcal{C}) 首先也是最重要的，本文引入预算 B ，以设置一个反映实际应用中资源有限的环境。此外，本文定义了离网偏好模块给出的离网偏好矩阵 C_p 和离网预测模块给出的离网风险向量 $\vec{C_r}$ 作为上下文信息，使所提出的框架具有上下文感知能力，从而提高整体性能。

动作 (\mathcal{A}') 由于匹配挽留策略对应于拉动拉杆，本文定义多臂老虎机中有 $M + 1$ 个拉杆。正式地说，本文将可用拉杆集合定义为互联网卡挽留策略集 \mathcal{S} 。

奖励 (\mathcal{R}) 对于每一个挽留策略 s ，本文定义了它的期望回报为

$$Q(s) = \mathbb{E}_{s \sim \mathcal{R}(\cdot|s)}[r] \quad (5-8)$$

。因此，当离网用户具有确定的离网偏好时，至少存在一种挽留策略的奖励期望大于或等于其他挽留策略的奖励期望。本文定义最佳奖励期望为

$$Q^* = \max_{s \in \mathcal{S}} Q(s) \quad (5-9)$$

。本文引入当前挽留策略的懊悔，即当前挽留策略的奖励期望与最佳挽留策略的奖励期望之差，可被以下公式计算

$$R(s) = Q^* - Q(s) \quad (5-10)$$

。自然地，累积懊悔是干预了 N 个预离网用户后的懊悔的总和。换句话说，对于一个序列 N 步决策过程 s_1, s_2, \dots, s_N 而言，累积懊悔

$$\sigma_R = \sum_{n=1}^N R(s_n) \quad (5-11)$$

。因此，多臂老虎机问题的目标是使累积奖励最大化，也等于使累积遗憾最小化。

5.5 挽留措施匹配算法设计

5.5.1 奖励生成模型设计

基于以下三个原因，本文设计了奖励生成模型。

1. 本文的数据缺乏直接的干预记录，如用户 id、匹配的挽留策略、干预结果等。然而，本文获得了不同离网原因所匹配的挽留策略成功概率的统计数据。
2. 受基于人类反馈的强化学习 (RLHF) 的启发，本文设计的这个模块可以通过接受预离网用户的离网偏好来生成反映人类偏好的奖励信号。
3. 由于干预记录数据的稀疏性，奖励生成模型可以生成合成数据用于训练后续算法，以降低相关数据的收集和清理成本。

为此，本文实现了一种接受预离网用户的离网偏好和相应的挽留策略作为输入，并返回信号值作为奖励的多臂老虎机 MAB。因此，奖励生成模型的拉杆数量需要满足约束 $arms = (M + 1) \times N$ ，其中 N 为离网原因数， M 为挽留策略数。具体而言，如图5-5所示，奖励生成模型有 N 行和 $M + 1$ 列的拉杆，其中

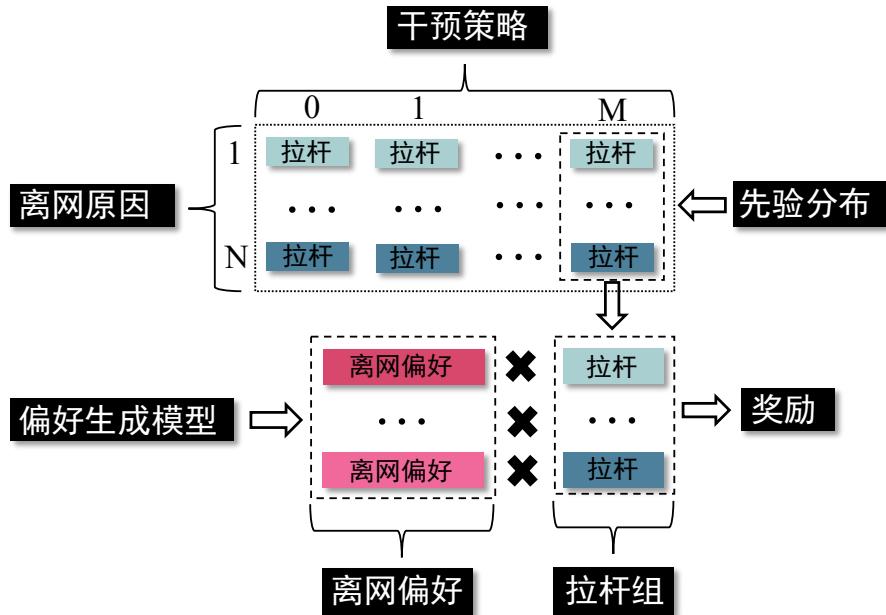


图 5-5 奖励模型内部示意图

arm_{ij} 表示对于因为离网原因 i 离网的用户匹配挽留策略 j 的奖励期望。一列的拉杆被合称为一个拉杆组。

奖励生成模型中的拉杆可以被任意分布初始化，包括领域知识分布、均匀分布、高斯分布、二项分布、伽玛分布、泊松分布和指数分布等。由于本文统计了不同离网原因对应的挽留策略成功概率。本文可以设定上述分布的期望等于平均成功概率。对于基于领域知识的分布，本文用不同离网原因对应的挽留策略平均成功概率填充。

接下来，本文会介绍产生被称为奖励的信号值机制。首先，离网偏好模块将输出预离网用户 c 的离网偏好向量 \vec{Cp}_c 。其次，策略匹配算法将匹配预离网用户 c 以挽留策略 s_c 。接着，奖励生成模型将挽留策略 s_c 作为输入，然后选择相应的拉杆组。然后，奖励生成模型将离网偏好向量 \vec{Cp}_c 与拉杆组 \vec{Ag}_c 的点积 \mathbb{E}_{s_c} 为挽留策略 s_c 的奖励期望，如公式(5-12)所示。

$$\mathbb{E}_{s_c} = \vec{Cp}_c \cdot \vec{Ag}_c \quad (5-12)$$

最后，奖励生成模型将根据 0 到 1 的均匀分布生成随机数 rn 。如果生成的随机数小于或等于点积 \mathbb{E}_{s_c} ，奖励生成模型将返回奖励 $r_c = 1$ ，否则为 $r_c = 0$ 。具体可见公式(5-13)

$$r_c = \begin{cases} 1, & \text{if } \mathbb{E}_{s_c} \leq rn \\ 0, & \text{otherwise} \end{cases} \quad (5-13)$$

由公式(5-13)可知，单个挽留策略的维系成功概率服从伯努利分布。假设有 $M+1$ 个挽留策略，那么如果我们尝试匹配无限次的话，将得到所有挽留策略的平均奖

励集合 $\theta = (\theta_0, \dots, \theta_M)$ 。接下来，如果策略匹配算法选择一个挽留策略 s ，那么本文可以得到一个奖励 $r \in \{0, 1\}$ 。这个奖励 r 实际上是从伯努利分布中抽取的样本，因为 $\mathbb{P}[r = 1|s, \theta] = \theta_s$ 并且 $\mathbb{P}[r = 0|s, \theta] = 1 - \theta_s$ ，并且这与观测到的事实也是一致的。

5.5.2 基于汤普森采样的挽留策略匹配算法

首先，本文选择汤普森采样 (TS) 作为基础算法，原因如下。TS 算法是一种蒙特卡罗抽样方法，它对所有拉杆的奖励概率进行抽样。更具体地说，TS 算法假设每次拉动拉杆的奖励期望服从一定的概率分布，然后选取其中奖励期望最高的拉杆。然而，获得所有拉杆奖励期望的成本是巨大的，也是不现实的。因此，TS 采用基于抽样的策略，即根据所有挽留策略的奖励概率分布进行一轮抽样，得到所有挽留策略的样本，然后 TS 在所有样本中选择奖励最高的作为匹配挽留策略。因此，在贝叶斯框架下，TS 比贪心算法具有天然的优势，因为前者是通过随机抽样而非通过后者的简单样本平均方法来估计奖励期望的。为了进一步挖掘上下文信息，本文提出了一种针对运营商互联网卡用户的挽留策略匹配算法 Internet Card Strategy Matching (ICSM)。在算法 5-1 中给出了所提出的 ICSM 算法的伪代码。但是这样通过激励用户来避免用户流失的机制可能会出现如下一种情况：用户通过某种途径了解了 UPRF 的工作原理，然后假装出将要离网的表现，从而免费获得 UPRF 给出的相应挽留策略。

5.6 实验评估与结果分析

5.6.1 实验设置

为了证明本文所提出的 UPRF 框架和 ICSM 算法的有效性，本文收集了年龄在 16-81 岁之间的正常个人互联网卡用户。在 2020 年 11 月收集的训练数据集有 30 万名用户，其中包括 23112 名离网用户。而在 2020 年 12 月收集的测试数据集有 7.5 万用户，其中包括 5939 名离网用户。两个数据集的正负样本不平衡比例非常接近，一个是 11.98，另一个是 11.62。

基准模型：为了证明本文提出的 ICSM 算法的优越性，本文设计并实现了以下可比较的基准算法，包括强化学习算法。需要注意的是，虽然这些算法在各个领域的文献中已被广泛采用，但没有应用于互联网卡用户挽留策略匹配的。此外，为了保证比较的公平性，所有基准算法都采用了与 ICSM 算法相同的离网风险和离网偏好输入。

- **ϵ -贪婪 (ϵ -Greedy):** 是强化学习中平衡探索与开发的一种简单方法。它指示智

算法 5-1 ICSM: 在资源有限上下文中的投资回报率优先的汤普森采样算法

Input: 预离网用户集 \mathcal{C} , 挽留策略集 \mathcal{S} , 成本向量 \vec{E} , 预算 \mathcal{B} , 离网偏好矩阵 C_p , 离网风险向量 \vec{Cr} , 离网指示向量 \vec{Ci} , 生命周期价值向量 \vec{LV} , 奖励生成模型 RGM

Output: ICSM, 预算 \mathcal{B} , 奖励列表 RL

```

1: 初始化  $S(1) = 0, F(1) = 0;$ 
2: for  $c = 1, 2, \dots, \mathcal{C}$  do
3:   if 预算  $\mathcal{B} <$  挽留策略最小的成本  $\min(\vec{E})$  then
4:     break
5:   else
6:     初始化最大概率  $\text{MaxProb} = -1;$ 
7:     初始化选择拉杆号  $\text{SelectedArm} = -1;$ 
8:     for  $m = 0, 1, \dots, \mathcal{M}$  do
9:       从  $Beta(S_m(t) + 1, F_m(t) + 1)$  分布中采样奖励期望  $r_m$ 
10:      if  $\mathcal{B} >= \vec{E}_m$  and  $LV_c >= \vec{E}_m$  and  $r_m / \vec{E}_m > \text{MaxProb}$  then
11:        最大概率  $\text{MaxProb} = r_m / \vec{E}_m$ ;
12:        选择拉杆号  $\text{SelectedArm} = m$ ;
13:      end if
14:    end for
15:    奖励  $r_c = RGM(C_{pc}, \text{SelectedArm});$ 
16:     $RL$  在尾部追加  $(r_c * Ci_c);$ 
17:     $S_{\text{SelectedArm}}(t + 1) = S_{\text{SelectedArm}}(t) + r_c * Cr_c;$ 
18:     $F_{\text{SelectedArm}}(t + 1) = F_{\text{SelectedArm}}(t) + 1 - r_c * Cr_c;$ 
19:    预算  $\mathcal{B} - = \vec{E}_{\text{SelectedArm}};$ 
20:  end if
21: end for

```

能体选择一个小概率 ϵ 的随机操作，否则就根据当前对奖励的估计选择最佳操作，其中概率 ϵ 是固定的。

- **ϵ -衰减 (ϵ -Decay):** 是 ϵ -贪婪算法的变体。在智能体使用一些在线算法来学习最优行为的情况下，智能体在最初探索更多，并最终在接近目标行为时利用更多。这种从重度探索到重度开发的转变可以通过逐渐减少 ϵ 来实现。在本文的场景中， $\epsilon = \frac{1}{\sqrt{t}}$ 。
- **置信区间上界算法 (UCB):** 是一种在网络广告、推荐系统、临床试验等多个领域平衡探索和开发的流行而有效的技术。UCB 算法以经验均值和方差为基础，为每个行动的期望回报分配一个上界，并在每一轮中选择上界最高的行动。在本文的场景中， $\hat{U}_t(a) = \sqrt{\frac{\log t}{2(N_t(a)+1)}}$ 。
- **汤普森采样 (TS):** 是一种用于在线决策问题的算法，其中行动是按顺序采取的，并且在利用已知的知识以最大化当前绩效和投资积累可能提高未来绩效的新信息之间取得平衡。该算法求解范围广，计算效率高，在多臂老虎机问题中得到了广泛应用。

评估指标：对于挽留策略匹配问题来说，基于以下这四个基础测试结果，分别是真阳性样本 (TP)，假阳性样本 (FP)，真阴性样本 (TN)，假阴性样本 (FN)，本文采用了以下 5 个评价指标来评估相应性能。

- **匹配算法性能：**

- **累加懊悔 (Cumulative Regrets)**：指的是一种衡量算法给出的动作序列与后验最佳动作序列之间表现差距的评价指标。它被定义为一个最优动作序列的期望奖励与算法选择的动作序列的期望奖励之间的差值，与时间步长相关。换句话说，它衡量的是由于算法做出了次优决策，随着轮次的增加其积累了多少懊悔。

- **系统总体性能：**

- **精准率 (Precision)**：指的是一个预离网用户是真实离网用户并且被成功挽留的概率，具体公式为， $\frac{TP}{TP+FP}$ 。
- **召回率 (Recall)**：指的是所有的真实离网用户被成功识别并且被成功挽留的比例，具体公式为， $\frac{TP}{TP+FN}$ 。
- **F1 分数 (F1-Score)**：指的是精准率和召回率的调和平均数，具体公式为， $2 \times \frac{Precision \times Recall}{Precision + Recall}$ 。

- **商业性能：**

- **奖励总和 (Rewards)**：指的是被成功识别和挽留的离网用户的数量，数值和 TP 一样。
- **平均奖励 (AR)**：指的是预离网用户被成功挽留的概率。
- **收入总和 (Total Revenue)**：指的是被成功识别和挽留的离网用户的生命周期价值总和。

5.6.2 预离网用户干预框架性能评估

匹配算法性能：本文首先通过与基准匹配算法的比较来测试所提出的 *ICSM* 算法的性能。

图5-6为5种不同匹配算法在干预互联网卡用户后的累加懊悔值，实线表示5次独立实验下的平均性能，对应的浅色面积表示性能的上下界。然后本文可以得到如下的表述。首先，本文提出的 *ICSM* 每轮累积遗憾次优只比 TS 差。同时，*ICSM* 算法干预了最多的预离网用户，从而获得了与其他基准相比最好的奖励。第二，尽管 TS 和 UCB 在干预的初始阶段表现有效，但在干预的中期，由于预算不足，它们很快就失效了。因为它们沉迷于成功概率较高的策略，同时也付出了较高的代价。最后，观察 ϵ -贪婪算法和 ϵ -衰减算法，本文可以得出结论，这些算

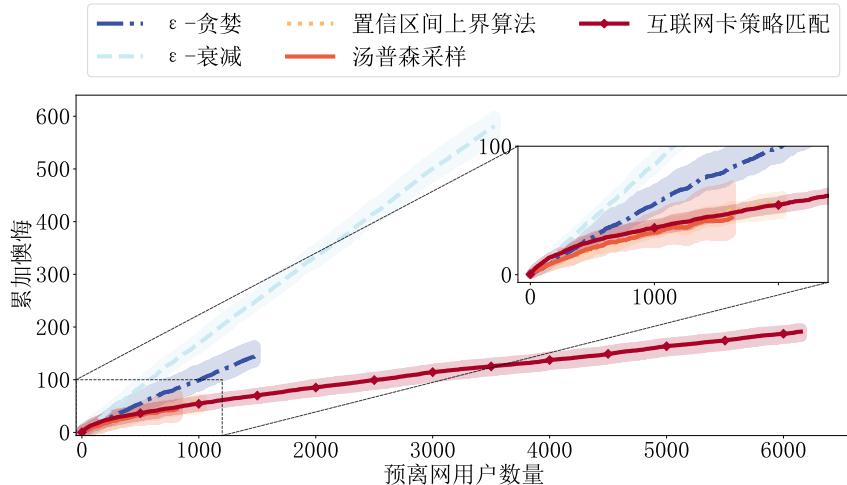


图 5-6 匹配算法性能对比图

法更倾向于成功率较低的策略，从而不能很好地挖掘挽留策略的潜力。

挽留框架总体性能：

为了证明本文提出的框架 UPRF 的优越性，本文检查了框架的整体性能，以评估整个工作流程的有效性，包括离网预测，偏好建模和策略匹配。因为整个框架被建模成了一个分类问题。因此，本文采用精准率、召回率和 F1 分数这些指标来评估整体性能。

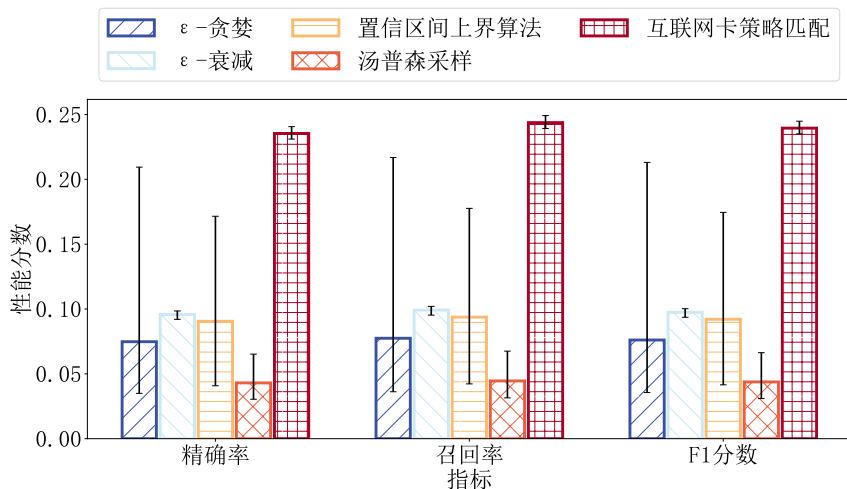


图 5-7 挽留框架总体性能对比图

图5-7显示了各个匹配算法总体性能的平均值和上下界。本文可以进行如下的主要观察。首先，提出的 ICSM 算法在所有指标上都显著优于其他基准算法。例如，ICSM 中精准率、召回率和 F1 分数的平均分为 0.23,0.25,0.24，次优算法 ϵ -衰减的平均分约为 0.08,0.09,0.08。其次是由于误差多重效应导致整体性能较

低。具体来说，系统的整体性能取决于以下两个因素的乘积，一个是离网预测性能，另一个是挽留策略匹配性能。

商业指标：

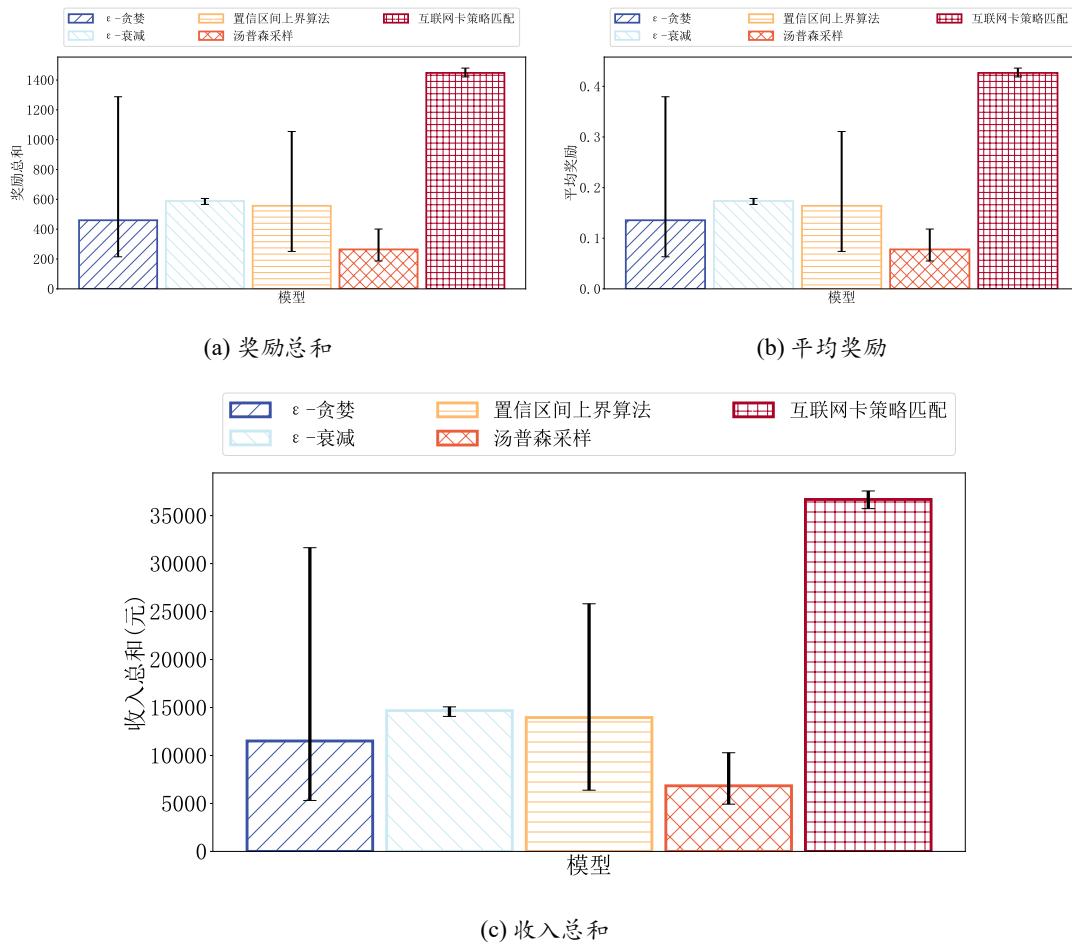


图 5-8 匹配算法商业指标性能对比图

本文选择了三个典型的商业指标来证明所提出的框架的有效性，分别是奖励总和、平均奖励和收入总和。根据图5-8，本文可以得出以下结论。首先，本文可以看到 ICSM 在三个指标上优于所有基线算法。其中， ϵ -贪婪、 ϵ -衰减、置信区间上界算法、汤普森采样的平均奖励的平均得分分别为 0.12、0.16、0.13、0.11，ICSM 的平均奖励平均得分为 0.41，性能分别提高了 242%、156%、215%、273%。其次，本文提出的 ICSM 算法在 5 个独立实验中表现出相当的稳定性，总体性能波动仅为 1%，有利于在工业生产环境中部署。

健壮性测试：在评估了本文提出的框架的总体性能后，本文对先验分布等超参数如何影响整个系统的健壮性产生了兴趣。因此，本文进行了以下参数影响实验。

为了检验本文提出的匹配算法 ICSM 的鲁棒性，本文准备了 6 个常见的先验

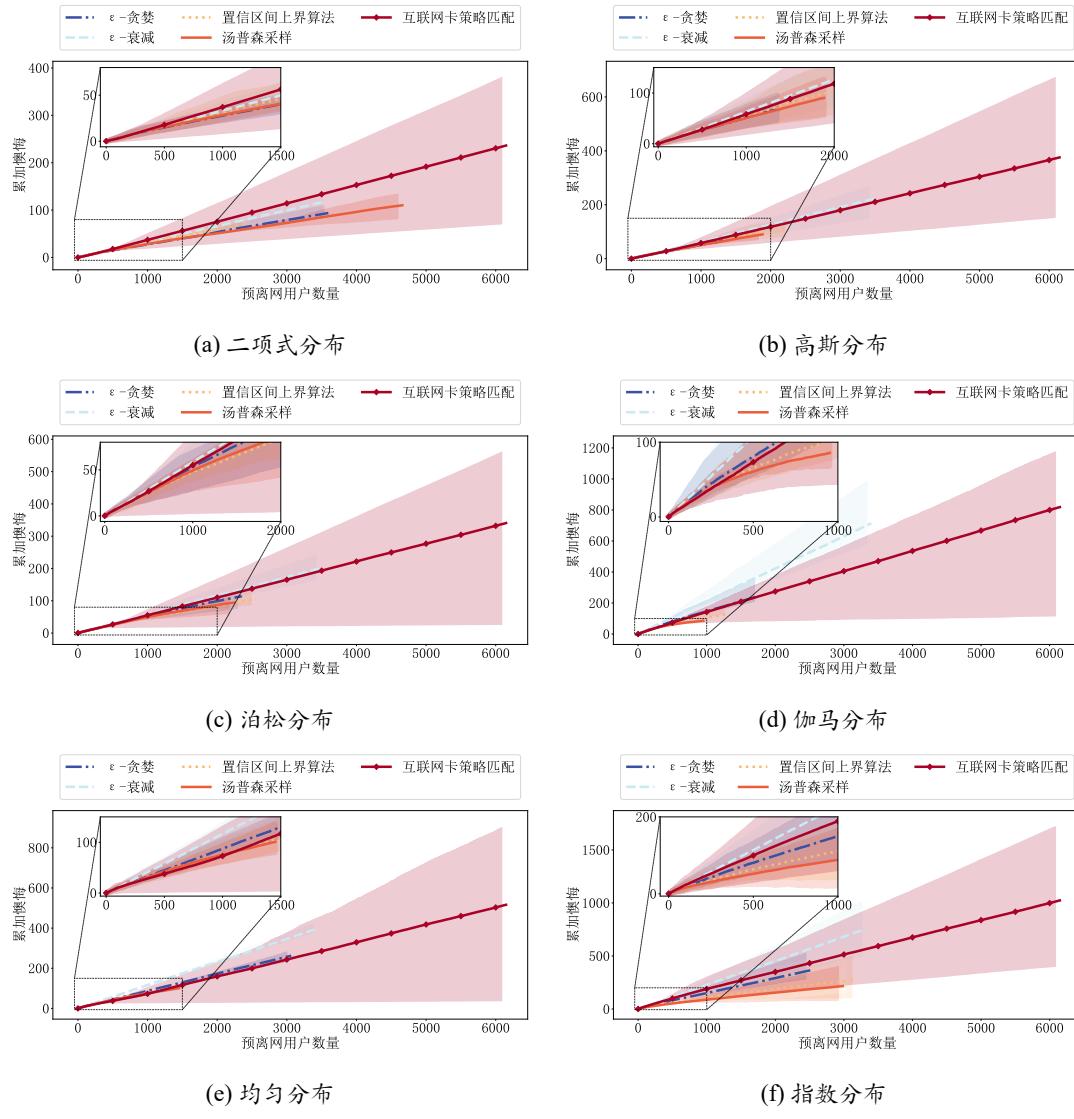


图 5-9 不同先验分布下的匹配算法性能对比图

概率分布。由图5-9可知，*ICSM* 在均匀分布、高斯分布、二项分布、伽玛分布、泊松分布、指数分布等常见概率分布下具有鲁棒性。在上述概率分布中，*ICSM* 均优于所有基准算法。

5.6.3 参数影响

城市：接下来，本文探讨城市层面对商业性能的影响，以找出城乡之间的不平等。本文首先按GDP降序排列城市，并且对城市名称做了脱敏处理，用对应ID代替，如图5-10所示。

我们可以看到，虽然城市之间的奖励总和是不相等的，而且分布不均匀，头部城市用户占比较大。但平均奖励却非常接近，这表明了*ICSM* 算法的鲁棒性，不会因为用户的所处城市对用户持有偏见。

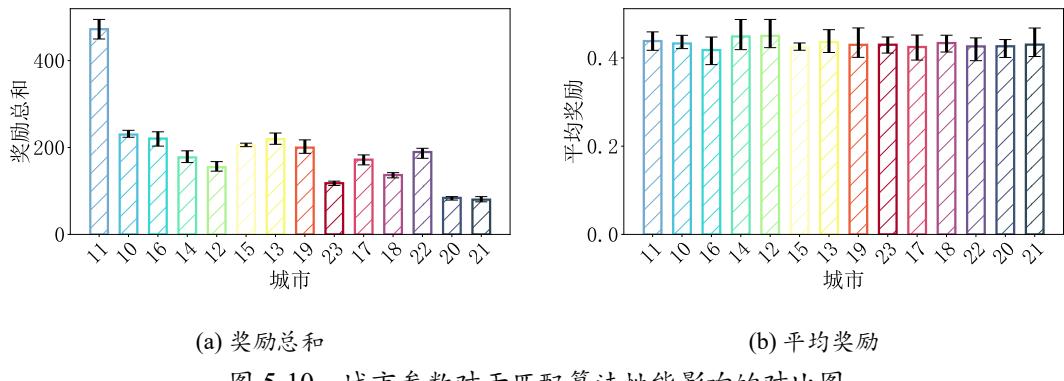


图 5-10 城市参数对于匹配算法性能影响的对比图

年龄：

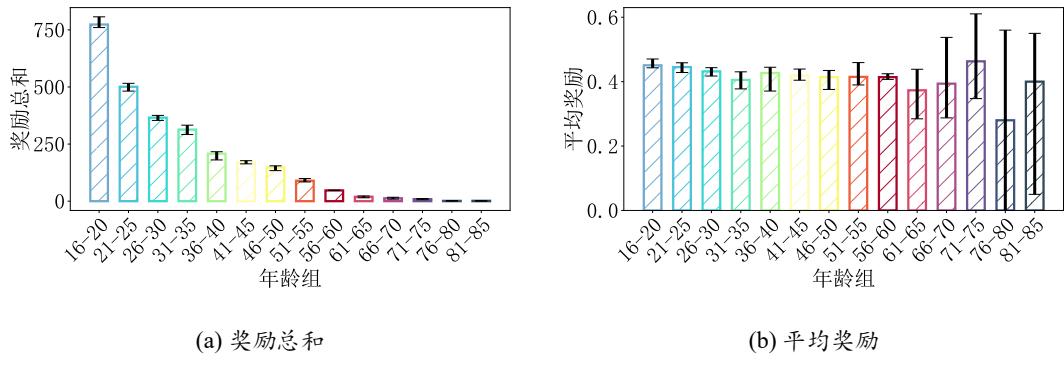


图 5-11 年龄参数对于匹配算法性能影响的对比图

然后，本文探讨年龄对商业性能的影响，以了解不同代际之间的差异。本文首先选择 16 岁到 85 岁的用户。其次，以 5 岁为单位进行年龄分组。从图 5-11 可以看出，虽然各年龄组的奖励不相等，明显呈长尾分布。这个现象显著说明了互联网卡用户呈现年轻态的特点和趋势。与此同时，每个年龄组的平均奖励值却非常接近，这表明本文的 ICSM 算法在年龄特征处具有鲁棒性，不会因为高龄用户的样本稀疏而学习不到他们的离网偏好以匹配合适的挽留策略，没有受到数据集本身的偏见影响。

离网风险： 最后，本文对离网预测模块给出的离网风险值的影响感兴趣，想探究 ICSM 算法对高离网风险的用户是否能够挽留成功。首先，本文将离网率风险值分成 5 个人数相等的类别，其中类别越高，风险越高。从图 5-12 可以看出，虽然流失风险等级之间的奖励总和不相等，但当流失风险等级增加时，平均奖励只会出现略微的衰减，离网风险最高组所在用户的平均挽留成功率与离网风险最低组所在用户的平均挽留成功率相差不大，这也证明了 ICSM 算法的健壮性。

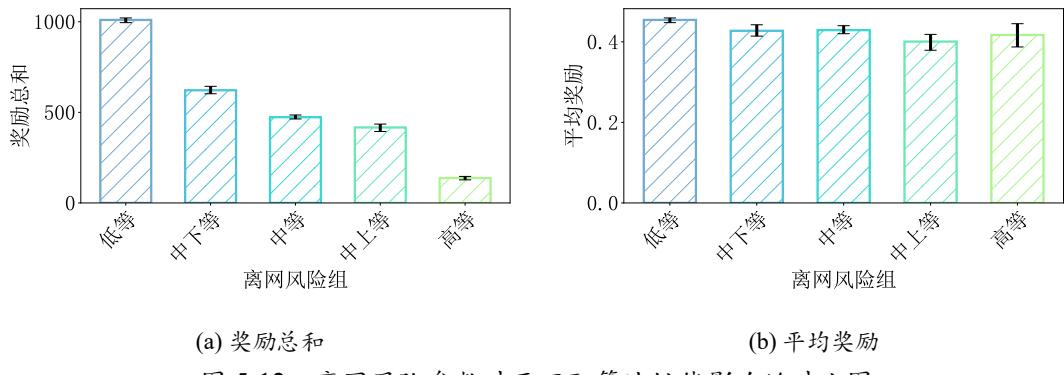


图 5-12 离网风险参数对于匹配算法性能影响的对比图

5.7 本章小结

由于互联网卡用户的离网原因众多，高达上百种。并且通过耦合分析，本章发现互联网卡用户往往因为多个原因的叠加而发生离网行为，并且现阶段运营商营销部门的挽留措施设计得较为粗糙，例如充送话费、送通用流量/定向流量和通话时长等粗粒度挽留措施，无法为每个用户进行定制个性化的挽留措施，导致即使提早知道了预离网用户名单，也无法通过较低的挽留成本甚至无法将预离网用户留存下来。针对以上问题，基于互联网卡用户离网预测模块给出的预离网用户名单，本章首先对挽留策略匹配问题建模成多臂老虎机问题，然后接收由互联网卡用户离网预测模块给出的离网风险值和互联网卡预离网用户离网偏好表征模块给出的离网偏好，使用基于领域知识的分布初始化奖励生成模型，最后训练基于预算有限的上下文感知的挽留策略匹配算法。

此外，本章还使用真实世界的某个运营商的数据来检验模型真实性能。从性能评估、健壮性测试和参数影响等角度全面地验证了 *ICSM* 算法和 *UPRF* 框架的有效性。此外，6.3 节还评估了不同参数对于 *ICSM* 算法和 *UPRF* 框架有效性的影响。通过分析上述实验结果，本文发现 *ICSM* 算法和 *UPRF* 框架在不同参数设置的情况下，都具有较好的健壮性。

第6章 总结与展望

6.1 工作总结

互联网卡（即流量卡）是近年来在我国兴起的运营商与互联网企业联合推动的一种新型商业模式。互联网卡以其低廉的套餐价格和充足的定向流量而受到了用户的青睐。从2017年推出起，互联网卡用户人数呈爆炸式增长。但是，当前面向互联网卡用户的运营系统由于缺乏信息化、智能化等算法模型的支撑，存在高离网率，离网原因众多，挽留成功率低等诸多问题。为了解决这些问题，本文从数据驱动的角度，提出了一种集成用户离网预测，用户离网偏好表征和挽留策略匹配的互联网卡用户干预框架UPRF，并且该框架能够泛化到其他的应用场景中。UPRF框架主要包含了以下三部分内容：

- 1) 通过数据分析和特征工程提取能明显区别互联网卡离网用户和正常用户的特征，设计并实现了一种基于自注意力机制的离网预测模型，向运营商输出下月的潜在离网用户名单和对应的离网风险值列表。
- 2) 基于离网预测模块给出的预离网用户集合，通过挑选与离网原因相关性较强的偏好特征，使用双重排名离散化和用户自适应权重归一化算法生成对应的离网偏好矩阵。
- 3) 基于离网预测模块给出的预离网用户集合和离网偏好模块给出的对应的离网偏好矩阵，本文采用基于领域知识的分布初始化奖励模型，最后在预先设定预算的上下文中训练互联网卡挽留策略匹配算法，得到潜在互联网卡离网用户相匹配的挽留策略，以最大化运营商的长期商业利益。

以下是针对每个模块的总结。

1) 互联网卡用户离网预测模块

由于运营商互联网卡的用户数据规模较大，异构特征显著，且离网时间没有固定规律，因此对互联网卡用户离网用户做出全面、精准和高效的预测是非常困难的。首先，本模块从互联网卡用户离网趋势、离网行为和离网原因等做了详细的分析，得到本模块需在本月初就给出离网预测结果的结论。然后，本模块基于数据分析的结果从用户的属性和行为两类数据中分别提取了能够明显区别互联网卡离网用户和正常用户的静态画像特征和序列特征。最后，本模块设计和实现了一种融合主成分分析算法和自注意力机制的互联网卡用户离网预测模型，能够高效利用用户的画像特征和序列特征，最后在当月初向运营商和以下两个模块输出当月的潜在离网用户名单和对应的离网风险值列表。

2) 互联网卡预离网用户离网偏好表征模块

由于互联网卡用户的离网原因众多，高达上百种并且通过耦合分析，本文发现互联网卡用户往往因为多个原因的叠加而发生离网行为，这也加大了预测互联网卡用户离网原因的挑战。与此同时，预测互联网卡用户离网原因又是十分重要的，可以用以“对症下药”，向互联网卡预离网用户匹配合适的挽留策略，以真正地挽留住用户。为了应对以上挑战，本模块首先从呈长尾分布的离网原因分布中抽取了5个能够被数据反映的离网原因，然后挑选了与这些离网原因较为相关的偏好特征，接着设计并实现了基于等频分箱的排名归一化算法，得到预离网用户的原始离网偏好向量，最后通过不可信用户过滤机制排除了不活跃的预离网用户，使用用户自适应权重归一化算法，想运营商和挽留策略匹配模块输出预离网用户的离网偏好表征。

3) 互联网卡预离网用户挽留策略匹配模块

由于现阶段运营商营销部门的挽留措施设计得较为粗糙，例如充送话费、送通用流量/定向流量和通话时长等粗粒度挽留措施，无法为每个用户进行定制个性化的挽留措施，导致即使提早知道了预离网用户名单，也无法通过较低的挽留成本甚至无法将预离网用户留存下来。针对以上问题，基于互联网卡用户离网预测模块给出的预离网用户名单，本模块首先对挽留策略匹配问题建模成序列决策问题，然后接收由互联网卡用户离网预测模块给出的离网风险值以及互联网卡预离网用户离网偏好表征模块给出的离网偏好，使用基于领域知识的分布初始化奖励生成模型，最后训练基于预算有限的上下文感知的挽留策略匹配算法。

6.2 未来工作展望

本研究针对互联网卡用户离网/流失严重问题，提出了一种集成用户离网预测，用户离网偏好表征和挽留策略匹配的干预框架，对互联网卡用户离网预测和挽留性能进行了提高，但是，本课题目前仍然存在诸多不足，所以有如下展望：

(1) 目前本文提出的ICCP模型和UPRF框架虽然大大提高了离网预测和挽留策略匹配的性能，但是由于本文只拥有一个通信运营商的数据。而不同的运营商可以提供不同的套餐和不同的互联网服务来吸引用户，这可能导致不同的流量消费分布，不同的用户画像和不同的用户联网模式。所以一种跨运营商的健壮性离网预测和干预框架仍然是一个值得研究的问题。

(2) 由于隐私问题，本文无法收集用户实时位置和基站位置信息的数据，在用户属性表中只提前知道用户所在城市。然而，在文献中，已经广泛验证了用户网络模式可以随位置而变化^[112]，这在本工作中是缺乏的。因此本文下一步将尽可能地采集用户的空间信息，然后通过对空间信息的分析揭示更多的用户行为偏好和模式，这可以进一步提升这项工作的性能。

(3) 尽管本文提出的 *UPRF* 框架约定了每个模块的输入输出数据的规范，以保证其能泛化到其他应用场景。但是本框架并没有充分利用不同模块之间的相关性，如果将不同模块的目标函数都统一到多任务学习的范式当中，就可以建立一个端到端充分优化的用户干预框架，这也是本文接下来的重点工作。

(4) 因为互联网卡用户数据属于个人数据，如何需要考虑保护用户个人数据的隐私问题，在本文中，我们已经将用户 ID 脱敏，但还是包含了一些个人特征信息。我们打算采用联邦学习范式以及先进的加密算法对用户的画像特征以及序列特征进行隐私保护，从而保证从数据处理到本地模型训练再到梯度上传到中央模型收敛的全流程中用户隐私不会被泄露。

参考文献

- [1] Xu D, Zhou A, Zhang X, et al. Understanding operational 5g: A first measurement study on its coverage, performance and energy consumption [C]// Proceedings of the Annual conference of the ACM Special Interest Group on Data Communication on the applications, technologies, architectures, and protocols for computer communication. 2020: 479-494.
- [2] Tan Z, Li Y, Li Q, et al. Supporting mobile vr in lte networks: How close are we? [J]. Proceedings of the ACM on Measurement and Analysis of Computing Systems, 2018, 2(1): 1-31.
- [3] Deng Y, Lyu F, Ren J, et al. Auction: Automated and quality-aware client selection framework for efficient federated learning [J]. IEEE Transactions on Parallel and Distributed Systems, 2021, 33(8): 1996-2009.
- [4] Krauß V, Boden A, Oppermann L, et al. Current practices, challenges, and design implications for collaborative ar/vr application development [C]//Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems. 2021: 1-15.
- [5] Wu F, Yang W, Lu J, et al. Rlss: A reinforcement learning scheme for hd map data source selection in vehicular ndn [J]. IEEE Internet of Things Journal, 2021, 9(13): 10777-10791.
- [6] Inc C S. Cisco annual internet report (2018–2023) [M]. Cisco Systems, Inc. San Jose, CA, USA, 2020.
- [7] Tian Y, Zhou K, Pelleg D. What and how long: Prediction of mobile app engagement [J]. ACM Transactions on Information Systems (TOIS), 2021, 40(1): 1-38.
- [8] Sheoran A, Fahmy S, Osinski M, et al. Experience: Towards automated customer issue resolution in cellular networks [C]//Proceedings of the 26th Annual International Conference on Mobile Computing and Networking. 2020: 1-13.
- [9] Wang G, Chen X, Zhang F, et al. Experience: Understanding long-term evolving patterns of shared electric vehicle networks [C]//The 25th Annual International Conference on Mobile Computing and Networking. 2019: 1-12.
- [10] Yu D, Li Y, Xu F, et al. Smartphone app usage prediction using points of interest [J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous

- Technologies, 2018, 1(4): 1-21.
- [11] Li T, Li Y, Hoque M A, et al. To what extent we repeat ourselves? discovering daily activity patterns across mobile app usage [J]. IEEE Transactions on Mobile Computing, 2020, 21(4): 1492-1507.
- [12] Wang G, Vaish H R, Sun H, et al. Understanding user behavior in car sharing services through the lens of mobility: Mixing qualitative and quantitative studies [J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2020, 4(4): 1-30.
- [13] Verbraken T, Verbeke W, Baesens B. A novel profit maximizing metric for measuring classification performance of customer churn prediction models [J]. IEEE transactions on knowledge and data engineering, 2012, 25(5): 961-973.
- [14] Huang Y, Zhu F, Yuan M, et al. Telco churn prediction with big data [C]// Proceedings of the 2015 ACM SIGMOD international conference on management of data. 2015: 607-618.
- [15] Óskarsdóttir M, Bravo C, Verbeke W, et al. Social network analytics for churn prediction in telco: Model building, evaluation and network architecture [J]. Expert Systems with Applications, 2017, 85: 204-220.
- [16] Idris A, Khan A. Churn prediction system for telecom using filter-wrapper and ensemble classification [J]. The Computer Journal, 2017, 60(3): 410-430.
- [17] Usman M, Ahmad W, Fong A. Design and implementation of a system for comparative analysis of learning architectures for churn prediction [J]. IEEE Communications Magazine, 2021, 59(9): 86-90.
- [18] Reelfs J H, Bergmann M, Hohlfeld O, et al. Understanding & predicting user lifetime with machine learning in an anonymous location-based social network [C]//Companion Proceedings of the Web Conference 2021. 2021: 324-331.
- [19] Jain H, Khunteta A, Srivastava S. Telecom churn prediction and used techniques, datasets and performance measures: a review [J]. Telecommunication Systems, 2021, 76: 613-630.
- [20] Pudipeddi J S, Akoglu L, Tong H. User churn in focused question answering sites: characterizations and prediction [C]//Proceedings of the 23rd International conference on world wide web. 2014: 469-474.
- [21] Liu X, Xie M, Wen X, et al. A semi-supervised and inductive embedding model for churn prediction of large-scale mobile games [C]//2018 ieee international conference on data mining (icdm). IEEE, 2018: 277-286.

- [22] Wangperawong A, Brun C, Laudy O, et al. Churn analysis using deep convolutional neural networks and autoencoders [J]. arXiv preprint arXiv:1604.05377, 2016.
- [23] Zhang G, Zeng J, Zhao Z, et al. A counterfactual modeling framework for churn prediction [C]//Proceedings of the Fifteenth ACM International Conference on Web Search and Data Mining. 2022: 1424-1432.
- [24] Liu X, Ai W, Li H, et al. Deriving user preferences of mobile apps from their management activities [J]. ACM Transactions on Information Systems (TOIS), 2017, 35(4): 1-32.
- [25] Yang C, Shi X, Jie L, et al. I know you'll be back: Interpretable new user clustering and churn prediction on a mobile social application [C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018: 914-922.
- [26] Zheng A, Chen L, Xie F, et al. Keep you from leaving: Churn prediction in online games [C]//Database Systems for Advanced Applications: 25th International Conference, DASFAA 2020, Jeju, South Korea, September 24–27, 2020, Proceedings, Part II 25. Springer, 2020: 263-279.
- [27] Li J, Lu H, Wang C, et al. A difficulty-aware framework for churn prediction and intervention in games [C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. 2021: 943-952.
- [28] Wang Z, Zhao Y, Chen X, et al. Task assignment with worker churn prediction in spatial crowdsourcing [C]//Proceedings of the 30th ACM International Conference on Information & Knowledge Management. 2021: 2070-2079.
- [29] Yang Y, Liu Z, Tan C, et al. To stay or to leave: Churn prediction for urban migrants in the initial period [C]//Proceedings of the 2018 World Wide Web Conference. 2018: 967-976.
- [30] Zhao S, Xu Y, Luo Z, et al. Player behavior modeling for enhancing role-playing game engagement [J]. IEEE Transactions on Computational Social Systems, 2021, 8(2): 464-474.
- [31] 徐树乔. 基于 XGBoost 的 Bagging 方法的电信客户流失预测应用研究 [D]. 华南理工大学, 2019.
- [32] 郑红, 叶成, 金永红, 等. 基于 Stacking 集成学习的流失用户预测方法 [J]. 应用科学学报, 2020, 38(6): 944-954.
- [33] 孙碧颖. 基于神经网络算法构建电信用户流失预测模型的研究 [D]. 兰州大

- 学, 2016.
- [34] 于瑞云, 薛林, 安轩邈, 等. 基于改进 GA-BP 的移动通信用户流失预测算法 [J]. 东北大学学报: 自然科学版, 2019, 40(2): 180-185.
- [35] 刘光远, 苑森森, 董立岩. 数据挖掘方法在用户流失预测分析中的应用 [J]. 计算机工程与应用, 2007, 43(9): 154-156.
- [36] 赖院根, 刘砾利. 基于客户价值的信息用户流失预测研究 [J]. 情报理论与实践, 2011, 34(7): 67-70.
- [37] Kim Y. Toward a successful crm: variable selection, sampling, and ensemble [J]. Decision Support Systems, 2006, 41(2): 542-553.
- [38] Braun M, Schweidel D A. Modeling customer lifetimes with multiple causes of churn [J]. Marketing Science, 2011, 30(5): 881-902.
- [39] Keaveney S M. Customer switching behavior in service industries: An exploratory study [J]. Journal of marketing, 1995, 59(2): 71-82.
- [40] Fader P S, Hardie B G. Customer-base valuation in a contractual setting: The perils of ignoring heterogeneity [J]. Marketing Science, 2010, 29(1): 85-93.
- [41] Gupta S, Lehmann D R, Stuart J A. Valuing customers [J]. Journal of marketing research, 2004, 41(1): 7-18.
- [42] Rust R T, Zahorik A J, Keiningham T L. Return on quality (roq): Making service quality financially accountable [J]. Journal of marketing, 1995, 59(2): 58-70.
- [43] Ebbes P, Ascarza E, Netzer O, et al. Beyond the target customer: Social effects of crm campaigns [R]. HEC Paris, 2015.
- [44] Nitzan I, Libai B. Social effects on customer retention [J]. Journal of Marketing, 2011, 75(6): 24-38.
- [45] Haenlein M. Social interactions in customer churn decisions: The impact of relationship directionality [J]. International Journal of Research in Marketing, 2013, 30(3): 236-248.
- [46] Giudicati G, Riccaboni M, Romiti A. Experience, socialization and customer retention: Lessons from the dance floor [J]. Marketing Letters, 2013, 24: 409-422.
- [47] Neslin S, Gupta S, Kamakura W, et al. Defection detection: improving predictive accuracy of customer churn models [J]. Tuck School of Business, Dartmouth College, 2004.
- [48] Lemmens A, Gupta S. Managing churn to maximize profits [J]. Marketing Science, 2020, 39(5): 956-973.

- [49] 于小兵, 曹杰, 现在武. 客户流失问题研究综述 [J]. 计算机集成制造系统, 2012, 18(10): 2253-2263.
- [50] 龙克树, 邓娟, 刘晓斌. 基于机器学习算法的运营商用户流失预判及应对策略研究 [J]. 信息记录材料, 2020.
- [51] Yang S, Han K, Zheng Z, et al. Towards personalized task matching in mobile crowdsensing via fine-grained user profiling [C]//IEEE INFOCOM 2018-IEEE Conference on Computer Communications. IEEE, 2018: 2411-2419.
- [52] Zhang J, Bai B, Lin Y, et al. General-purpose user embeddings based on mobile app usage [C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2020: 2831-2840.
- [53] Lyu F, Ren J, Cheng N, et al. Lead: Large-scale edge cache deployment based on spatio-temporal wifi traffic statistics [J]. IEEE Transactions on Mobile Computing, 2020, 20(8): 2607-2623.
- [54] Sun F, Wang P, Zhao J, et al. Mobile data traffic prediction by exploiting time-evolving user mobility patterns [J]. IEEE Transactions on mobile computing, 2021, 21(12): 4456-4470.
- [55] Wu F, Lyu F, Wu H, et al. Characterizing user association patterns for optimizing small-cell edge system performance [J]. IEEE Network, 2022.
- [56] Tian Y, Zhou K, Lalmas M, et al. Identifying tasks from mobile app usage patterns [C]//Proceedings of the 43rd international ACM SIGIR conference on research and development in information retrieval. 2020: 2357-2366.
- [57] Li T, Zhang M, Cao H, et al. "what apps did you use?" : Understanding the long-term evolution of mobile app usage [C]//Proceedings of The Web Conference 2020. 2020: 66-76.
- [58] Pi Q, Bian W, Zhou G, et al. Practice on long sequential user behavior modeling for click-through rate prediction [C]//Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2019: 2671-2679.
- [59] Luo C, Zeng J, Yuan M, et al. Telco user activity level prediction with massive mobile broadband data [J]. ACM Transactions on Intelligent Systems and Technology (TIST), 2016, 7(4): 1-30.
- [60] Xia T, Li Y, Feng J, et al. Deepapp: predicting personalized smartphone app usage via context-aware multi-task learning [J]. ACM Transactions on Intelligent Systems and Technology (TIST), 2020, 11(6): 1-12.

- [61] Tian Y, Zhou K, Lalmas M, et al. Cohort modeling based app category usage prediction [C]//Proceedings of the 28th ACM Conference on User Modeling, Adaptation and Personalization. 2020: 248-256.
- [62] Shen J, Cao J, Liu X. Bag: Behavior-aware group detection in crowded urban spaces using wifi probes [C]//The World Wide Web Conference. 2019: 1669-1678.
- [63] Lu H, Zhang M, Ma S. Between clicks and satisfaction: Study on multi-phase user preferences and satisfaction for online news reading [C]//The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval. 2018: 435-444.
- [64] Yao Y, Gu B, Su Z, et al. Mvstgn: A multi-view spatial-temporal graph network for cellular traffic prediction [J]. IEEE Transactions on Mobile Computing, 2021.
- [65] Hu R, Liu Y, Li Y, et al. Exploiting user preference and mobile peer influence for human mobility annotation [J]. ACM Transactions on Knowledge Discovery from Data (TKDD), 2020, 14(6): 1-18.
- [66] Wu T W, Chien Y L, Lee H P, et al. Im receptivity and presentation-type preferences among users of a mobile app with automated receptivity-status adjustment [C]//Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems. 2021: 1-14.
- [67] Sakai T, Zeng Z. Retrieval evaluation measures that agree with users' serp preferences: Traditional, preference-based, and diversity measures [J]. ACM Transactions on Information Systems (TOIS), 2020, 39(2): 1-35.
- [68] Shen Z, Yang K, Du W, et al. Deepapp: a deep reinforcement learning framework for mobile application usage prediction [C]//Proceedings of the 17th Conference on Embedded Networked Sensor Systems. 2019: 153-165.
- [69] Dou Y, Shu K, Xia C, et al. User preference-aware fake news detection [C]//Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2021: 2051-2055.
- [70] Gao S, Chen X, Liu L, et al. Learning to respond with your favorite stickers: A framework of unifying multi-modality and user preference in multi-turn dialog [J]. ACM Transactions on Information Systems (TOIS), 2021, 39(2): 1-32.
- [71] LeCun Y, Bengio Y, Hinton G. Deep learning [J]. nature, 2015, 521(7553): 436-444.
- [72] Bengio Y, Courville A, Vincent P. Representation learning: A review and new

- perspectives [J]. IEEE transactions on pattern analysis and machine intelligence, 2013, 35(8): 1798-1828.
- [73] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks [J]. Communications of the ACM, 2020, 63(11): 139-144.
- [74] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [J]. Advances in neural information processing systems, 2017, 30.
- [75] Martens J, Sutskever I. Learning recurrent neural networks with hessian-free optimization [C]//Proceedings of the 28th international conference on machine learning (ICML-11). 2011: 1033-1040.
- [76] Sutskever I, Martens J, Hinton G E. Generating text with recurrent neural networks [C]//Proceedings of the 28th international conference on machine learning (ICML-11). 2011: 1017-1024.
- [77] Graves A, Schmidhuber J. Offline handwriting recognition with multidimensional recurrent neural networks [J]. Advances in neural information processing systems, 2008, 21.
- [78] De Mulder W, Bethard S, Moens M F. A survey on the application of recurrent neural networks to statistical language modeling [J]. Computer Speech & Language, 2015, 30(1): 61-98.
- [79] Xu K, Ba J, Kiros R, et al. Show, attend and tell: Neural image caption generation with visual attention [C]//International conference on machine learning. PMLR, 2015: 2048-2057.
- [80] Graves A, Jaitly N. Towards end-to-end speech recognition with recurrent neural networks [C]//International conference on machine learning. PMLR, 2014: 1764-1772.
- [81] Zhang H, Wang Z, Liu D. A comprehensive review of stability analysis of continuous-time recurrent neural networks [J]. IEEE Transactions on Neural Networks and Learning Systems, 2014, 25(7): 1229-1262.
- [82] Schuster M, Paliwal K K. Bidirectional recurrent neural networks [J]. IEEE transactions on Signal Processing, 1997, 45(11): 2673-2681.
- [83] Hochreiter S, Schmidhuber J. Long short-term memory [J]. Neural computation, 1997, 9(8): 1735-1780.
- [84] Lei T, Zhang Y, Wang S I, et al. Simple recurrent units for highly parallelizable recurrence [J]. arXiv preprint arXiv:1709.02755, 2017.
- [85] Jang M, Seo S, Kang P. Recurrent neural network-based semantic variational

- autoencoder for sequence-to-sequence learning [J]. *Information Sciences*, 2019, 490: 59-73.
- [86] Larochelle H, Hinton G E. Learning to combine foveal glimpses with a third-order boltzmann machine [J]. *Advances in neural information processing systems*, 2010, 23.
- [87] Mnih V, Heess N, Graves A, et al. Recurrent models of visual attention [J]. *Advances in neural information processing systems*, 2014, 27.
- [88] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate [J]. *arXiv preprint arXiv:1409.0473*, 2014.
- [89] Luong M T, Pham H, Manning C D. Effective approaches to attention-based neural machine translation [J]. *arXiv preprint arXiv:1508.04025*, 2015.
- [90] Yang Z, Yang D, Dyer C, et al. Hierarchical attention networks for document classification [C]//Proceedings of the 2016 conference of the North American chapter of the association for computational linguistics: human language technologies. 2016: 1480-1489.
- [91] Wang Y, Huang M, Zhu X, et al. Attention-based lstm for aspect-level sentiment classification [C]//Proceedings of the 2016 conference on empirical methods in natural language processing. 2016: 606-615.
- [92] Anderson P, He X, Buehler C, et al. Bottom-up and top-down attention for image captioning and visual question answering [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6077-6086.
- [93] Ma Y, Peng H, Cambria E. Targeted aspect-based sentiment analysis via embedding commonsense knowledge into an attentive lstm [C]//Proceedings of the AAAI conference on artificial intelligence: volume 32. 2018.
- [94] Chorowski J K, Bahdanau D, Serdyuk D, et al. Attention-based models for speech recognition [J]. *Advances in neural information processing systems*, 2015, 28.
- [95] Bahdanau D, Chorowski J, Serdyuk D, et al. End-to-end attention-based large vocabulary speech recognition [C]//2016 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2016: 4945-4949.
- [96] Kim S, Hori T, Watanabe S. Joint ctc-attention based end-to-end speech recognition using multi-task learning [C]//2017 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2017: 4835-4839.
- [97] Cho K, Van Merriënboer B, Bahdanau D, et al. On the properties of neural machine translation: Encoder-decoder approaches [J]. *arXiv preprint*

- arXiv:1409.1259, 2014.
- [98] Parmar N, Vaswani A, Uszkoreit J, et al. Image transformer [C]//International conference on machine learning. PMLR, 2018: 4055-4064.
- [99] Zhou L, Zhou Y, Corso J J, et al. End-to-end dense video captioning with masked transformer [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8739-8748.
- [100] Sun F, Liu J, Wu J, et al. Bert4rec: Sequential recommendation with bidirectional encoder representations from transformer [C]//Proceedings of the 28th ACM international conference on information and knowledge management. 2019: 1441-1450.
- [101] Durand A, Achilleos C, Iacovides D, et al. Contextual bandits for adapting treatment in a mouse model of de novo carcinogenesis [C]//Machine learning for healthcare conference. PMLR, 2018: 67-82.
- [102] Mary J, Gaudel R, Preux P. Bandits and recommender systems [C]//Machine Learning, Optimization, and Big Data: First International Workshop, MOD 2015, Taormina, Sicily, Italy, July 21-23, 2015, Revised Selected Papers 1. Springer, 2015: 325-336.
- [103] Ding K, Li J, Liu H. Interactive anomaly detection on attributed networks [C]// Proceedings of the twelfth ACM international conference on web search and data mining. 2019: 357-365.
- [104] Lai T L, Robbins H, et al. Asymptotically efficient adaptive allocation rules [J]. Advances in applied mathematics, 1985, 6(1): 4-22.
- [105] Auer P, Cesa-Bianchi N, Fischer P. Finite-time analysis of the multiarmed bandit problem [J]. Machine learning, 2002, 47: 235-256.
- [106] Bouneffouf D, Féraud R. Multi-armed bandit problem with known trend [J]. Neurocomputing, 2016, 205: 16-21.
- [107] Agrawal S, Goyal N. Analysis of thompson sampling for the multi-armed bandit problem [C]//Conference on learning theory. JMLR Workshop and Conference Proceedings, 2012: 39-1.
- [108] Langford J, Zhang T. The epoch-greedy algorithm for multi-armed bandits with side information [J]. Advances in neural information processing systems, 2007, 20.
- [109] Agrawal S, Goyal N. Thompson sampling for contextual bandits with linear payoffs [C]//International conference on machine learning. PMLR, 2013: 127-135.

- [110] Li L, Chu W, Langford J, et al. A contextual-bandit approach to personalized news article recommendation [C]//Proceedings of the 19th international conference on World wide web. 2010: 661-670.
- [111] Allesiardo R, Féraud R, Bouneffouf D. A neural networks committee for the contextual bandit problem [C]//Neural Information Processing: 21st International Conference, ICONIP 2014, Kuching, Malaysia, November 3-6, 2014. Proceedings, Part I 21. Springer, 2014: 374-381.
- [112] Song Y, Liu Y, Qiu W, et al. Miff: Human mobility extractions with cellular signaling data under spatio-temporal uncertainty [J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2020, 4(4): 1-19.

攻读学位期间主要的研究成果

一、学术论文

- [1] Fan Wu, Feng Lyu, Ju Ren, Peng Yang, **Kai Qian**, Shijie Gao, Yaoxue Zhang. Characterizing Internet Card User Portraits for Efficient Churn Prediction Model Design[J]. IEEE Transaction on Mobile Computing: 1(1):1-10. (SCI 检索, JCR1 区)

二、发明专利

发明专利 3 项，其中 2 项已授权，1 项已公开

- [1] 吕丰, 钱凯, 吴帆, 任炬, 张尧学. 基于深度学习的用户流失预测方法及系统. 申请号: CN2021112951915, 授权公告号: CN 114022202 B
- [2] 吕丰, 钱凯, 吴帆, 任炬, 张尧学. 基于用户画像的互联网卡用户流失预测方法及系统. 申请号: 2021112981395, 公开号: CN 113962160 A
- [3] 高世杰, 张永敏, 王姗姗, 周杰钰, 钱凯. 一种数据驱动的互联网卡用户价值分类方法设备及介质: ZL 202211513076.5[P]. 授权公告号: CN 115563555 B

三、个人获奖情况

- [1] 2020 年度中南大学研究生一等奖学金
- [2] 2021 年度中南大学研究生二等奖学金
- [3] 2022 年度中南大学研究生二等奖学金

致谢

白驹过隙，日月如梭，不知不觉间已经在透明计算实验室度过了三年难忘的研究生生活了。其中酸甜苦辣，百般滋味，只有自己知晓，不足为外人道也。但是，我今天能成功地取得硕士学位，离不开家人和以下老师，朋友的一贯支持和有力帮助。

首先，我想感谢我的恩师，吕丰教授。在透明计算实验室的三年多的研究生生活中，吕老师不遗余力地指导我进行科研课题的研究，教授我解决问题的通用范式，身体力行地为我树立想要从事科研应当学习的榜样。在每次的组会讨论，外出谈判中，我都能从吕老师身上学习到了更加准确的思维逻辑和为人处世。

其次，我想感谢实验室的吴帆、刘彤、周杰钰师兄和卢华丽、段思婧师姐，他们作为博士师兄、师姐，首先给了在科研和生活中非常多的指导以及帮助，并且他们身上刻苦钻研的科研精神和求实务真的科研态度深深地激励了我。

然后，我想感谢实验室的同门，包括肖飞、高世杰、王艺锋、何骁豪、刘佳璇、张静，还有赵张梦茹、王姗姗、孟陈莹、唐程等师弟师妹们，他们每个人身上都有各自的闪光点和才华，和他们的朝夕相处中，我不仅感受到了蓬勃的青春，而且被处处的真情所感动，大家都十分团结，互帮互助，在一起时充满了欢声笑语。只可惜时不我待，我不得不和他们挥手告别。但是往昔的情谊都留在心中，不必多说。

最后，我想感谢我的家人们，包括我的爸爸、妈妈、爷爷、奶奶、外公、外婆等，在我外出求学的第5到7个年头，包括之后的8到12个年头，无论我提出什么要求，只要是我自己愿意的，他们都无条件地支持我，并且及时地给予我物质上的支持和精神的援助。他们对我的爱，我也都深深铭刻在心中，而我也将我的实际行动回报他们对我的爱。

最后的最后，感谢所有花时间阅读我硕士学位的老师、同学和朋友们，你们的意见和建议将使我变得更好。希望在下一个四年，你们能看到我更加优秀的博士学位论文。言尽于此，我继续去科研了。